



DÍA 1 • LUNES 08:00 – 13:00

# Fundamentos, datos y diseño inverso

De un cristal a números que un algoritmo aprende, y de la propiedad al material

# El plan de hoy

*Hoy no usamos el cluster: teoría y una demostración en vivo*

| Hora  | Bloque    | Actividad                                                                        |
|-------|-----------|----------------------------------------------------------------------------------|
| 08:00 | T1.1      | Bienvenida, mapa del curso y logística virtual                                   |
| 08:15 | T1.2      | Por qué IA en materiales: casos reales                                           |
| 08:35 | T1.3      | Introducción a ML: regresión, clasificación y validación (Fabricio Quirós, CNCA) |
| 09:35 | T1.4      | La IA como herramienta, no como sustituto del criterio                           |
| 09:45 | Conceptos | Cristal, propiedades, estabilidad y datos                                        |
| 10:05 | T1.5      | Feature engineering: representar un material                                     |
| 10:30 |           | Receso                                                                           |
| 11:00 | T1.6      | Ecosistema de herramientas                                                       |
| 11:10 | T2.3      | Bases de datos computacionales y sesgos en los datos                             |
| 11:30 | T2.4      | Diseño inverso: de la propiedad al material                                      |
| 12:00 | T2.5      | Interpretabilidad: qué aprendió el modelo                                        |
| 12:20 | Demo      | El notebook 01 en vivo                                                           |
| 12:45 |           | Tarea: activar la cuenta de Kabré y probar el entorno; preguntas y cierre        |

**Términos** **IA:** inteligencia artificial: sistemas que aprenden o deciden a partir de datos · **ML (aprendizaje automático):** algoritmos que aprenden una relación a partir de ejemplos · **Regresión:** predecir un número (por ejemplo K en GPa) · **Clasificación:** predecir una categoría (por ejemplo el sistema cristalino) · **Validación:** comprobar el modelo con datos que no vio · **CNCA:** Colaboratorio Nacional de Computación Avanzada, del CeNAT · **Descriptor (feature):** número que describe un material y que el modelo usa como entrada · **Feature engineering:** diseñar y calcular los descriptores de cada material · **Sesgo:** error sistemático; en datos, las preferencias de quien eligió qué medir o calcular · **Diseño inverso:** partir de la propiedad deseada y buscar el material · **Interpretabilidad:** entender qué usó un modelo para hacer sus predicciones · **Notebook:** documento con celdas de código y texto que se ejecutan en orden · **Kabré:** supercomputadora del CNCA



T1.1 • 15 min

# Bienvenida y mapa del curso

Qué vamos a hacer, cómo y dónde



CeNAT  
Centro Nacional de Alta Tecnología



## PREGUNTA PARA EL GRUPO

# Para conocernos: ¿de dónde vienen?

- A Síntesis o procesamiento de materiales en el laboratorio
- B Caracterización (difracción, microscopía, espectroscopía...)
- C Cálculo o simulación (DFT, dinámica molecular...)
- D Industria o gestión de procesos
- E TI, datos o software

**Términos** **XRD**: difracción de rayos X: picos que revelan la red cristalina · **DFT**: teoría del funcional de la densidad: cálculo cuántico de energía y electrones · **Dinámica molecular**: simulación del movimiento de los átomos en el tiempo


*Escriban la letra en el chat · 1 minuto*

# La idea del curso en una frase

- Usar inteligencia artificial para elegir mejor qué material estudiar y qué experimento hacer, sin tener que convertirse en programador.
- Para quién: personas de laboratorio, industria y academia con formación en materiales, química, física o ingeniería.
- Qué se llevan: un flujo de trabajo completo (datos → modelo → candidatos → experimento) y notebooks que pueden adaptar a sus propios datos.
- Qué no es: un curso de programación ni de teoría de ML. Usamos las herramientas con criterio físico.

**Idea clave** Al final del Día 5 cada equipo defiende una propuesta con datos, modelo y limitaciones honestas.

# Cinco días, un flujo de trabajo



- Lunes: solo teoría. Martes: solo práctica. Miércoles a viernes: teoría en la primera mitad y práctica en la segunda.
- Cada día termina con un ejercicio para casa cuya solución vemos al inicio del día siguiente.

**Términos** **Random Forest**: promedio de muchos árboles de decisión entrenados al azar · **Screening**: evaluar con un modelo rápido muchos candidatos y quedarse con los mejores · **SHAP**: reparte cada predicción entre los descriptores: valor base + aportes = predicción · **Modelo de difusión**: genera quitando ruido paso a paso, partiendo de ruido puro · **GPU**: procesador gráfico; acelera el entrenamiento y uso de redes neuronales · **DoE**: diseño de experimentos: elegir de antemano qué combinaciones medir · **Optimización bayesiana (BO)**: ciclo: modelo con incertidumbre → elegir experimento → medir → repetir · **LANOTEC**: Laboratorio Nacional de Nanotecnología del CeNAT

# Dónde trabajamos desde el martes: Kabré OnDemand

*Nada que instalar: todo corre en la supercomputadora del CNCA desde el navegador*



- **Hoy:** solo la demostración. La tarea es activar su cuenta (doble factor) y probarla; desde el martes trabajamos aquí.
- **Día 3:** también en kura. Lo que necesita GPU se envía desde el notebook como un trabajo corto a la cola de GPU (nukwa).
- **Si algo falla:** copie el mensaje de error completo en el canal de soporte del curso.

**Términos OnDemand:** portal web de Kabré; abre Jupyter en el navegador · **Jupyter:** entorno web para trabajar con notebooks · **kura:** cola de CPU de Kabré donde corre Jupyter · **Kernel:** en Jupyter, el proceso de Python que ejecuta las celdas; en un GP, la función que mide el parecido entre dos puntos · **Python:** lenguaje de programación usado en el curso · **nukwa:** nodos de Kabré con GPU para trabajos cortos

# Reglas del juego



## Sesiones virtuales

- Cámara opcional, micrófono apagado salvo para preguntar
- Preguntas por chat en cualquier momento
- Salas pequeñas para las prácticas y el reto



## Evaluación

- Asistencia y participación: 20 %
- Ejercicios diarios (Días 1–4): 40 %
- Mini-reto final (Día 5): 40 %



## Cómo pedir ayuda

- Primero: leer el error completo
- Segundo: canal de soporte con captura
- No avanzar con errores de entorno

Fuente: Syllabus del curso



T1.2 • 20 min

# ¿Por qué IA en materiales?

El problema, las cuatro formas en que ayuda y casos reales



CeNAT  
Centro Nacional de Alta Tecnología



## PREGUNTA PARA EL GRUPO

# Piensen en su propio trabajo: ¿qué les cuesta más tiempo o dinero?

**A** Decidir qué material o composición probar

**B** Ajustar las condiciones de proceso


**C** Caracterizar y entender los resultados

**D** Conseguir datos confiables y ordenados

*Respondan en el chat · 1 minuto*

# El espacio de materiales posibles es enorme

- **~1.6 millones** de sistemas químicos distintos de 4 elementos tomados de 80, antes de elegir proporciones o estructura.
- **150 000+** materiales calculados en Materials Project, y horas o días por cada cálculo DFT o síntesis.
- Izquierda: combinaciones posibles por número de elementos, y cuántas sobreviven a reglas de carga y electronegatividad.
- Derecha: aun filtrado, el espacio supera por órdenes de magnitud a lo conocido (ICSD, Materials Project).




**Idea clave** La IA no reemplaza al experimento: ayuda a decidir cuál vale la pena hacer.

**Términos** **Materials Project**: base abierta de más de 150 000 materiales calculados con DFT • **Balance de carga**: las cargas de cationes y aniones suman cero • **Electronegatividad**: tendencia de un átomo a atraer electrones en un enlace • **ICSD**: base de estructuras cristalinas medidas experimentalmente

Fuente: Fig. de Davies et al. (2016), Chem 1, 617–627, doi:10.1016/j.chempr.2016.09.010, CC BY 4.0; Jain et al. (2013)

# Cuatro maneras de hacer ciencia de materiales

- **Experimental:** sintetizar, medir, comparar. Siglos de práctica.
- **Teórica:** leyes y modelos: termodinámica, mecánica cuántica.
- **Computacional:** simular con DFT o dinámica molecular.
- **Basada en datos:** aprender patrones de miles de resultados previos.
- La cuarta no reemplaza a las otras tres: se alimenta de ellas. Lo nuevo es la escala de los datos.



Fuente: Fig. 1 de Agrawal y Choudhary (2016), APL Mater. 4, 053208, doi:10.1063/1.4946894, CC BY 4.0

# Cuatro formas en que el aprendizaje automático ayuda



## Predecir propiedades

Un modelo entrenado con miles de cálculos predice en milisegundos lo que DFT tarda horas. Días 1 y 2.



## Buscar (diseño inverso)

Pasar de la pregunta "qué propiedad tiene" a "qué material tiene esta propiedad". Día 2.



## Generar

Proponer estructuras cristalinas que no están en ninguna base de datos. Día 3.




## Decidir el siguiente experimento

Optimización bayesiana y laboratorios autónomos. Día 4.

**Términos** **Entrenamiento y prueba:** datos con los que el modelo aprende y datos reservados para evaluarlo · **Laboratorio autónomo:** robots y algoritmos que sintetizan, miden y deciden en ciclo

Fuente: Butler et al. (2018); Schmidt et al. (2019)

# Anatomía de un proyecto de ML en materiales




- **Hoy:** datos y representación. Día 2: modelo y validación. Días 3 y 4: decisión.
- El paso más subestimado es el primero: una pregunta vaga produce un modelo inútil aunque tenga  $R^2$  alto.

Términos  $R^2$ : fracción de la variación que explica el modelo; 1 es perfecto

# El mismo ciclo, como lo resume la literatura

- Generar o reunir datos etiquetados, limpiarlos y elegir un algoritmo.
- **El conjunto de prueba** se aparta desde el inicio y no se toca hasta la evaluación final.
- Entrenar, validar y volver atrás: elegir otras variables, otros hiperparámetros. El ciclo se repite varias veces.
- Al final, el modelo sirve para predecir datos nuevos, que es lo que interesa.



**Términos** **Hiperparámetro:** ajuste del modelo que no se aprende de los datos (n.º de árboles)

Fuente: Fig. 1 de Schmidt et al. (2019), *npj Comput. Mater.* 5, 83, doi:10.1038/s41524-019-0221-0. Licencia CC BY 4.0

# Casos reales que vamos a mencionar en el curso

| Caso                                   | Qué hicieron                                                                                         | Día |
|----------------------------------------|------------------------------------------------------------------------------------------------------|-----|
| Superduros (Mansouri Tehrani 2018)     | Modelo entrenado con módulos elásticos DFT propone compuestos superduros; los sintetizan y miden     | 2   |
| GNoME (Merchant 2023)                  | Redes de grafos + DFT a gran escala: 2.2 millones de estructuras estables frente a las bases previas | 3   |
| MatterGen (Zeni 2025)                  | Modelo de difusión que genera cristales condicionados a química, simetría y propiedades              | 3   |
| A-Lab (Szymanski 2023)                 | Laboratorio autónomo: 41 de 58 compuestos objetivo sintetizados en 17 días                           | 4   |
| Experimentos fallidos (Raccuglia 2016) | Usar los intentos de síntesis que no funcionaron como datos de entrenamiento                         | 5   |


**Idea clave** Los casos exitosos combinan ML con cálculo y experimento; ninguno es "solo ML".

**Términos** **Material superduro**: dureza Vickers mayor que unos 40 GPa · **GNoME**: proyecto de Google DeepMind que propuso millones de estructuras con GNN y DFT · **GNN**: red neuronal que opera sobre un grafo de átomos y vecinos · **Grafo**: conjunto de nodos unidos por aristas; en un cristal, átomos y enlaces · **MatterGen**: modelo de difusión de Microsoft que genera cristales · **Generación condicionada**: pedirle al generador una propiedad, química o simetría · **A-Lab**: laboratorio autónomo de Berkeley que sintetiza con robots

Fuente: Mansouri Tehrani et al. (2018); Merchant et al. (2023); Zeni et al. (2025); Szymanski et al. (2023); Raccuglia et al. (2016)

# Así se ve uno de esos casos: el A-Lab

- Objetivos elegidos con cálculos DFT (Materials Project y Google DeepMind).
- Recetas propuestas por modelos entrenados con textos de síntesis de la literatura.
- Un robot dosifica, mezcla, calienta y mide difracción de rayos X; un modelo interpreta el patrón.
- Si la síntesis falla, el aprendizaje activo propone otra receta.



**Términos Aprendizaje activo:** el modelo elige qué dato medir después para aprender más rápido

Fuente: Fig. 1 de Szymanski et al. (2023), Nature 624, 86–91, doi:10.1038/s41586-023-06734-w. Licencia CC BY 4.0

# Y las advertencias, desde el primer día



## Basura entra, basura sale

El modelo aprende los errores de sus datos. Entrenado con DFT-PBE, predice PBE, no la realidad.



## Extrapolar es peligroso

Un modelo es confiable cerca de lo que vio. Química nueva = predicción dudosa.



## Pocos datos

En el laboratorio real hay decenas de experimentos, no miles. Eso cambia qué modelo usar (Días 4 y 5).

**Términos** **PBE:** aproximación de DFT más usada; subestima los band gaps · **Extrapolar:** predecir fuera de la región de los datos de entrenamiento · **Pocos datos (small data):** decenas o pocos cientos de experimentos; piden modelos simples con incertidumbre



## PREGUNTA PARA EL GRUPO

**Un modelo entrenado con band gaps calculados con DFT-PBE predice 1.1 eV para su material. ¿Qué gap esperan medir en el laboratorio?**

**A** Alrededor de 1.1 eV

**B** Menos de 1.1 eV

**C** Más de 1.1 eV

**Términos** **Band gap**: brecha de energía entre bandas ocupadas y vacías; cero en metales · **eV**: electronvoltio, unidad de energía de los electrones

*Respondan en el chat · 1 minuto*



T1.3 • 60 min

# Introducción a Machine Learning

Regresión, clasificación y validación • Fabricio Quirós (CNCA)



T1.4 • 10 min

## La IA como herramienta, no como sustituto

Después de ver cómo aprende un modelo: cómo usarlo sin dejar de pensar

# La IA es una herramienta, no un sustituto del criterio

*La misma herramienta puede hacernos mejores científicos o peores, según cómo la usemos*

## Como herramienta

- Usted define la pregunta y qué resultado lo convencería
- Acelera tareas cuyo resultado usted sabe verificar
- Propone hipótesis que se ponen a prueba con cálculo o experimento
- Usted puede explicar por qué el resultado tiene sentido físico

## Como sustituto

- Se acepta la respuesta porque suena convincente
- La herramienta decide qué preguntas vale la pena hacer
- Se producen más resultados, pero se entienden menos
- Nadie responde por el resultado

**Idea clave** Si usted no podría reconocer una respuesta equivocada, todavía no está listo para delegar esa tarea.

Fuente: Messeri y Crockett (2024)

# Lo que dicen los estudios sobre delegar el pensamiento

**-17 %**

en el examen sin IA, para estudiantes que practicaron con GPT-4 sin guías (casi 1000 estudiantes de secundaria)

**-19 pp**

de respuestas correctas con IA en una tarea fuera de lo que la IA hace bien (758 consultores)

**319**

profesionales: más confianza en la IA se asoció con menos pensamiento crítico; más confianza en sí mismos, con más

- No es un argumento contra la IA: con un tutor que daba pistas en vez de respuestas, el daño casi desapareció; y en tareas dentro de su alcance, la calidad subió más de 40 %.
- La diferencia la hace cómo se usa: para pensar mejor o para no pensar.

**Términos LLM:** modelo de lenguaje grande entrenado con texto (ChatGPT, Claude)

Fuente: Bastani et al. (2025); Dell'Acqua et al. (2023); Lee et al. (2025)

# En materiales: cuando la revisión crítica corrigió el entusiasmo

| Caso                                      | Lo que se anunció                                                              | Lo que encontró la revisión                                                                                                                                    |
|-------------------------------------------|--------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| GNoME (2023)                              | Millones de estructuras estables nuevas predichas con redes de grafos y DFT    | Cheetham y Seshadri: en 10 compuestos al azar, todos tenían estructura conocida en ICSD; muchos ordenamientos artificiales                                     |
| A-Lab (2023)                              | Laboratorio autónomo: 41 compuestos nuevos sintetizados en 17 días             | Leeman et al.: ningún material nuevo; cerca de dos tercios eran versiones desordenadas de compuestos conocidos; el análisis automático de XRD no era confiable |
| IA en un laboratorio de materiales (2024) | Preprint muy citado: más materiales y patentes gracias a una herramienta de IA | MIT (mayo 2025): sin confianza en la procedencia ni la validez de los datos; pidió retirarlo                                                                   |

**Idea clave** En los tres casos la corrección vino de personas que conocían los materiales y revisaron los datos con cuidado.

**Términos** **Desorden catiónico:** cationes distintos que ocupan los mismos sitios al azar • **Preprint:** artículo publicado antes de la revisión por pares

Fuente: Merchant et al. (2023); Cheetham y Seshadri (2024); Szymanski et al. (2023); Leeman et al. (2024); MIT (2025)

# Errores que hay que saber detectar (y un buen ejemplo)



## Referencias inventadas

En un estudio, GPT-3.5 inventó 55 % de las citas y GPT-4 18 %; muchas de las reales tenían errores. Cada referencia se verifica con su DOI.



## Fugas de datos

Se documentaron 294 artículos en 17 campos con resultados inflados porque la prueba se "filtró" al entrenamiento. Lo veremos el Día 2 con los polimorfos.




## Bien usada

Con datos de experimentos fallidos, un modelo predijo condiciones de síntesis con 89 % de éxito, mejor que la estrategia humana, y al invertirlo dio hipótesis que los químicos pusieron a prueba.


**Términos** **DOI:** identificador permanente de un artículo; permite verificar que existe • **Fuga de información:** datos de prueba que se cuelan en el entrenamiento e inflan las métricas • **Polimorfos:** misma fórmula, distinta estructura cristalina (diamante y grafito)

Fuente: Walters y Wilder (2023); Kapoor y Narayanan (2023); Raccuglia et al. (2016)

# Cómo vamos a usar la IA en este curso



- Vale para los modelos del curso y para los asistentes de IA (ChatGPT, Copilot, Claude u otros) si los usa para programar o redactar.
- Una buena señal: puede explicarle el resultado a un colega sin la herramienta abierta.




CONCEPTOS • 20 min

# Conceptos de ciencia de materiales

Cristal, propiedades, estabilidad y datos: lo mínimo para el resto del curso

# Un cristal es una red que se repite

- **Red de Bravais:** puntos que se repiten con tres vectores  $a$ ,  $b$ ,  $c$ .
- **Base:** los átomos que se colocan en cada punto de la red.
- **Celda unitaria:** el bloque mínimo que, repetido, llena el espacio. Se describe con 6 números:  $a$ ,  $b$ ,  $c$ ,  $\alpha$ ,  $\beta$ ,  $\gamma$ .
- **Coordenadas fraccionarias:** cada átomo se ubica como  $(x, y, z)$  entre 0 y 1 dentro de la celda.
- Con esos datos, pymatgen reconstruye el cristal completo (objeto Structure).



*Red de Bravais \* base = cristal (animada en PowerPoint: cambia la base sobre la misma red)*


**Términos** **Red de Bravais:** puntos que se repiten con tres vectores · **Celda:** en un cristal, la celda unitaria: bloque mínimo que se repite ( $a$ ,  $b$ ,  $c$ ,  $\alpha$ ,  $\beta$ ,  $\gamma$ ); en un notebook, un bloque de código · **Coordenadas fraccionarias:** posición de un átomo dentro de la celda, entre 0 y 1 · **pymatgen:** biblioteca de Python para estructuras cristalinas

Fuente: Animación: Berto, Wikimedia Commons, CCO; Callister y Rethwisch (2018); Kittel (2005)

# 7 sistemas cristalinos, 230 grupos espaciales

El número del grupo espacial dice a qué sistema pertenece; así clasificamos el dataset del Día 1

| Sistema      | Restricciones de la celda                                                 | Grupos espaciales | Ejemplo                                        |
|--------------|---------------------------------------------------------------------------|-------------------|------------------------------------------------|
| Triclínico   | $a \neq b \neq c$ ; $\alpha \neq \beta \neq \gamma$                       | 1 – 2             | $\text{CuSO}_4 \cdot 5\text{H}_2\text{O}$      |
| Monoclínico  | $\alpha = \gamma = 90^\circ \neq \beta$                                   | 3 – 15            | $\text{ZrO}_2$ (baddeleyita)                   |
| Ortorrómbico | $\alpha = \beta = \gamma = 90^\circ$ ; $a \neq b \neq c$                  | 16 – 74           | $\text{TiO}_2$ (brookita)                      |
| Tetragonal   | $a = b \neq c$ ; todos $90^\circ$                                         | 75 – 142          | $\text{TiO}_2$ (rutilo)                        |
| Trigonal     | $a = b = c$ ; $\alpha = \beta = \gamma \neq 90^\circ$ (o celda hexagonal) | 143 – 167         | $\alpha\text{-Al}_2\text{O}_3$                 |
| Hexagonal    | $a = b \neq c$ ; $\gamma = 120^\circ$                                     | 168 – 194         | $\text{ZnO}$ (wurtzita)                        |
| Cúbico       | $a = b = c$ ; todos $90^\circ$                                            | 195 – 230         | $\text{NaCl}$ , $\text{Si}$ , $\text{SrTiO}_3$ |



**Idea clave** Más simetría = menos parámetros libres. Un cúbico se describe con un solo número (a).

**Términos** **Sistema cristalino:** 7 familias según la forma de la celda (de triclínico a cúbico) · **Grupo espacial:** una de las 230 combinaciones de simetría de un cristal · **Wurtzita:** estructura hexagonal con coordinación tetraédrica, como  $\text{ZnO}$

Fuente: Imagen: Napy1kenobi, Wikimedia Commons, CC BY-SA 3.0

# Estados de oxidación y balance de carga

*El primer filtro químico para decidir si una fórmula tiene sentido*



## La regla

En un compuesto iónico, las cargas de cationes y aniones deben sumar cero.  
 $\text{Fe}_2\text{O}_3$ :  $2 \cdot (+3) + 3 \cdot (-2) = 0$ .



## Ejemplos que pasan

- $\text{SiO}_2$ :  $\text{Si}^{4+}$ ,  $\text{O}^{2-}$
- $\text{Si}_3\text{N}_4$ :  $\text{Si}^{4+}$ ,  $\text{N}^{3-}$
- $\text{LiMnO}_2$ :  $\text{Li}^+$ ,  $\text{Mn}^{3+}$ ,  $\text{O}^{2-}$



## Ejemplos que no

- $\text{SiN}$ :  $\text{Si}^{4+}$  no balancea con  $\text{N}^{3-}$
- $\text{LiO}_2$  sin considerar superóxido
- Intermetálicos: la regla no aplica

**Idea clave** SMACT automatiza esta revisión con los estados de oxidación conocidos de cada elemento (Día 3).

**Términos** **Estado de oxidación:** carga formal de un átomo en un compuesto ( $\text{Fe}^{3+}$ ,  $\text{O}^{2-}$ ) · **Enlace covalente, iónico y metálico:** electrones compartidos, transferidos o deslocalizados · **Catión y anión:** ion con carga positiva y con carga negativa · **SMACT:** filtro químico de balance de carga y electronegatividad

Fuente: Davies et al. (2019), SMACT

# Rigidez: módulo volumétrico K y de corte G



## K: módulo volumétrico (bulk)

- Resistencia a cambiar de volumen bajo presión uniforme.
- Unidades: GPa. Diamante  $\approx 440$  GPa; aluminio  $\approx 76$  GPa.



## G: módulo de corte (shear)

- Resistencia a cambiar de forma sin cambiar de volumen.
- Correlaciona mejor con la dureza que K.



## Promedio VRH

- DFT calcula el tensor elástico completo del monocristal (hasta 21 constantes independientes).
- Voigt y Reuss dan cotas superior e inferior para un policristal; Hill las promedia:  $K_{VRH}$ ,  $G_{VRH}$ .



## Relación de Pugh G/K


- $G/K > 0.57$  ( $K/G < 1.75$ ): tiende a frágil;  $G/K < 0.57$ : tiende a dúctil.
- Criterio empírico; útil para interpretar resultados del Día 1.

**Términos** **Módulo volumétrico K**: resistencia a cambiar de volumen bajo presión uniforme · **GPa**: gigapascal, unidad de presión y de módulo elástico · **Módulo de corte G**: resistencia a cambiar de forma sin cambiar de volumen · **Correlación**: qué tanto dos variables cambian juntas (de  $-1$  a  $1$ ); no implica causa · **Promedio VRH**: media de las cotas de Voigt (techo) y Reuss (piso) para un policristal · **Tensor elástico**: constantes que relacionan esfuerzo y deformación del cristal · **Monocristal y policristal**: un solo cristal continuo, o muchos granos orientados al azar · **Relación de Pugh**:  $G/K > 0.57$  sugiere frágil; menor, dúctil (regla empírica)


Fuente: Hill (1952); Pugh (1954); de Jong et al. (2015)

# VRH y Pugh con los datos del curso

Las 1181 entradas de elastic\_tensor\_2015



G de Reuss (piso) a Voigt (techo); rombo: promedio de Hill.  $A^u$ : anisotropía



G frente a K para todo el dataset; la recta separa frágil (arriba) de dúctil (abajo)

**Idea clave** Cristales casi isótropos (W, diamante): las cotas coinciden. Grafito, muy anisótropo: difieren en 180 GPa y el promedio dice poco.

**Términos** **Anisotropía:** propiedades distintas según la dirección; isótropo: iguales

Fuente: Datos: de Jong et al. (2015); Hill (1952); Pugh (1954)

# ¿Por qué la temperatura de fusión predice la rigidez?


- Ambas dependen de lo mismo: la fuerza y densidad de los enlaces.
- Un enlace fuerte cuesta más energía romperlo (fusión) y cuesta más deformarlo (módulo elástico).
- Por eso, en el Día 1, la temperatura de fusión promedio de los elementos aparece entre los descriptores más correlacionados con  $K_{VRH}$ .
- Otros descriptores con sentido físico: número de electrones de valencia, volumen atómico, electronegatividad.
  - Ninguno es causa directa: son aproximaciones (proxies) de la química del enlace.

**Idea clave** Un buen descriptor no es mágico: resume física que ya conocemos en un número que el modelo puede usar.

**Términos** **Electrones de valencia:** electrones de la capa externa, los que forman los enlaces • **Proxy:** variable que no es la causa pero refleja la misma física

# Band gap: la propiedad electrónica central

- **Metal:** no hay brecha; conduce siempre.
- **Semiconductor:** brecha pequeña ( $\approx 0.3\text{--}3\text{ eV}$ ); se controla con dopaje, luz o temperatura.
- **Aislante:** brecha grande; no conduce.
- Para celdas solares de una unión, el óptimo teórico está cerca de  $1.1\text{--}1.4\text{ eV}$  (límite de Shockley–Queisser). Por eso el Día 3 pedimos gaps de  $\sim 1.5\text{ eV}$ .
- **Ojo:** el DFT estándar (PBE) subestima los gaps; los datos experimentales son pocos y valiosos.





Llenado de bandas: metal, semimetal, semiconductor ( $p$ , intrínseco,  $n$ ) y aislante

**Términos** **Semiconductor:** material con gap pequeño, cuya conducción se controla • **Dopaje:** impurezas que agregan electrones ( $n$ ) o huecos ( $p$ ) • **Shockley-Queisser:** eficiencia máxima teórica de una celda solar de una unión • **Semimetal:** las bandas apenas se tocan o se superponen un poco

Fuente: Imagen: Nanite, Wikimedia Commons, CCO; Shockley y Queisser (1961); Zhuo et al. (2018)

# Termoeléctricos: convertir calor en electricidad

- **Figura de mérito:**  $ZT = S^2\sigma T / \kappa$ 
  - S: coeficiente Seebeck ( $\mu\text{V/K}$ ), voltaje por grado de diferencia.
  - $\sigma$ : conductividad eléctrica;  $\kappa$ : conductividad térmica; T: temperatura.
- Queremos conducir electricidad pero no calor: un conflicto difícil, porque los electrones también transportan calor.
- S y  $\sigma$  se oponen al variar la concentración de portadores, así que el factor de potencia  $S^2\sigma$  tiene un óptimo.
- $ZT \approx 1$  ya es un buen material comercial.




Izq.: un par n-p entre la fuente caliente y el lado frío. Der.: el compromiso entre S,  $\sigma$  y  $S^2\sigma$

**Términos** **Termoeléctrico:** convierte una diferencia de temperatura en electricidad · **ZT:** figura de mérito termoeléctrica  $S^2\sigma T/\kappa$  · **Efecto Seebeck:** una diferencia de temperatura produce un voltaje ( $S = \Delta V/\Delta T$ ) · **Conductividad:** qué tan bien conduce un material la electricidad ( $\sigma$ ) o el calor ( $\kappa$ ) · **Portadores de carga:** electrones o huecos que conducen la corriente · **Factor de potencia:**  $S^2\sigma$ ; tiene un óptimo según la concentración de portadores

Fuente: Diagrama: Ken Brazier, Wikimedia Commons, CC BY-SA 4.0; gráfico propio; Snyder y Toberer (2008); He y Tritt (2017)

# Energía de formación y distancia al casco convexo

- **$E_f$** : energía del compuesto menos la de sus elementos puros (eV/átomo). Negativa = favorable frente a los elementos.
- **Casco convexo**: la envolvente inferior de todas las fases conocidas de un sistema químico.
- **$E_{\text{above\_hull}}$** : cuánto está un compuesto por encima del casco. 0 = estable;  $> 0$  = se descompondría en fases vecinas.
- Muchos materiales útiles son metaestables ( $E_{\text{hull}}$  pequeño pero positivo).



**Idea clave**  $E_f$  negativa no basta: hay que competir contra todas las demás fases del sistema.

**Términos** **Energía de formación**: energía del compuesto menos la de sus elementos, por átomo · **Casco convexo y  $E_{\text{hull}}$** : fases más estables de un sistema;  $E_{\text{hull}}$  = distancia a ellas (0 = estable) · **Metaestable**: por encima del casco pero existe porque la cinética lo protege

Fuente: Sun et al. (2016); Bartel (2022)

# DFT en una lámina



## Qué es

Teoría del funcional de la densidad: resuelve la mecánica cuántica de los electrones usando su densidad en vez de la función de onda completa (Hohenberg-Kohn 1964; Kohn-Sham 1965).



## Qué calcula

- Energía total → estabilidad,  $E_f$ ,  $E_{hull}$
- Tensor elástico → K, G
- Bandas → band gap



## Cuánto cuesta

De minutos a días por material en un clúster como Kabré. Un modelo de ML entrenado predice en milisegundos.



## Errores típicos

- Gaps subestimados con PBE
- Materiales magnéticos y correlacionados
- Sin temperatura ni defectos por defecto

**Términos** **Magnetismo:** orden de los momentos magnéticos de los átomos

Fuente: Hohenberg y Kohn (1964); Kohn y Sham (1965)

# Recubrimientos (Ti,Al)N por deposición física de vapor

- **El proceso:** se evapora o pulveriza un blanco metálico (Ti, Al) en atmósfera de  $N_2$  y se deposita una película de pocos micrómetros sobre herramientas de corte.
- **Variables que controlamos:** temperatura del sustrato, presión parcial de  $N_2$ , voltaje de polarización (bias), relación Ti/Al, potencia.
- **Lo que medimos:** dureza Vickers (HV), coeficiente de fricción (CoF), adhesión, tasa de deposición.
- **Por qué optimizar:** cada corrida cuesta horas de equipo y material. Elegir bien el siguiente experimento es el problema del Día 4.



*Fresas con recubrimiento AlTiN depositado por PVD*

**Términos** **PVD:** deposición física de vapor: se pulveriza un blanco y se deposita una película · **Película delgada:** capa de nanómetros a micrómetros depositada sobre un sustrato · **Sustrato:** pieza sobre la que se deposita la película · **Bias:** voltaje aplicado al sustrato que controla la energía de los iones · **Dureza Vickers (HV):** dureza medida con un indentador piramidal de diamante · **Coeficiente de fricción (CoF):** fuerza de fricción entre fuerza normal

Fuente: Foto: Sunyataburus, Wikimedia Commons, CC BY-SA 3.0; PalDey y Deevi (2003)




T1.5 • 25 min

## Feature engineering: representar un material

Un algoritmo no puede leer " $\text{Fe}_2\text{O}_3$ ": necesita números

# Niveles de representación de un material



- Más información = más poder predictivo, pero también más datos necesarios y más costo.
- La composición es la opción más barata y funciona sorprendentemente bien para muchas propiedades.

**Términos** **Magpie**: 132 descriptores de composición: 22 propiedades  $\times$  6 estadísticas · **Coordinación**: número de vecinos inmediatos de un átomo · **CGCNN**: red de grafos que predice propiedades desde la estructura

Fuente: Ward et al. (2016); Xie y Grossman (2018)

# Descriptores Magpie: 22 propiedades × 6 estadísticas = 132 números



## Propiedades elementales

- Electronegatividad, radio covalente, masa atómica
- Temperatura de fusión, electrones de valencia s, p, d, f
- Volumen atómico (GSvolume\_pa), grupo y periodo, entre otras



## Estadísticas sobre la composición

- Media ponderada por fracción atómica
- Mínimo, máximo, rango
- Desviación media absoluta y moda

**Idea clave** El mismo vector de 132 números sirve para cualquier composición: es la entrada del modelo del Día 2.

Fuente: Ward et al. (2016)

# Ejemplo a mano: electronegatividad media de Fe<sub>2</sub>O<sub>3</sub>

Así calcula matminer cada una de las 132 columnas

| Elemento | Fracción atómica | Electronegatividad (Pauling) | Contribución               |
|----------|------------------|------------------------------|----------------------------|
| Fe       | $2/5 = 0.40$     | 1.83                         | $0.40 \times 1.83 = 0.732$ |
| O        | $3/5 = 0.60$     | 3.44                         | $0.60 \times 3.44 = 2.064$ |
| Media    |                  |                              | 2.796                      |
| Rango    |                  |                              | $3.44 - 1.83 = 1.61$       |

**Idea clave** Nada de magia: son promedios y diferencias de propiedades tabuladas.

Términos **matminer**: biblioteca de Python con datasets y descriptores de materiales · **Fracción atómica**: átomos de un elemento entre el total (Fe en Fe<sub>2</sub>O<sub>3</sub>: 2/5)

# Dos materiales, dos vectores


*Cinco de las 132 columnas Magpie, calculadas con matminer*

| Descriptor                               | WC   | NaCl | Qué sugiere                        |
|------------------------------------------|------|------|------------------------------------|
| Electronegatividad media                 | 2.46 | 2.05 | Parecidas: no distingue mucho      |
| Rango de electronegatividad              | 0.19 | 2.23 | WC covalente/metálico, NaCl iónico |
| Temperatura de fusión media (K)          | 3759 | 271  | Enlaces mucho más fuertes en WC    |
| Electrones d sin llenar (media)          | 3.0  | 0.0  | Enlace d direccional en WC         |
| Volumen atómico medio ( $\text{\AA}^3$ ) | 10.8 | 26.9 | WC mucho más compacto              |
| K_VRH en el dataset (GPa)                | 385  | 23   | Lo que el modelo debe aprender     |

**Idea clave** El modelo nunca ve "WC" ni "NaCl": ve estos números y aprende qué combinaciones acompañan a un K alto.

# ¿Qué descriptores "ven" la física?

- Correlación de cada descriptor con K\_VRH en el dataset del curso (1181 materiales).
- Arriba: temperatura de fusión media (0.78). Tiene sentido: ambas dependen de la fuerza del enlace.
- Luego: volumen atómico y electrones d sin llenar.
- **Cuidado:** correlación no es causa, y muchos descriptores están correlacionados entre sí.





Fuente: Cálculo propio con *elastic\_tensor\_2015* y *Magpie*


# Descriptores de estructura

*Densidad, empaquetamiento, coordinación y simetría: lo que la composición no ve*

**NaCl (roca salina, cúbico Fm-3m)    SrTiO<sub>3</sub> (perovskita, cúbico Pm-3m)**



**ZnO (wurtzita, hexagonal P6<sub>3</sub>mc)**




**Idea clave** En matminer: DensityFeatures, GlobalSymmetryFeatures y otros. En el notebook los calculamos con pymatgen.

Fuente: Ward et al. (2018)

# La limitación de la composición

- Magpie no sabe nada de la estructura: todos los polimorfos reciben el mismo vector.
- En el dataset, las 5 entradas de carbono van de 117 a 436 GPa y el modelo las verá idénticas.
- 174 de 1181 materiales comparten fórmula con otro.
- Soluciones: descriptores estructurales (densidad, coordinación) o grafos cristalinos (Día 3).



**Idea clave** Elegir la representación es una decisión científica, no un detalle técnico.



## PREGUNTA PARA EL GRUPO

**Si dos polimorfos del carbono quedan uno en entrenamiento y otro en prueba, ¿qué le pasa a la evaluación del modelo?**

**A**

Nada: son materiales distintos

**B**

Parece mejor de lo que es: el modelo ya "vio" ese vector

**C**

Parece peor de lo que es

*Respondan en el chat · 1 minuto*



T1.6 • 10 min

# Ecosistema de herramientas

Todo es abierto y gratuito

# Las bibliotecas del curso

| Biblioteca          | Para qué                                                       | Día   |
|---------------------|----------------------------------------------------------------|-------|
| pymatgen            | Estructuras cristalinas, composición, simetría, lectura de CIF | 1–3   |
| matminer            | Datasets curados y 70+ tipos de descriptores                   | 1, 2  |
| pandas / matplotlib | Tablas de datos y figuras                                      | todos |
| scikit-learn, shap  | Modelos clásicos (Random Forest, GP) e interpretabilidad       | 2, 5  |
| mp-api              | Consultas a Materials Project                                  | 2     |
| MatterGen, smact    | Generación de cristales y filtro químico                       | 3     |
| pyDOE3, botorch     | Diseño de experimentos y optimización bayesiana                | 4, 5  |

**Idea clave** En Kabré todo esto ya está instalado en el kernel Python-AI-Materials.

**Términos** **CIF**: formato de archivo estándar para estructuras cristalinas · **pandas**: biblioteca de Python para tablas de datos · **matplotlib**: biblioteca de Python para gráficos · **scikit-learn**: biblioteca de Python de modelos clásicos de ML · **Proceso gaussiano (GP)**: modelo que da una predicción y su incertidumbre en cada punto · **pyDOE3**: biblioteca de Python para diseños de experimentos · **BoTorch**: biblioteca de optimización bayesiana sobre PyTorch

Fuente: Ong et al. (2013); Ward et al. (2018); Balandat et al. (2020)

# Cómo se conectan las piezas



- Casi todo el código del curso es este flujo con variaciones.

# Cómo leer un notebook del curso



## Celdas en orden

Ejecute de arriba hacia abajo (Shift + Enter). Si reinicia el kernel, vuelva a empezar desde arriba.



## "Cómo funciona"

Recuadros azules que explican las líneas menos obvias. Léalos antes de modificar el código.



## Retos

Recuadros naranja con una celda vacía: ahí escribe usted. No hay una única respuesta.



## Banderas

USAR\_PLOTLY y USAR\_NGLVIEW en la primera celda ya vienen en True. Si un visor no aparece, recargue la página (F5) una vez.



T2.3 • 20 min

# Bases de datos computacionales

Materials Project y sus parientes



## PREGUNTA PARA EL GRUPO

# ¿Por qué no entrenamos los modelos solo con datos experimentales?

**A** Porque para la mayoría de propiedades hay muy pocos

**B** Porque vienen de laboratorios, muestras y condiciones distintas

**C** Las dos cosas

*Respondan en el chat · 1 minuto*

# Cómo se construye una base de datos de alto rendimiento




- La fortaleza no es la precisión de cada cálculo sino la consistencia: todos los materiales se tratan igual.

**Términos** **Alto rendimiento:** calcular o medir miles de materiales con un flujo automatizado • **Relajación:** mover átomos y celda hasta que las fuerzas sean casi cero • **API:** interfaz para consultar una base de datos desde un programa

Fuente: Jain et al. (2013); Curtarolo et al. (2013)

# Materials Project en una lámina

- **Qué es:** base de datos abierta con más de 150 000 materiales inorgánicos calculados con DFT de forma sistemática.
- **Qué trae:** energía de formación y  $E_{\text{above\_hull}}$ , band gap y estructura de bandas, tensores elásticos, piezoeléctricos y dieléctricos, estructura relajada (CIF).
- **Cómo se usa:** con una cuenta gratuita y una API key, desde Python con mp-api (MPRester).



La ficha de un material en el sitio de Materials Project

Fuente: Captura de Materials Project, vía Wikimedia Commons, CC BY 4.0; Jain et al. (2013)

# Tres advertencias sobre los datos calculados



## Gaps subestimados

El funcional PBE subestima los band gaps de forma sistemática. Ejemplo clásico: Si da unos 0.6 eV frente a 1.1 eV medido.



## Cero kelvin

Sin temperatura ni entropía: una fase estable a 0 K puede no serlo a 800 °C, y al revés.



## La base cambia

Correcciones y recálculos cambian valores entre versiones. Registre la fecha o versión de lo que descargó.

**Idea clave** Son cálculos, no mediciones: excelentes para ordenar candidatos, no para dar el número final.

Términos **Entropía**: medida del desorden; pesa en la estabilidad a temperatura finita

# El sesgo humano también está en los datos

*Síntesis hidrotermal de óxidos con aminas: lo que se publicó frente a lo que se probó al azar*

**17 % → 79 %**

17 % de las aminas aparece en 79 % de los compuestos reportados: se repite lo popular

**548**

experimentos con reactivos y condiciones elegidos al azar

**Al azar gana**

el modelo entrenado con esos pocos experimentos aleatorios predijo mejor que el entrenado con muchos más datos "humanos"

- Los reactivos populares no rindieron mejor que los demás: su popularidad venía de la costumbre, no de la química.
- Las bases calculadas tienen el mismo problema: Materials Project contiene lo que alguien decidió calcular.

**Idea clave** Más datos no siempre es mejor: importa cómo se eligieron.

Fuente: Jia et al. (2019)



## PREGUNTA PARA EL GRUPO

**Su laboratorio tiene 300 síntesis exitosas registradas en 10 años. ¿Qué le falta a ese conjunto para entrenar un modelo útil?**

**A** Nada: 300 datos es suficiente

**B** Los intentos fallidos y las condiciones que nadie probó

**C** Más cifras decimales en las mediciones

*Respondan en el chat · 1 minuto*

# Anatomía de una consulta a Materials Project

```
from mp_api.client import MPRester

with MPRester(API_KEY) as mpr:
    docs = mpr.materials.summary.search(
        band_gap=(0.3, 2.5),      # filtro por rango
        is_stable=True,          # solo sobre el casco
        fields=["material_id", "formula_pretty",
                "band_gap", "energy_above_hull",
                "symmetry", "nsites"],
    )

df_mp = pd.DataFrame({"formula": d.formula_pretty,
                      "band_gap": d.band_gap}
                      for d in docs)
df_mp.to_json("datos/mp_bandgap_cache.json")
```

- **with ... as mpr:** abre y cierra la conexión automáticamente.
- **Filtros:** rangos como tuplas (min, max); booleanos como is\_stable.
- **fields:** pide solo lo que necesita; la consulta es mucho más rápida.
- **Caché:** en clase leemos un JSON ya descargado para no depender de la red ni de la API key.

Términos **DataFrame**: tabla de pandas: filas = materiales, columnas = variables · **JSON**: formato de texto para guardar datos estructurados



## PREGUNTA PARA EL GRUPO

**La consulta anterior pide band\_gap entre 0.3 y 2.5 eV e is\_stable=True. ¿Qué materiales NO van a aparecer?**

- A** Metales como WC o TiN (gap cero)
- B** Aislantes como SiO<sub>2</sub> o el diamante (gap grande)
- C** Fases metaestables, aunque se puedan sintetizar
- D** Todos los anteriores

*Respondan en el chat · 1 minuto*

# Otras fuentes y los benchmarks



## OQMD, AFLOW

Otras bases DFT de alto rendimiento con millones de cálculos; útiles para cruzar datos.



## Matbench

13 tareas estándar (módulos, gaps, estabilidad...) para comparar modelos de forma justa.




## Datos experimentales

matbench\_expt\_gap y colecciones propias. Menos datos, pero miden la realidad.

**Idea clave** Antes de entrenar un modelo propio, compare contra un benchmark: le dice si su resultado es bueno.

**Términos Benchmark:** tarea de referencia para comparar modelos en las mismas condiciones · **OQMD y AFLOW:** otras bases de cálculos DFT de alto rendimiento

Fuente: Curtarolo et al. (2013); Dunn et al. (2020); Zhuo et al. (2018)



T2.4 • 30 min

# Diseño inverso

De "¿qué propiedad tiene este material?" a "¿qué material tiene esta propiedad?"



## PREGUNTA PARA EL GRUPO

**Un cliente quiere un material más rígido que el carburo de tungsteno (WC). ¿Por dónde empiezan?**

**A**

Busco en Materials Project los de mayor módulo

**B**

Pruebo combinaciones en el laboratorio


**C**

Entreno un modelo y evalúo miles de fórmulas en minutos

*Respondan en el chat · 1 minuto*

# Dirección directa vs dirección inversa

- **Directa:** de un material a sus propiedades, con DFT, experimento o un modelo de ML. Fácil de evaluar, pero hay que saber qué material probar.
- **Inversa:** de las propiedades deseadas a materiales candidatos. Hay muchísimos posibles y pocos cumplen; es la pregunta que interesa al laboratorio y a la industria.
- En la figura: procesamiento, estructura, propiedades y desempeño. La ciencia recorre la cadena hacia la derecha (causa y efecto); el diseño la recorre de regreso.




**Idea clave** Casi todo el diseño inverso práctico se construye encima de un buen modelo directo.

Fuente: Fig. 2 de Agrawal y Choudhary (2016), APL Mater. 4, 053208, doi:10.1063/1.4946894, CC BY 4.0; Zunger (2018)

# El espacio químico es enorme

- Con 80 elementos útiles hay 3 160 pares, 82 160 tríos, 1.6 millones de combinaciones de cuatro y 24 millones de cinco.
- Y eso antes de elegir proporciones y estructura cristalina.
- Materials Project, con todo su tamaño, cubre una fracción mínima.



**Idea clave** No se puede calcular ni medir todo: hace falta una forma barata de decidir qué vale la pena probar.

# Tres estrategias de diseño inverso



## Screening (notebook 02)

- Enumerar candidatos
- Predecir con el modelo
- Filtrar los mejores
- Simple y transparente; solo explora lo que enumeramos



## Generación (Día 3)

- Un modelo generativo propone estructuras nuevas
- Puede condicionarse a propiedades
- Explora fuera de lo conocido



## Optimización (Día 4)

- Buscar iterativamente el óptimo con pocas evaluaciones
- Ideal cuando cada evaluación es cara (experimentos)

**Términos** **Modelo generativo:** aprende cómo son los ejemplos reales y produce otros nuevos parecidos

Fuente: Sanchez-Lengeling y Aspuru-Guzik (2018); Zunger (2018)

# El embudo de screening del notebook 02




- El modelo redescubre los carburos duros conocidos: es la validación del método.
- Los candidatos que no conocemos son hipótesis para verificar con DFT o experimento, no descubrimientos.

Términos **Estequiometría**: proporción de los elementos en la fórmula · **Escalado**: llevar cada descriptor a media 0 y desviación 1 (StandardScaler)

# Qué dice el modelo sobre las 270 fórmulas

- Los carburos (naranja) dominan la cola de alta rigidez; los siguen los boruros de W.
- Óxidos, siliciuros y aluminuros quedan abajo.
- 5 de los 13 candidatos con  $K > 300$  GPa ya están en el conjunto de entrenamiento.
- Ninguna predicción pasa de 331 GPa: un Random Forest promedia lo que vio y no extrapola por encima.





## PREGUNTA PARA EL GRUPO

**WC sale en el top del screening y no aparece en el caché de Materials Project del curso. ¿Es un descubrimiento?**

**A** Sí: el modelo lo encontró y no está en la base

**B** No: WC se conoce desde hace más de un siglo

**C** Depende de contra qué base comparé

*Respondan en el chat · 1 minuto*

# Validar con honestidad: ¿qué es "nuevo"?



## Comparar contra lo conocido

- Contra el propio dataset de entrenamiento (WC y TaC están ahí)
- Contra toda la base de Materials Project, no contra un subconjunto filtrado



## La trampa del caché filtrado

- Si comparamos contra una consulta de gaps entre 0.3 y 2.5 eV, ningún carburo metálico aparece
- Resultado falso: WC marcado como "nuevo"

**Idea clave** Un chequeo de novedad solo vale lo que vale la base contra la que compara.

Términos **Novedad**: que un compuesto no exista ya en las bases de referencia

# ¿Qué tan confiable es una predicción?



## Dominio de aplicabilidad

Un candidato muy distinto de todo lo visto en el entrenamiento tiene una predicción poco confiable, aunque el número sea atractivo.



## Techo del modelo

Los árboles promedian valores de entrenamiento: no pueden predecir algo más rígido que lo más rígido que vieron.



## El veredicto final

DFT para confirmar estabilidad y propiedad; después síntesis y medición.

**Términos** **Dominio de aplicabilidad:** región de datos parecida al entrenamiento, donde la predicción es confiable · **Árbol de decisión:** modelo que divide los datos con preguntas del tipo  $\{x > \text{umbral}\}$

Fuente: Mansouri Tehrani et al. (2018)

# Un caso real: materiales superduros guiados por ML

- Mansouri Tehrani y colaboradores entrenaron un modelo con módulos elásticos calculados (el mismo tipo de dato que usamos en el curso).
- Hicieron screening de miles de composiciones en busca de materiales ultraincompresibles y superduros.
- Sintetizaron candidatos propuestos por el modelo y midieron sus propiedades mecánicas.
- Es exactamente el flujo del notebook 02 de mañana, llevado hasta el laboratorio.

**Idea clave** El valor del ML aquí no fue predecir perfecto: fue reducir miles de opciones a unas pocas síntesis.

*Fuente: Mansouri Tehrani et al. (2018)*



## PREGUNTA PARA EL GRUPO

**Tienen 13 candidatos con  $K > 300$  GPa ( $W_2C$ ,  $MoC$ ,  $W_3C_2$ ,  $W_3C$ ,  $WC$ ,  $BW$ ,  $B_2W_3$ ,  $Mo_3C_2$ ,  $BW_2$ ,  $BW_3$ ,  $Cr_3C_2$ ,  $TaC$ ,  $CrC$ ) y presupuesto para 3 síntesis. ¿Con qué criterio eligen?**

*Discusión en voz alta · 2 minutos*



T2.5 • 20 min

# Interpretabilidad del modelo

Qué aprendió, y qué no podemos concluir de eso

# Tres formas de preguntarle al modelo qué aprendió



## Importancia por impureza

La que trae el Random Forest: rápida, pero sesgada a favor de variables con muchos valores distintos.



## Importancia por permutación

Se desordena una variable en los datos de prueba y se mide cuánto empeora el modelo. Más confiable.



## SHAP

Reparte cada predicción entre las variables: explica un material a la vez (waterfall) y el conjunto (beeswarm).


**Idea clave** Las tres responden "qué usó el modelo", no "qué causa la propiedad".

**Términos** **Importancia por impureza:** cuánto reduce el error un descriptor en los cortes de los árboles • **Importancia por permutación:** cuánto empeora el modelo al desordenar un descriptor • **Beeswarm y waterfall:** gráficos SHAP de todos los materiales (enjambre) o de uno solo (cascada)

Fuente: Breiman (2001); Strobl et al. (2007); Lundberg y Lee (2017)

# Cómo se lee un gráfico SHAP (beeswarm)

- **Cada punto** es una muestra; cada fila, una variable, ordenadas de más a menos influyente.
- **Posición horizontal:** cuánto empujó esa variable la predicción hacia arriba o hacia abajo.
- **Color:** el valor de la variable (rojo alto, azul bajo).
- Aquí: precio de viviendas en California; el ingreso medio (MedInc) domina. Mañana lo hacen con el módulo volumétrico.



Fuente: Imagen del repositorio de SHAP (Lundberg y Lee, [github.com/shap/shap](https://github.com/shap/shap)), licencia MIT

# Cuidado al leer una explicación



## Descriptores correlacionados

Si dos variables dicen casi lo mismo (radio medio y volumen atómico), el crédito se reparte entre ellas o se lo lleva una al azar.



## Contraste con la física

Un ranking que coincide con la intuición (fuerza de enlace, temperatura de fusión) da confianza; uno que no, pide revisar los datos.



## No es causalidad

El modelo explica sus predicciones, no el material. Para afirmar una causa hace falta un experimento o un cálculo dirigido.

Fuente: Strobl et al. (2007); Lundberg y Lee (2017)



## PREGUNTA PARA EL GRUPO

**SHAP dice que la temperatura de fusión media es el descriptor que más pesa al predecir  $K_{VRH}$ . ¿Qué podemos concluir?**

- A** Que subir el punto de fusión aumenta el módulo
- B** Que ambas dependen de algo común, como la fuerza del enlace; el modelo lo aprovecha
- C** Que el modelo está mal: el punto de fusión no tiene nada que ver

*Respondan en el chat · 1 minuto*



DEMO • 25 min

# El notebook 01 en vivo

Lo que harán ustedes mañana en Kabré: cargar datos, ver estructuras y calcular descriptores



Centro Nacional de Alta Tecnología

# El dataset del día: elastic\_tensor\_2015



## Qué es

Propiedades elásticas calculadas con DFT para 1181 cristales inorgánicos (Materials Project).



## Columnas clave

- formula, structure (objetos)
- K\_VRH, G\_VRH (GPa)
- elastic\_anisotropy, poisson\_ratio
- space\_group (número 1-230)



## Lo que verán

- 452 cúbicos, 239 hexagonales, 193 ortorrómbicos, 193 tetragonales
- Ningún triclinico
- K y G muy correlacionados

Fuente: de Jong et al. (2015)

# Tarea para mañana



## Activar su cuenta

- Siga el correo del CNCA
- Configure el doble factor (código QR)
- Entre a `ondemand.kabre.cenat.ac.cr`



## Probar el entorno

- Jupyter en la cola kura, 2 núcleos, 4 GB
- Abra y corra el notebook `00_test_entorno`
- Debe terminar en "ENTORNO LISTO"



## Repasar

- El anexo de Python mínimo (presentación 00)
- Si quiere más detalle: la presentación 00 completa
- Unos 20 minutos

**Idea clave** Mañana empezamos directo en Kabré: si algo falla hoy, repórtelo en el canal de soporte del curso.

# Referencias (1/8)

- [1] Agrawal, A., Choudhary, A. (2016). **Perspective: Materials informatics and big data: Realization of the "fourth paradigm" of science in materials science.** *APL Mater.* 4, 053208. doi:10.1063/1.4946894
- [2] Butler, K. T., Davies, D. W., Cartwright, H., Isayev, O., Walsh, A. (2018). **Machine learning for molecular and materials science.** *Nature* 559, 547–555. doi:10.1038/s41586-018-0337-2
- [3] Schmidt, J., Marques, M. R. G., Botti, S., Marques, M. A. L. (2019). **Recent advances and applications of machine learning in solid-state materials science.** *npj Comput. Mater.* 5, 83. doi:10.1038/s41524-019-0221-0
- [4] Jain, A., Ong, S. P., Hautier, G., et al. (2013). **The Materials Project: A materials genome approach to accelerating materials innovation.** *APL Materials* 1, 011002. doi:10.1063/1.4812323
- [5] Mansouri Tehrani, A., Oliynyk, A. O., et al. (2018). **Machine learning directed search for ultraincompressible, superhard materials.** *J. Am. Chem. Soc.* 140, 9844–9853. doi:10.1021/jacs.8b02717
- [6] Merchant, A., Batzner, S., Schoenholz, S. S., et al. (2023). **Scaling deep learning for materials discovery.** *Nature* 624, 80–85. doi:10.1038/s41586-023-06735-9

## Referencias (2/8)

- [7] Zeni, C., Pinsler, R., Zügner, D., et al. (2025). **A generative model for inorganic materials design.** *Nature* 639, 624–632. doi:10.1038/s41586-025-08628-5
- [8] Szymanski, N. J., Rendy, B., Fei, Y., et al. (2023). **An autonomous laboratory for the accelerated synthesis of novel materials.** *Nature* 624, 86–91. doi:10.1038/s41586-023-06734-w
- [9] Raccuglia, P., Elbert, K. C., Adler, P. D. F., et al. (2016). **Machine-learning-assisted materials discovery using failed experiments.** *Nature* 533, 73–76. doi:10.1038/nature17439
- [10] Ward, L., Agrawal, A., Choudhary, A., Wolverton, C. (2016). **A general-purpose machine learning framework for predicting properties of inorganic materials.** *npj Comput. Mater.* 2, 16028. doi:10.1038/npjcompumats.2016.28
- [11] Ward, L., Dunn, A., Faghaninia, A., et al. (2018). **Matminer: An open source toolkit for materials data mining.** *Comput. Mater. Sci.* 152, 60–69. doi:10.1016/j.commatsci.2018.05.018
- [12] Xie, T., Grossman, J. C. (2018). **Crystal graph convolutional neural networks for an accurate and interpretable prediction of material properties.** *Phys. Rev. Lett.* 120, 145301. doi:10.1103/PhysRevLett.120.145301

# Referencias (3/8)

- [13] de Jong, M., Chen, W., et al. (2015). **Charting the complete elastic properties of inorganic crystalline compounds.** *Scientific Data* 2, 150009. doi:10.1038/sdata.2015.9
- [14] Ong, S. P., Richards, W. D., Jain, A., et al. (2013). **Python Materials Genomics (pymatgen): A robust, open-source python library for materials analysis.** *Comput. Mater. Sci.* 68, 314–319. doi:10.1016/j.commatsci.2012.10.028
- [15] Balandat, M., Karrer, B., Jiang, D. R., et al. (2020). **BoTorch: A framework for efficient Monte-Carlo Bayesian optimization.** *NeurIPS* 33. arXiv:1910.06403
- [16] Messeri, L., Crockett, M. J. (2024). **Artificial intelligence and illusions of understanding in scientific research.** *Nature* 627, 49–58. doi:10.1038/s41586-024-07146-0
- [17] Bastani, H., Bastani, O., Sungu, A., et al. (2025). **Generative AI without guardrails can harm learning: Evidence from high school mathematics.** *Proc. Natl. Acad. Sci. USA* 122, e2422633122. doi:10.1073/pnas.2422633122
- [18] Dell'Acqua, F., McFowland III, E., Mollick, E. R., et al. (2023). **Navigating the jagged technological frontier: Field experimental evidence of the effects of AI on knowledge worker productivity and quality.** *Harvard Business School Working Paper* 24-013. doi:10.2139/ssrn.4573321

# Referencias (4/8)

- [19] Lee, H.-P., Sarkar, A., Tankelevitch, L., et al. (2025). **The impact of generative AI on critical thinking: Self-reported reductions in cognitive effort and confidence effects from a survey of knowledge workers.** *Proc. CHI 2025, ACM*, 1–22. doi:10.1145/3706598.3713778
- [20] Walters, W. H., Wilder, E. I. (2023). **Fabrication and errors in the bibliographic citations generated by ChatGPT.** *Sci. Rep.* 13, 14045. doi:10.1038/s41598-023-41032-5
- [21] Kapoor, S., Narayanan, A. (2023). **Leakage and the reproducibility crisis in machine-learning-based science.** *Patterns* 4, 100804. doi:10.1016/j.patter.2023.100804
- [22] Cheetham, A. K., Seshadri, R. (2024). **Artificial intelligence driving materials discovery? Perspective on the article: Scaling deep learning for materials discovery.** *Chem. Mater.* 36, 3490–3495. doi:10.1021/acs.chemmater.4c00643
- [23] Leeman, J., Liu, Y., Stiles, J., et al. (2024). **Challenges in high-throughput inorganic materials prediction and autonomous synthesis.** *PRX Energy* 3, 011002. doi:10.1103/PRXEnergy.3.011002
- [24] MIT Department of Economics (2025). **Assuring an accurate research record (comunicado del 16 de mayo de 2025).** [economics.mit.edu/news/assuring-accurate-research-record](https://economics.mit.edu/news/assuring-accurate-research-record)

# Referencias (5/8)

- [25] Curtarolo, S., Hart, G. L. W., et al. (2013). **The high-throughput highway to computational materials design.** *Nature Materials* 12, 191–201. doi:10.1038/nmat3568
- [26] Sun, W., Dacek, S. T., Ong, S. P., et al. (2016). **The thermodynamic scale of inorganic crystalline metastability.** *Science Advances* 2, e1600225. doi:10.1126/sciadv.1600225
- [27] Dunn, A., Wang, Q., Ganose, A., Dopp, D., Jain, A. (2020). **Benchmarking materials property prediction methods: the Matbench test set and Automatminer reference algorithm.** *npj Comput. Mater.* 6, 138. doi:10.1038/s41524-020-00406-3
- [28] Zhuo, Y., Mansouri Tehrani, A., Brgoch, J. (2018). **Predicting the band gaps of inorganic solids by machine learning.** *J. Phys. Chem. Lett.* 9, 1668–1673. doi:10.1021/acs.jpclett.8b00124
- [29] Zunger, A. (2018). **Inverse design in search of materials with target functionalities.** *Nat. Rev. Chem.* 2, 0121. doi:10.1038/s41570-018-0121
- [30] Sanchez-Lengeling, B., Aspuru-Guzik, A. (2018). **Inverse molecular design using machine learning: Generative models for matter engineering.** *Science* 361, 360–365. doi:10.1126/science.aat2663

# Referencias (6/8)

- [31] Breiman, L. (2001). **Random forests**. *Machine Learning* 45, 5–32. doi:10.1023/A:1010933404324
- [32] Strobl, C., Boulesteix, A.-L., Zeileis, A., Hothorn, T. (2007). **Bias in random forest variable importance measures: Illustrations, sources and a solution**. *BMC Bioinformatics* 8, 25. doi:10.1186/1471-2105-8-25
- [33] Lundberg, S. M., Lee, S.-I. (2017). **A unified approach to interpreting model predictions**. *NeurIPS* 30. arXiv:1705.07874
- [34] Jia, X., Lynch, A., Huang, Y., et al. (2019). **Anthropogenic biases in chemical reaction data hinder exploratory inorganic synthesis**. *Nature* 573, 251–255. doi:10.1038/s41586-019-1540-5
- [35] Callister, W. D., Rethwisch, D. G. (2018). **Materials Science and Engineering: An Introduction (10.<sup>a</sup> ed.)**. Wiley
- [36] Kittel, C. (2005). **Introduction to Solid State Physics (8.<sup>a</sup> ed.)**. Wiley

# Referencias (7/8)

- [37] Hill, R. (1952). **The elastic behaviour of a crystalline aggregate.** *Proc. Phys. Soc. A* 65, 349–354. doi:10.1088/0370-1298/65/5/307
- [38] Pugh, S. F. (1954). **Relations between the elastic moduli and the plastic properties of polycrystalline pure metals.** *Phil. Mag.* 45, 823–843. doi:10.1080/14786440808520496
- [39] Hohenberg, P., Kohn, W. (1964). **Inhomogeneous electron gas.** *Phys. Rev.* 136, B864. doi:10.1103/PhysRev.136.B864
- [40] Kohn, W., Sham, L. J. (1965). **Self-consistent equations including exchange and correlation effects.** *Phys. Rev.* 140, A1133. doi:10.1103/PhysRev.140.A1133
- [41] Shockley, W., Queisser, H. J. (1961). **Detailed balance limit of efficiency of p-n junction solar cells.** *J. Appl. Phys.* 32, 510–519. doi:10.1063/1.1736034
- [42] Snyder, G. J., Toberer, E. S. (2008). **Complex thermoelectric materials.** *Nature Materials* 7, 105–114. doi:10.1038/nmat2090

# Referencias (8/8)

- [43] He, J., Tritt, T. M. (2017). **Advances in thermoelectric materials research: Looking back and moving forward.** *Science* 357, eaak9997. doi:10.1126/science.aak9997
- [44] Bartel, C. J. (2022). **Review of computational approaches to predict the thermodynamic stability of inorganic solids.** *J. Mater. Sci.* 57, 10475–10498. doi:10.1007/s10853-022-06915-4
- [45] Davies, D. W., Butler, K. T., Jackson, A. J., et al. (2019). **SMACT: Semiconducting Materials by Analogy and Chemical Theory.** *J. Open Source Softw.* 4, 1361. doi:10.21105/joss.01361
- [46] PalDey, S., Deevi, S. C. (2003). **Single layer and multilayer wear resistant coatings of (Ti,Al)N: a review.** *Mater. Sci. Eng. A* 342, 58–79. doi:10.1016/S0921-5093(02)00259-9
- [47] Davies, D. W., Butler, K. T., Jackson, A. J., Morris, A., et al. (2016). **Computational screening of all stoichiometric inorganic materials.** *Chem* 1, 617–627. doi:10.1016/j.chempr.2016.09.010



# ¡Gracias!

Tomás Rojas Solórzano  
Universidad de Costa Rica · [tomas.rojas\\_s@ucr.ac.cr](mailto:tomas.rojas_s@ucr.ac.cr)