



DÍA 3 • MIÉRCOLES 08:00 - 13:00

Generación de materiales con modelos de difusión

Cristales nuevos, átomo por átomo, en las GPU de Kabré

Curso IA Aplicada a Ciencia de Materiales • Tomás Rojas Solórzano • CNCA-CeNAT, 2026

El plan de hoy: casi todo en Jupyter

Hora	Bloque	Qué hacemos
08:00	Recap	El ejercicio del martes, en 5 minutos
08:05	Intro	Qué es generar materiales, en 4 láminas
08:20	P3.1	Jupyter en kura y la celda nueva
08:30	P3.2	Generación libre: leer y auditar estructuras • mini retos
09:00	P3.3	Generación con condiciones: química, simetría, gap • mini retos
09:40	P3.4 (a)	Filtros: química (SMACT) y novedad
10:00		Receso
10:30	P3.4 (b)	Estabilidad con MatterSim • mini retos y retos R3
11:30	P3.5	Notebook 06: XRD y SEM con modelos ya entrenados • retos
12:35	Cierre	Tarea para casa en la GPU y puente al jueves

Idea clave La teoría aparece justo antes de la celda que la usa. El resto queda en el apéndice, para leer después.

Lo que aprendimos al predecir el band gap



El resultado

- 655 materiales con gap entre 1.0 y 2.0 eV en el caché
- Random Forest + Magpie: MAE $\approx$ 0.19 eV, $R^2 \approx 0.36$



El descriptor clave

- Rango de electronegatividad
- Tiene sentido: diferencias de electronegatividad grandes favorecen enlaces iónicos y gaps más abiertos



Por qué es más difícil que K

- El gap depende mucho de la estructura
- Rango estrecho (1–2 eV): poca señal
- Los polimorfos vuelven a confundir al modelo

Idea clave La composición llega lejos para la rigidez, pero no tanto para el gap. Hoy empezamos a trabajar con estructuras completas.

Términos **Band gap**: brecha de energía entre bandas ocupadas y vacías; cero en metales · **eV**: electronvoltio, unidad de energía de los electrones · **Magpie**: 132 descriptores de composición: 22 propiedades $\times$ 6 estadísticas · **MAE**: error absoluto medio, en las unidades de la propiedad · **R^2** : fracción de la variación que explica el modelo; 1 es perfecto · **Descriptor (feature)**: número que describe un material y que el modelo usa como entrada · **Electronegatividad**: tendencia de un átomo a atraer electrones en un enlace · **Enlace covalente, iónico y metálico**: electrones compartidos, transferidos o deslocalizados · **Polimorfos**: misma fórmula, distinta estructura cristalina (diamante y grafito)



INTRO • 15 min

Generar materiales en cuatro ideas

Por qué generar • difusión • qué sabe un generador • cómo medir lo generado

Modelo de difusión: genera quitando ruido paso a paso, partiendo de ruido puro



Centro Nacional de Alta Tecnología



PREGUNTA PARA EL GRUPO

¿Qué tienen en común un generador de imágenes y un generador de cristales?

A

Nada: uno hace fotos y el otro química

B

Los dos aprenden cómo son los ejemplos reales y producen nuevos parecidos

C

Los dos copian y mezclan ejemplos de su base de entrenamiento

Términos **Entrenamiento y prueba:** datos con los que el modelo aprende y datos reservados para evaluarlo

Respondan en el chat · 1 minuto

Por qué generar en vez de enumerar

Screening (Día 2)

- Solo explora lo que nosotros enumeramos
- Composición fija, estructura desconocida
- Barato y transparente
- Limitado por nuestra imaginación química


Generación (hoy)

- El modelo propone composición y estructura a la vez
- Aprende la "gramática" de los cristales estables a partir de cientos de miles de ejemplos
- Puede pedirse con condiciones: química, simetría, propiedad
- Necesita GPU y filtros posteriores


Términos **Screening:** evaluar con un modelo rápido muchos candidatos y quedarse con los mejores • **GPU:** procesador gráfico; acelera el entrenamiento y uso de redes neuronales

Fuente: Sanchez-Lengeling y Aspuru-Guzik (2018)

Difusión en una imagen



En una foto: el ruido se agrega paso a paso hasta borrar la imagen



En un cristal 2D: posiciones y especies salen del ruido a la vez (animada)

Idea clave Entrenar: aprender a quitar ruido. Generar: partir de ruido puro y aplicar ese aprendizaje paso a paso (MatterGen usa 1000 pasos).

Términos **MatterGen**: modelo de difusión de Microsoft que genera cristales

Fuente: Izq.: MrAlanKoh, Wikimedia Commons, CC BY-SA 4.0; der.: esquema propio; Ho et al. (2020); Zeni et al. (2025)

Lo que un generador sabe y lo que no

Lo que aprendió de los datos

- Distancias y coordinaciones típicas
- Qué elementos suelen aparecer juntos
- Estequiometrías y simetrías frecuentes

Lo que no puede garantizar

- Que el material sea estable (hay que calcularlo)
- Que se pueda sintetizar ni cómo
- Que la propiedad pedida se cumpla exactamente

Idea clave Un generador propone hipótesis bien formadas. La verificación sigue siendo nuestra.



PREGUNTA PARA EL GRUPO

MatterGen les entrega 1000 cristales nuevos. ¿Qué revisan primero?

A Que las distancias entre átomos sean razonables

B Que las cargas se puedan balancear

C Que no existan ya en las bases de datos

D Que sean estables según DFT

Términos **Balance de carga:** las cargas de cationes y aniones suman cero • **DFT:** teoría del funcional de la densidad: cálculo cuántico de energía y electrones

Respondan en el chat • 1 minuto

Métricas: ¿cómo sabemos si lo generado sirve?



Válido

Distancias interatómicas razonables y, si es iónico, balance de carga (SMACT).



Único

No repetido dentro del mismo lote (comparando estructuras, no solo fórmulas).



Nuevo

No está en las bases de datos conocidas, comparando contra la base completa.



Estable

Cerca del casco convexo tras relajar con DFT o con un potencial universal (MatterSim, M3GNet, MACE). Hoy: MatterSim.

Idea clave La cifra que importa combina las cuatro: la fracción de estructuras estables, únicas y nuevas (S.U.N.).

Términos **SMACT**: filtro químico de balance de carga y electronegatividad · **Casco convexo y E_{hull}**: fases más estables de un sistema; E_{hull} = distancia a ellas (0 = estable) · **Relajación**: mover átomos y celda hasta que las fuerzas sean casi cero · **Potencial interatómico universal**: red que da energía y fuerzas de casi cualquier material en milisegundos · **MatterSim**: potencial interatómico universal de Microsoft · **M3GNet**: potencial universal de grafos con ángulos entre tres átomos · **MACE**: potencial universal entrenado con Materials Project · **S.U.N.**: estable, única y nueva: métrica de MatterGen

Fuente: Zeni et al. (2025); Chen y Ong (2022)



PRÁCTICA • 160 min

Notebook 03: MatterGen


P3.1 kura y celda nueva • P3.2 libre • P3.3 con condiciones • P3.4 filtros y estabilidad • mini retos y R3

Notebook: documento con celdas de código y texto que se ejecutan en orden • **kura:** cola de CPU de Kabré donde corre Jupyter • **Celda:** en un cristal, la celda unitaria: bloque mínimo que se repite (a, b, c, α , β , γ); en un notebook, un bloque de código



Centro Nacional de Alta Tecnología

P3.1: Jupyter en kura, la GPU solo para trabajos cortos



- Somos unas 50 personas y hay 7 GPU L40S: una sesión de Jupyter en nukwa retendría la GPU toda la mañana aunque nadie la use.
- Un trabajo de MatterGen ocupa unos 4 minutos de GPU. Uno por persona a la vez; la cola reparte el resto.

Términos **Jupyter**: entorno web para trabajar con notebooks · **L40S**: modelo de GPU de NVIDIA en los nodos nukwa · **nukwa**: nodos de Kabré con GPU para trabajos cortos · **SLURM**: sistema que administra la cola de trabajos del clúster

Antes de empezar: una celda nueva arriba de todo

Notebook 03 · se hace una sola vez y se guarda

```
# Celda nueva, ARRIBA de la celda [1]:  
import os  
os.environ["IA_CM_HF_HOME"] = "/work/trojas/hf_cache"  
  
# Al correr la celda [3] deben ver:  
X GPU  
✓ código MatterGen (mattergen_src)  
✓ pesos en /work/trojas/hf_cache  
  
Modo de trabajo: fallback
```

1. Kernel → Change kernel → Python-AI-Materials.
 2. Clic en la celda [1], Esc y luego A: aparece una celda vacía arriba. Pegue las dos líneas.
 3. Corra de arriba hacia abajo y guarde con Ctrl+S.
- X GPU y fallback son lo normal en kura:** la clase usa lotes ya generados.
- ¿Para qué es la línea?** Le dice a la tarea en GPU (celda [18]) dónde están los pesos de MatterGen.

Idea clave Si alguien ve **X** en pesos, la clase sigue igual. Solo hay que revisarlo antes de enviar la tarea.


Términos **Kernel:** en Jupyter, el proceso de Python que ejecuta las celdas; en un GP, la función que mide el parecido entre dos puntos · **Python:** lenguaje de programación usado en el curso

Cómo se le describe un cristal a un generador

L, la celda: matriz 3×3 de los vectores de red (o a , b , c , α , β , γ , como en la figura).

X, posiciones: coordenadas fraccionarias de cada átomo, que viven en un toro: 0 y 1 son el mismo punto.

A, especies: qué elemento ocupa cada sitio.



Idea clave El modelo debe respetar simetrías: rotar el cristal, trasladarlo o reenumerar los átomos no cambia el material.

Términos **Coordenadas fraccionarias:** posición de un átomo dentro de la celda, entre 0 y 1

Fuente: Celda: Mcpazzo, Wikimedia Commons, dominio público; Xie et al. (2022); Jiao et al. (2023); Zeni et al. (2025)

Python del día (2): leer lo que generó

```
import zipfile
from pymatgen.core import Structure

z = zipfile.ZipFile(salida / "generated_crystals_cif.zip")
estructuras = [Structure.from_str(z.read(n).decode(), fmt="cif")
                 for n in sorted(z.namelist()) if n.endswith(".cif")]

for s in estructuras:
    d = s.distance_matrix
    dmin = d[d > 0].min() # distancia más corta
    sg = s.get_space_group_info(symprec=0.1)
    print(s.composition.reduced_formula, sg, round(dmin, 2))
```

- MatterGen deja un zip con un CIF por estructura; se leen sin descomprimir a disco.

distance_matrix: todas las distancias entre pares; $d > 0$ excluye la distancia de cada átomo consigo mismo.

symprec=0.1: tolerancia en Å para reconocer simetría; lo generado nunca es perfectamente simétrico.

Términos **pymatgen:** biblioteca de Python para estructuras cristalinas · **symprec:** tolerancia para decidir si dos posiciones son simétricas · **CIF:** formato de archivo estándar para estructuras cristalinas

Mini retos P3.2: auditar la generación libre (15 min)

Copiar una celda: clic en ella, Esc, C y luego V (pega debajo). Edite solo la copia

Mini reto	Copie	Qué cambiar
1. ¿Cuál es la estructura más compacta?	[6]	Al final agregue: <code>df_gen["vol_atomo"] = df_gen["volume_A3"] / df_gen["nsites"]</code> y luego <code>df_gen.sort_values("vol_atomo")</code>
2. Un filtro más exigente	[6]	Cambie <code>min_dist > 0.5</code> por <code>min_dist > 2.0</code> . ¿Cuántas siguen válidas? ¿Cuáles caen y qué elementos tienen?
3. ¿Cuántos elementos distintos tiene cada una?	[6]	Agregue la columna <code>df_gen["n_elem"] = [len(s.composition.elements) for s in structures_raw]</code>

Idea clave Un umbral único para toda la química no funciona: los enlaces con O y F son cortos de por sí.

La guía sin clasificador en una lámina

En cada paso: ruido = sin condición + $\gamma \times (\text{con condición} - \text{sin condición})$



$\gamma = 0$

Ignora la condición: es la generación libre.



$\gamma = 1$

Sigue la condición tal como la aprendió.



$\gamma > 1$ (usamos 2)

Exagera la condición: la obedece más, a costa de menos diversidad y a veces estructuras menos realistas.

Idea clave γ es una perilla de compromiso, como la temperatura en un modelo de lenguaje. En el notebook es el argumento `guia=2.0`.

Términos **Guía sin clasificador:** mezcla generar con y sin condición; γ controla cuánto se obedece • **LLM:** modelo de lenguaje grande entrenado con texto (ChatGPT, Claude)

Fuente: Ho y Salimans (2022); Zeni et al. (2025)

Los modelos que usamos en Kabré

Cada condición es un modelo ajustado distinto (pesos de Hugging Face)

Nombre del modelo	Condición	Ejemplo en el notebook
mattergen_base	ninguna	10 cristales "libres"
chemical_system	sistema químico	{'chemical_system': 'Li-Mn-O'}
space_group	grupo espacial	{'space_group': 225} (cúbico Fm-3m)
dft_band_gap	band gap (eV)	{'dft_band_gap': 1.5}
ml_bulk_modulus, dft_mag_density, ...	otras propiedades	no se usan en el curso

Idea clave No existe una condición "sistema cristalino": para pedir cúbicos se pide un grupo espacial concreto.

Términos **Kabré:** supercomputadora del CNCA · **Hugging Face:** repositorio público de modelos ya entrenados · **Grupo espacial:** una de las 230 combinaciones de simetría de un cristal · **Sistema cristalino:** 7 familias según la forma de la celda (de triclinico a cúbico)

Fuente: Repositorio microsoft/mattergen; Zeni et al. (2025)

Python del día (1): Llamar a MatterGen desde el notebook

```
import subprocess, os
env = dict(os.environ,
           HF_HOME=str(HF_CACHE),           # pesos del curso
           HF_HUB_OFFLINE="1",
           PYTHONPATH=f"{MG_SRC}:" + os.environ.get("PYTHONPATH", ""))

cmd = ["python", "-m", "mattergen.scripts.generate", str(salida),
      "--pretrained-name=chemical_system",
      "--batch_size=20", "--num_batches=1",
      "--properties_to_condition_on={'chemical_system': 'Li-Mn-O'}",
      "--diffusion_guidance_factor=2.0"]
subprocess.run(cmd, env=env, check=True)
```

MatterGen es un programa de línea de comandos: no hay un MatterGen.generate() en Python.

HF_HOME + OFFLINE: lee los pesos de la carpeta compartida del curso (solo lectura) y no descarga nada.

Dónde corre: en kura, generar() carga los lotes ya generados; este mismo comando es el que ejecuta su tarea en la GPU.

PYTHONPATH: apunta al código fuente de MatterGen incluido en el curso (la instalación del entorno no trae algunos archivos de configuración).

Términos **Modelo preentrenado (fundacional):** modelo ya entrenado con muchos datos que se reutiliza

Lo que generó MatterGen en Kabré (prueba del 22/09/2026)

GPU L40S, nodo nukwa-04. Son los lotes que usamos en clase

Lote	Tiempo	Geometría válida	Pasan SMOCT	Observación
Incondicional (10)	1.5 min	10/10	2/10	8 son intermetálicos: SMOCT no aplica
Li-Mn-O (20)	4 min	20/20	11/20	Aparece LiMnO ₂ laminar (R-3m) y Li ₂ MnO ₃
Grupo 225 (20)	3.7 min	20/20	no aplica	16/20 cúbicos; 7 exactamente en 225
Gap 1.5 eV (20)	4.4 min	20/20	9/20	20 fórmulas distintas; el gap no se verifica aquí
Si-O-N (20)	3.5 min	16/20 (> 1.2 Å)	2/20	Una es Si ₂ N ₂ O, que existe como mineral (sinoita)

Idea clave La condición guía, no garantiza: 80 % de los "cúbicos" lo fueron.

Términos **Generación condicionada:** pedirle al generador una propiedad, química o simetría · **Intermetálico:** compuesto entre metales, sin iones definidos

Mini retos P3.3: ¿obedeció la condición? (15 min)

Cada reto es una celda copiada y editada; las originales no se tocan

Mini reto	Copie	Qué cambiar
1. ¿La simetría depende de la tolerancia?	[11]	Cambie <code>symprec=0.1</code> por <code>symprec=0.01</code> (más estricto). ¿Cuántas siguen siendo cúbicas y cuántas del grupo 225?
2. ¿Qué tan repetitivo es el lote Li-Mn-O?	celda nueva	<code>from collections import Counter</code> <code>Counter(s.composition.reduced_formula for s in structs_limnox).most_common(3)</code>
3. ¿Qué lote es más denso?	celda nueva	<code>np.mean([s.density for s in structs_limnox])</code> y lo mismo con <code>structs_solar</code> y <code>structs_cubic</code>

Idea clave La condición guía la generación, pero cuánto la obedeció depende también de cómo lo medimos.

Python del día (3): filtrar con química y novedad

```
from smact.screening import smact_validity

def balance_de_carga(s):
    return smact_validity(s.composition.reduced_formula,
                          include_alloys=False)

conocidas = set(formulas_mp) | set(formulas_entrenamiento)

candidatos = [s for s in estructuras
               if dmin(s) > 0.5
               and balance_de_carga(s)
               and s.composition.reduced_formula not in conocidas]
```

smact_validity: revisa la fórmula concreta (SiN falla, Si₃N₄ pasa). No use smact_filter: esa función solo dice si los elementos pueden formar algún compuesto.

include_alloys=False: no aprueba automáticamente los intermetálicos.

Novedad: contra una lista completa de fórmulas conocidas, no contra un caché filtrado por gap.

Términos **Novedad:** que un compuesto no exista ya en las bases de referencia



PREGUNTA PARA EL GRUPO

8 de las 10 estructuras incondicionales no pasan SMACT. ¿Qué significa?

A

Que son estructuras malas y hay que descartarlas

B

Que son intermetálicos, donde el balance de carga iónico no aplica

C

Que el modelo no aprendió química

Respondan en el chat · 1 minuto



PREGUNTA PARA EL GRUPO

Diamante y grafito tienen la misma fórmula, C. ¿Qué modelo del marte los distingue?

A El Random Forest con descriptores Magpie


B Ninguno: Magpie solo ve la composición

C Cualquiera, si tiene suficientes datos

Términos **Random Forest:** promedio de muchos árboles de decisión entrenados al azar

Respondan en el chat · 1 minuto

Un cristal como grafo




- El grafo no cambia si se traslada, rota o renumera el cristal: respeta las mismas simetrías de T3.2.
- Diamante y grafito dan grafos distintos: cuatro vecinos en tetraedro frente a tres en un plano.

Términos **Grafo**: conjunto de nodos unidos por aristas; en un cristal, átomos y enlaces · **Radio de corte**: distancia máxima para considerar vecinos a dos átomos

Fuente: Xie y Grossman (2018); Chen y Ong (2022)

P3.4: ¿sería estable? E_hull en segundos

DFT tarda horas por estructura; un potencial universal lo aproxima en kura





- Regla práctica: $E_{\text{hull}} < 0.1$ eV/átomo es un candidato razonable; muchos materiales útiles son metaestables.
- Error típico del atajo: 0.05 eV/átomo. Sirve para ordenar candidatos, no reemplaza a DFT.

Términos **Energía de formación:** energía del compuesto menos la de sus elementos, por átomo · **Materials Project:** base abierta de más de 150 000 materiales calculados con DFT · **Metaestable:** por encima del casco pero existe porque la cinética lo protege · **Atajo (shortcut):** el modelo acierta por una pista accidental, no por la física

Fuente: Yang et al. (2024); Sun et al. (2016)

Qué hay adentro de un potencial universal

- El cristal se vuelve un grafo: los átomos son nodos y los vecinos dentro de un radio de corte, aristas.
- Además de distancias, usa ángulos entre tríos de átomos (interacciones de muchos cuerpos).
- La red da una energía por átomo y las suma; fuerzas y esfuerzos salen como derivadas de esa energía.
- MatterSim v1, el que usamos hoy, se basa en esta arquitectura (M3GNet) y se entrenó con muchos más cálculos.



Términos **Esfuerzo:** fuerza por unidad de área dentro de un material

Fuente: Fig. 1 de Chen y Ong (2022), arXiv:2202.02450 (versión arXiv). Licencia CC BY 4.0

Python del día (4): relajar y medir la distancia al casco

```
calc = MatterSimCalculator(load_path="datos/hull/mattersim-v1.0.0-1M.pth")

def relajar(struct, pasos=200):
    atoms = AseAtomsAdaptor.get_atoms(struct)
    atoms.calc = calc                                # red en vez de DFT
    FIRE(FrechetCellFilter(atoms)).run(fmax=0.05, steps=pasos)
    return AseAtomsAdaptor.get_structure(atoms), atoms.get_potential_energy()

s_rel, energia = relajar(s)
ef = e_form_mattersim(s_rel.composition, energia)      # eV/átomo
print(e_hull(s_rel.composition, ef))                  # 0 = sobre el casco
```

MatterSimCalculator: una red entrenada con millones de cálculos DFT; da energía y fuerzas en milisegundos.


FrechetCellFilter: deja que también cambie la celda, como una relajación DFT completa.

e_hull(): arma el diagrama de fases con los compuestos conocidos (pymatgen PhaseDiagram) y mide qué tan arriba queda el candidato.

E_hull negativo: "más estable que todo lo conocido": casi siempre es error del modelo; ahí se corre DFT.

Términos **FIRE:** algoritmo de minimización usado para relajar estructuras

Lo que hace la relajación, en un caso real



SrTiO₃ 2x2x2 con átomos desplazados al azar y la celda estirada 4 %, relajado con MatterSim v1 (1M), FIRE y filtro de celda (animada)

Idea clave En 62 pasos la energía baja de -7.48 a -8.02 eV/átomo y la fuerza máxima cae bajo 0.05 eV/Å: eso es "relajada".

Fuente: Cálculo propio con MatterSim v1.0.0-1M (Yang et al. 2024) y ASE, en CPU

P3.4: lo que deben obtener con el lote Li-Mn-O

16 / 20

con $E_{\text{hull}} < 0.1 \text{ eV/átomo}$

≈ 0

E_{hull} de LiMnO_2 : un compuesto estable conocido cae sobre el casco, como debe ser

2 / 20

pasan distancia, SMOCT y novedad contra la lista completa de Materials Project

- Con un caché parcial de MP, 11 de 20 parecían nuevas, entre ellas LiMnO_2 y Li_2MnO_3 , que se conocen desde hace décadas.
- Tiempo: unos 3 minutos para las 20 estructuras en la prueba con 4 núcleos; con los 2 núcleos de la sesión de clase puede tardar el doble.

Idea clave Cada filtro responde una pregunta distinta: geometría, química, novedad y energía. Ninguno basta solo.



PREGUNTA PARA EL GRUPO

Una estructura no pasa SMOCT, pero MatterSim le da $E_{\text{hull}} = 0.02$ eV/átomo. ¿A cuál filtro le creen más?

- A** A SMOCT: si las cargas no se balancean, no existe
- B** A MatterSim: la energía es lo que decide
- C** A ninguno todavía: puede ser un intermetálico o un error del modelo; hay que mirar la estructura

Respondan en el chat · 1 minuto

Estable no es lo mismo que sintetizable

E_hull dice si un compuesto debería existir, no si alguien puede hacerlo

Lo que mide E_hull

- Energía a 0 K, sin temperatura ni entropía
- Comparación solo con las fases conocidas del mismo sistema
- Ignora la cinética: no dice qué ruta, precursores o condiciones usar
- Muchos materiales útiles son metaestables: depende de la química

Lo que decide el laboratorio

- A temperatura de síntesis, átomos parecidos se mezclan: el cristal ordenado que propone el modelo puede salir desordenado
- En el A-Lab, cerca de dos tercios de los "nuevos" resultaron versiones desordenadas de compuestos conocidos
- Un límite útil: por encima de la energía del amorfo, la síntesis es muy improbable (probado con más de 700 polimorfos de 41 sistemas)

Idea clave E_hull ordena candidatos; la síntesis la decide el experimento.

Términos **Desorden catiónico**: cationes distintos que ocupan los mismos sitios al azar • **A-Lab**: laboratorio autónomo de Berkeley que sintetiza con robots • **Amorfo**: sólido sin orden de largo alcance

Fuente: Sun et al. (2016); Aykol et al. (2018); Leeman et al. (2024)

Mini retos P3.4: filtrar y elegir candidatos (20 min)

El reto 3 necesita la tabla de estabilidad de la celda [15]

Mini reto	Copie	Qué cambiar
1. Los mismos filtros, otro lote	[13]	Cambie structs_limnox por structs_solar (y luego por structs_cubic). ¿Cuántos pasan?
2. ¿Qué filtro elimina más?	celda nueva	sum(is_smact_valid(s) for s in structs_limnox) sum(s.composition.reduced_formula not in mp_formulas for s in structs_limnox)
3. Los mejores candidatos	celda nueva	estab[(estab["E_hull"] < 0.05) & estab["SMACT"]] ¿Cuál de ellos es además nuevo?

Idea clave El candidato que vale un cálculo DFT es el que pasa los cuatro filtros a la vez: geometría, química, novedad y energía.

Retos y ejercicio para casa



Retos en clase (R3)

- Diseñe su propio criterio de validez (densidad, volumen por átomo, distancia vs suma de radios) y aplíquelo al lote incondicional
- Compare la diversidad de los lotes Li-Mn-O y cúbico; defina primero cómo medirla



Para casa

- Envíe su generación a la GPU (tarea_mattergen.sbatch; sugerido Si-O-N)
- ¿Cuántas tienen distancia mínima $> 1.2 \text{ \AA}$? ¿Cuántas pasan SMOCT? ¿Cuántas son nuevas? ¿Qué E_hull tienen?
- Elija 3 para síntesis y justifique

Idea clave Mañana: ya tenemos candidatos. ¿Cuál probamos primero si cada experimento cuesta un día de laboratorio?

Tarea del Día 3: su propia generación en la GPU

Se envía en clase y se revisa después; no hay que esperar frente a la pantalla



- Un trabajo de GPU a la vez por persona: si ya tiene uno en la cola, `enviar_a_gpu()` no manda otro.
- Unos 4 minutos de GPU por trabajo; con todo el grupo enviando, la cola puede tardar de 30 a 60 minutos.
- La tarea de visión (`tarea_vision.sbatch`) funciona igual: 20 épocas de la CNN de XRD con una variante del aumento de datos.

Términos **Época**: una pasada completa por todos los datos de entrenamiento · **CNN**: red convolucional: aplica filtros que se deslizan sobre una señal o imagen · **XRD**: difracción de rayos X: picos que revelan la red cristalina · **Aumento de datos**: crear variantes artificiales de los ejemplos para hacer robusto al modelo



P3.5 • 65 min

Notebook 06: visión computacional

XRD con una red 1D • imágenes SEM con ResNet-18 • modelos ya entrenados

SEM y TEM: microscopía electrónica de barrido y de transmisión • **ImageNet y ResNet:** colección de 1.2 millones de fotos y la red entrenada con ella




Centro Nacional de Alta Tecnología

Un difractograma es una imagen de una dimensión

- Cada patrón es una lista de intensidades: aquí, 1200 números entre 10 y 70°.
- La simetría decide cuántos picos hay y cómo se ordenan: el cúbico tiene pocos y muy regulares; el monoclinico, muchos.
- Un cristalógrafo reconoce esas "formas" con la experiencia. Una red las aprende con ejemplos.


Ley de Bragg: $n\lambda = 2d \sin \theta$. Cada familia de planos da un pico (abajo).




Términos Ley de Bragg: $n\lambda = 2d \sin \theta$: dónde aparecen los picos de difracción

Fuente: Diagrama de Bragg: Hydrargyrum, Wikimedia Commons, CC BY-SA 3.0; patrones: cálculo propio


NaCl, cúbico (Fm-3m)



TiO₂ rutilo, tetragonal (P4₂/mnm)




TaSb₂, monoclinico (grupo 12)



La convolución: un detector que se desliza

- Un filtro es una lista corta de pesos (aquí 31) que recorre el patrón.
- Donde el patrón se parece al filtro, la salida es alta: el filtro "se enciende".
- La red aprende cientos de filtros: picos anchos, angostos, dobletes, hombros.
- Las capas siguientes combinan esas detecciones en patrones más grandes.



Términos **Convolución:** deslizar un filtro sobre la señal y medir cuánto se parece cada zona · **Doblete:** par de picos cercanos de un mismo elemento o transición

Fuente: Animación propia (patrón de rutilo simulado con pymatgen); LeCun et al. (2015)

Aprendizaje por transferencia: no empezar de cero

Entrenar desde cero

- Decenas de miles de imágenes etiquetadas
- Horas o días de GPU
- Difícil con los datos de un solo laboratorio

Transferir y ajustar

- Partir de una red que ya aprendió a ver (ImageNet: 1.2 millones de fotos)
- Ajustar con unos cientos de micrografías propias
- Minutos de GPU; así se entrenó el modelo SEM del curso

Idea clave Los bordes y texturas de una foto cotidiana también sirven para una micrografía.

Términos **Aprendizaje por transferencia:** partir de una red ya entrenada y ajustarla con pocos datos propios


Fuente: He et al. (2016); Stuckner et al. (2022)

El cambio de dominio: de lo simulado a lo medido

Lo que el simulador no incluye: orientación preferencial, fases secundarias, tamaño de cristalito, portamuestras.

Química distinta: un tercio de los patrones reales son cristales moleculares, casi ausentes en Materials Project.

Qué se hace: más aumento de datos, ajustar con algunos patrones reales, y medir siempre con datos propios antes de confiar.



Idea clave Un modelo solo vale lo que vale su prueba con datos como los suyos.

Términos **Cambio de dominio:** los datos de uso difieren de los de entrenamiento

Fuente: Hollarek et al. (2025); Szymanski et al. (2021)

Los datos y los modelos de la práctica

52 809

XRD simulados (Materials Project) para
entrenar la red 1D

328

XRD experimentales de opXRD para la
prueba de fuego

3 783

imágenes SEM de NFFA-Europe en 10
categorías para ajustar ResNet-18

- Todo con licencia CC BY 4.0. Los modelos se entrenaron en Kabré antes del curso (GPU L40S, unos 15 minutos en total).
- Ustedes reciben los pesos (1.3 MB y 22 MB) y 200 imágenes de prueba: el notebook corre en CPU.

Términos opXRD y NFFA-Europe: conjuntos abiertos de difractogramas y de imágenes SEM • **CPU:** procesador general de una computadora

Fuente: Dunn et al. (2020); Hollarek et al. (2025); Aversa et al. (2018)

Python del día (5): usar un modelo que entrenó otro

```
modelo = CNN1D(n_clases=7)                # misma arquitectura
pesos = torch.load("modelos/xrd_cnn1d.pt", map_location="cpu")
modelo.load_state_dict(pesos)              # copiar lo aprendido
modelo.eval()                             # modo predicción

with torch.no_grad():
    prob = torch.softmax(modelo(torch.tensor(X)), dim=1)
    pred = prob.argmax(1)                  # clase más probable
```

Misma arquitectura: el archivo de pesos solo guarda números; la clase CNN1D tiene que ser idéntica a la del entrenamiento.

map_location="cpu": permite cargar en kura pesos entrenados en una GPU.

eval() y no_grad(): apagan el dropout y el cálculo de gradientes; predecir es mucho más rápido.

softmax: convierte las salidas en probabilidades que suman 1; la máxima mide la confianza.

Términos **PyTorch:** biblioteca de Python para redes neuronales • **Softmax:** convierte las salidas de una red en probabilidades que suman 1 • **Dropout:** apagar neuronas al azar al entrenar para evitar el sobreajuste • **Gradiente:** dirección en que una función crece más rápido; guía el ajuste de los pesos

P3.5: lo que deben obtener

Prueba	Exactitud	Referencia
XRD simulados que el modelo no vio (700)	61 %	azar: 14 %
XRD experimentales opXRD (328)	28 %	siempre "monoclínico": 31 %
solo inorgánicos (222)	30 %	
XRD reales tras ajustar con 163 patrones (se mide en los otros 165)	45 %	antes del ajuste: 30 %
SEM, 20 imágenes por categoría (200)	94 %	azar: 10 %

Idea clave El mismo tipo de modelo brilla o falla según qué tan parecidos sean los datos de prueba a los de entrenamiento.

Términos **Exactitud (accuracy)**: fracción de aciertos en una clasificación

Qué confunde el modelo de XRD

- El cúbico es casi perfecto: pocos picos, muy regulares.
- Los errores siguen la física: monoclinico con triclínico y ortorrómbico, trigonal con hexagonal, tetragonal con cúbico.
- Cuando un modelo se equivoca "como un cristalógrafo", es buena señal: aprendió algo real.

XRD simulados de prueba (100 por clase)

	triclínico	monoclínico	ortorrómbico	tetragonal	trigonal	hexagonal	cúbico
real triclínico	52	29	7	3	2	0	7
monoclínico	15	61	14	4	3	1	2
ortorrómbico	3	19	59	6	4	5	4
tetragonal	2	9	10	59	8	0	12
trigonal	4	10	13	7	48	10	8
hexagonal	0	1	9	13	15	54	8
cúbico	0	0	1	4	1	1	93

Retos de la práctica y ejercicio para casa



Retos en clase

- Reto A: desplace los XRD en 2θ (0 a 1°) y agregue ruido; grafique la exactitud. ¿Cuándo deja de servir?
- Reto B: las 5 imágenes SEM con menor confianza. ¿Son ambiguas? ¿Usarían un umbral?



Para casa

- Envíe `tarea_vision.sbatch` quitando una parte del aumento de datos y compare con el modelo del curso
- Opcional: pruebe el modelo XRD con un difractograma propio (Cu K α , dos columnas)

Idea clave Usar un modelo ajeno con responsabilidad: medirlo, entender qué mira y saber dónde falla.

Roboflow Universe: así se ve un dataset

Quién y con qué licencia: autor y CC BY 4.0 (se puede usar citando la fuente).

Tarea: aquí Classification: una etiqueta por imagen.


Clases: los 6 defectos del acero, con 1 799 imágenes.

Pestañas: Images para mirar cada imagen y su etiqueta; Dataset para las versiones y la descarga.

NEU-DET classification Computer Vision Dataset

by Park Sung-ho Task: [Classification](#) License: CC BY 4.0 [0 stars](#)
39 views 2 downloads

[Fork Dataset](#)



[Overview](#) [Images 1,799](#) [Dataset 1](#)

Images 1.8k
Dataset versions 1
Models 0

CLASSES (6)

[scratches](#) [patches](#)
[crazing](#) [inclusion](#)
[pitted_surface](#) [rolled-in_scale](#)


TAGS

[Classification](#)

Updated 4 years ago

[Report](#)

[See all 1.8k images](#)




About NEU-DET classification Dataset



A description for this project has not been published yet.


Buscar datasets: universe.roboflow.com

Busque en inglés (microstructure, SEM, crack, corrosion, weld) y filtre por tipo de proyecto y número de imágenes




Idea clave Hay cientos de datasets de materiales; casi todos pequeños y de calidad muy variable.

Cada dataset tiene versiones y una división fija



Versión 1 de NEU: 1 259 de entrenamiento, 360 de validación y 180 de prueba, sin preprocesamiento



Para descargar hace falta una cuenta gratis (Google, GitHub o correo)

Idea clave Use siempre la misma versión: así sus resultados se pueden comparar con los de otros.

Términos **Validación:** comprobar el modelo con datos que no vio • **Preprocesamiento:** limpiar, suavizar y normalizar los datos antes del modelo

Extra: bajar un dataset de Roboflow Universe (demo)

```
import io, zipfile, requests
from pathlib import Path

key = open(Path.home() / ".roboflow_key").read().strip()
url = ("https://api.roboflow.com/park-sung-ho/"
      "neu-det-classification/1/folder")
r = requests.get(url, params={"api_key": key}).json()
z = requests.get(r["export"]["link"]).content
zipfile.ZipFile(io.BytesIO(z)).extractall("neu")
```

Roboflow Universe: sitio donde la comunidad publica imágenes ya etiquetadas, cada una con su licencia y sus versiones.

Formato "folder": una carpeta por clase, separada en train / valid / test. Para detección se pide YOLO o COCO.

API key: gratis pero personal. Va en un archivo privado, nunca escrita en el notebook.

Antes de usarlo: revise licencia y origen. NEU: 1 800 imágenes de acero laminado en caliente, 6 defectos, CC BY 4.0.

Idea clave Lo bajo yo con mi key a una carpeta compartida: ustedes no necesitan cuenta.

Términos API: interfaz para consultar una base de datos desde un programa

Más datasets de materiales en Roboflow Universe

Todos públicos, CC BY 4.0. Antes de pegar el enlace: universe.roboflow.com/


Dataset	Tarea	Imágenes	Enlace (después de universe.roboflow.com/)
NEU-DET: 6 defectos en acero laminado (el de hoy)	Clasificación	1 799	park-sung-ho/neu-det-classification
NEU: los mismos defectos con cajas	Detección	388	data-set-fptet/neu-surface-defect
Micrografías de acero: bainita, martensita, perlita	Segmentación	58	1-nhhe4/micro_structure1
Nanopartículas (una sola clase)	Segmentación	38	ehsan-moradpurtari/nanoparticles-snnks
Soldaduras: grieta, porosidad, sobremonta, salpicaduras	Segmentación	9 877	weldingdefects-yfhj4/weld-defects-kcocu
Corrosión en distintas superficies	Segmentación	2 059	failure-sjoo6/corrosion-instance-segmentation-sfcpc-1yuxi

Idea clave Revise siempre quién etiquetó, cuántas imágenes hay por clase y la licencia: la calidad varía mucho.


Términos **Clasificación:** predecir una categoría (por ejemplo el sistema cristalino) • **Segmentación:** separar regiones u objetos en una imagen

Tres tipos de etiqueta

Clasificación: una etiqueta por imagen (aquí: crazing)



Detección: una caja por cada defecto




Segmentación: el contorno de cada poro (polígono)



Idea clave El tipo de etiqueta decide el modelo: un clasificador, un detector (como YOLO) o un segmentador.

Cómo etiquetar sus propias imágenes en Roboflow


1. **Crear el proyecto** en app.roboflow.com: elegir el tipo (clasificación, detección o segmentación) y nombrar las clases.
2. **Subir las imágenes:** arrastrar la carpeta al navegador.
3. **Etiquetar:** B dibuja una caja, P un polígono, S un polígono inteligente (sugiere el contorno con un clic), N marca "sin defecto". Luego se elige la clase.
4. **Generar una versión:** división train / valid / test, preprocesamiento y aumentos.
5. **Exportar:** folder, YOLO o COCO, como zip o con la API key (como en el demo).



Revise las etiquetas antes de confiar en un dataset



Lo que se guarda: cada polígono es una lista de puntos (x, y) en píxeles



Un dataset de "segmentación" de perlita cuya etiqueta es un rectángulo de casi toda la imagen

Idea clave Un modelo no puede ser mejor que sus etiquetas: abra 10 imágenes al azar antes de usar un dataset.

Mini reto P3.5c: la red de SEM mira acero

Al final del notebook: celda nueva (Esc, B), escriba la línea %load y ejecútela dos veces

```
%load /work/trojas/ia_cm_cnca/roboflow_neu/neu_celda.py

# lo que trae la celda, en resumen:
entreno = ImageFolder(NEU / "train", transform=prep_neu)
prueba = ImageFolder(NEU / "test", transform=prep_neu)
X_tr, y_tr = rasgos(entreno)      # ResNet sin capa final
X_te, y_te = rasgos(prueba)      # 512 números por imagen
clf = LogisticRegression(max_iter=3000).fit(X_tr, y_tr)
```

%load: la primera ejecución pega el código del archivo en la celda; la segunda lo corre.

ImageFolder: lee el formato "folder" de Roboflow: el nombre de cada carpeta es la etiqueta.

rasgos(): la ResNet de SEM sin su última capa; no se reentrena nada de la red.

LogisticRegression: lo único que aprende: cómo separar los 6 defectos con esos 512 números.

Idea clave No reentrenamos la red: reusamos lo que aprendió con SEM y solo entrenamos un clasificador pequeño.

Mini reto P3.5c: preguntas (15 min)

Copiar una celda: clic en ella, Esc, C y luego V (pega debajo). Edite solo la copia

Pregunta	Qué escribir o cambiar
1. ¿Sirve una red de SEM para acero?	Corra la celda y compare la exactitud con el azar (17 %). ¿Por qué funciona si nunca vio acero?
2. ¿Cuántas etiquetas hacen falta?	En la copia use <code>.fit(X_tr[:,20], y_tr[:,20])</code> (1 de cada 20) y luego <code>[:,60]</code> . ¿Cuánto cae?
3. ¿Qué defectos confunde?	<code>ConfusionMatrixDisplay.from_predictions(y_te, pred_neu, display_labels=entreno.classes, xticks_rotation=45)</code>
4. ¿Qué cree la red de SEM que es el acero?	<code>X5 = torch.stack([prueba[i][0] for i in range(0, len(prueba), 30)])</code> y luego <code>[CLASES_SEM[i] for i in modelo_sem(X5).argmax(1)]</code>

Idea clave Con buenos rasgos bastan pocas etiquetas: por eso un dataset pequeño y bien etiquetado ya sirve.



APÉNDICE

Para leer después


La teoría completa del día: MatterGen en profundidad, redes de grafos y visión computacional

GNN: red neuronal que opera sobre un grafo de átomos y vecinos



CeNAT
Centro Nacional de Alta Tecnología

Un mismo cristal, muchas descripciones



Idea clave Trasladar, rotar o reenumerar no cambia el material: el modelo debe dar la misma respuesta. Por eso usan redes equivariantes.

Términos **Invariancia y equivariancia:** no cambiar al rotar el cristal (energía) o cambiar con él (fuerzas)

Familias de modelos generativos para cristales

Modelo	Idea central	Año
CDVAE	Autoencoder variacional: comprime cristales a un espacio latente y decodifica con un proceso de difusión sobre posiciones	2022
DiffCSP	Difusión conjunta y equivariante sobre celda y coordenadas fraccionarias, para predecir estructuras	2023
GNoME	No genera directamente: redes de grafos filtran millones de candidatos y DFT los verifica en ciclo activo	2023
MatterGen	Difusión sobre especies, posiciones y celda; se ajusta a propiedades con adaptadores y guía sin clasificador	2025

Idea clave La tendencia: difusión (la misma familia que los generadores de imágenes) + condicionamiento a propiedades.

Términos **Modelo generativo:** aprende cómo son los ejemplos reales y produce otros nuevos parecidos · **CDVAE y DiffCSP:** generadores de cristales anteriores a MatterGen · **Autoencoder variacional (VAE):** red que comprime los datos a un espacio latente y los reconstruye · **Espacio latente:** representación comprimida que aprende un modelo · **GNoME:** proyecto de Google DeepMind que propuso millones de estructuras con GNN y DFT · **Adaptador:** módulo pequeño que se ajusta para condicionar un modelo grande

Fuente: Xie et al. (2022); Jiao et al. (2023); Merchant et al. (2023); Zeni et al. (2025)

Entrenar y generar son procesos opuestos

Entrenar (una vez, costoso)

- Tomar un cristal real
- Agregarle ruido en posiciones, celda y especies
- Pedirle a la red que adivine el ruido
- Repetir con cientos de miles de cristales

Generar (en clase, minutos)

- Empezar de ruido puro
- La red estima el ruido y lo quita un poco
- Repetir muchos pasos hasta obtener un cristal
- Con condición: la red también recibe la propiedad pedida

Idea clave Nosotros solo generamos: el entrenamiento ya lo hicieron los autores y usamos sus pesos.

Fuente: Ho et al. (2020); Zeni et al. (2025)

MatterGen: qué hay adentro



Entrenamiento base

Cientos de miles de estructuras estables de Materials Project y Alexandria (conjunto Alex-MP-20, hasta 20 átomos por celda).



Red que quita el ruido

GemNet: una red de grafos equivariante que "ve" distancias y ángulos entre átomos.



Adaptadores

Módulos pequeños que se ajustan con datos etiquetados (gap, simetría, sistema químico...) sin reentrenar todo.




Guía sin clasificador

Mezcla la predicción con y sin condición. El factor de guía controla qué tanto se obedece la condición (usamos 2.0).

Términos **GemNet:** red de grafos que MatterGen usa para quitar el ruido

Fuente: Zeni et al. (2025)

MatterGen, en la figura del artículo



(a) Difusión directa e inversa sobre tipos de átomo (A), coordenadas (X) y red (L). (b) Preentrenamiento y ajuste con adaptadores. (c) Generación condicionada a química, simetría o propiedad.

Fuente: Fig. 1 de Zeni et al. (2025), Nature 639, 624–632, doi:10.1038/s41586-025-08628-5. Licencia CC BY 4.0

Lo que reporta el artículo de MatterGen

- Comparado con modelos previos, sus estructuras tienen más del doble de probabilidad de ser nuevas y estables, y quedan más de diez veces más cerca de un mínimo de energía.
- Puede generar condicionado a química, simetría y propiedades electrónicas, magnéticas y mecánicas.
- Como prueba de concepto sintetizaron un material propuesto por el modelo (TaCr_2O_6) y su módulo volumétrico medido quedó cerca del valor pedido.
- Los propios autores insisten: generar es el primer paso; el filtrado, el cálculo y el experimento siguen siendo necesarios.

Idea clave Un generador bueno no elimina la verificación: la vuelve más productiva.

Términos **Módulo volumétrico K:** resistencia a cambiar de volumen bajo presión uniforme

Fuente: Zeni et al. (2025)

Los resultados, en la figura del artículo


a: cuatro cristales generados.

b: energía sobre el casco convexo, comparada con dos referencias.

c: cuánto se mueven los átomos al relajar con DFT (RMSD): casi nada.

d: fracción de estructuras únicas y nuevas al generar millones.


e, f: tasa de estructuras S.U.N. y RMSD frente a otros generadores.



Términos RMSD: desviación media de posiciones entre dos estructuras

Fuente: Fig. 2 de Zeni et al. (2025), Nature 639, 624–632, doi:10.1038/s41586-025-08628-5. Licencia CC BY 4.0

Algunas estructuras generadas




Estructuras generadas por MatterGen en Kabré, simetrizadas con pymatgen (symprec = 0.1) y dibujadas con ASE

Idea clave Algunas se parecen a materiales conocidos: es buena señal (el modelo aprendió química real) y es la razón de revisar novedad.

Términos **ASE**: biblioteca de Python para simular átomos (relajar, calcular energías)

Paso de mensajes: cada átomo aprende de sus vecinos



- Tras tres capas, cada átomo "sabe" de sus vecinos, de los vecinos de sus vecinos y uno más allá.
- Si se suma una energía por átomo, la predicción escala con el tamaño de la celda, como la energía real.

Términos Paso de mensajes: cada átomo actualiza su información con la de sus vecinos

Fuente: Xie y Grossman (2018); Chen y Ong (2022)

Redes de grafos que aparecen en el curso

Modelo	Qué hace	Dónde lo vemos
CGCNN (2018)	Predice propiedades (energía de formación, gap, módulos) directamente desde la estructura	Referencia clásica
GNoME (2023)	Redes de grafos + DFT en ciclo activo para proponer estructuras estables	Día 1, casos
M3GNet (2022)	Potencial universal: energía, fuerzas y esfuerzos; incluye ángulos	Hoy, P3.4
MatterSim v1 (2024)	Arquitectura M3GNet entrenada en un rango amplio de temperaturas y presiones	Hoy, P3.4
MACE-MP-0 (2023)	Potencial universal entrenado con datos de Materials Project	Día 5, tendencias
GemNet	Red equivariante que quita el ruido dentro de MatterGen	Hoy, T3.3

Términos CGCNN: red de grafos que predice propiedades desde la estructura
Fuente: Xie y Grossman (2018); Merchant et al. (2023); Chen y Ong (2022); Yang et al. (2024); Batatia et al. (2023); Zeni et al. (2025)

Grafos frente a descriptores de composición

Magpie + Random Forest (martes)

- Solo necesita la fórmula
- Funciona con cientos de datos
- No distingue polimorfos
- Rápido en CPU e interpretable con SHAP

Redes de grafos (hoy)

- Necesitan la estructura completa
- Se entrenan con miles a millones de ejemplos y GPU
- Distinguen polimorfos y dan fuerzas
- En la práctica se usan ya entrenadas, como en visión

Idea clave Con pocos datos y solo composición, Random Forest; con estructuras y un modelo preentrenado, grafos.

Términos **Interpretabilidad:** entender qué usó un modelo para hacer sus predicciones · **SHAP:** reparte cada predicción entre los descriptores: valor base + aportes = predicción · **Pocos datos (small data):** decenas o pocos cientos de experimentos; piden modelos simples con incertidumbre



PREGUNTA PARA EL GRUPO

¿Qué datos de caracterización se acumulan en su laboratorio sin que nadie alcance a analizarlos a fondo?

A Difractogramas (XRD)

B Imágenes SEM o TEM

C Espectros Raman, FTIR o XPS

D Mapas EDS o de otras técnicas

Términos **FTIR y Raman:** espectroscopías vibracionales de las moléculas y enlaces · **XPS:** espectroscopía de fotoelectrones: composición y estados químicos en superficie · **EDS:** mapa de composición con rayos X característicos en el microscopio

Respondan en el chat · 1 minuto

Tres tipos de datos, las mismas ideas



Espectros (1D)

- XRD, Raman, FTIR, XPS
- Intensidad contra ángulo, número de onda o energía
- Tareas: identificar fases, clasificar simetría, cuantificar



Imágenes (2D)

- SEM, TEM, óptica, AFM
- Intensidad en cada píxel
- Tareas: clasificar, segmentar granos o partículas, medir tamaños, detectar defectos



Mapas (2D + canales)



- EDS, EELS, Raman confocal
- Un espectro en cada píxel
- Tareas: separar fases, mapas de composición

Idea clave En los tres casos la herramienta central es la misma: la red convolucional.

Términos EELS: espectroscopía de pérdida de energía de electrones

Fuente: Holm et al. (2020); LeCun et al. (2015)

En imágenes, la misma idea en dos dimensiones



Un filtro 3 × 3 recorre la imagen; cada salida es una suma de productos (animada)


Esquema con partículas sintéticas y un filtro de bordes

Idea clave Primeras capas: bordes y texturas. Capas profundas: partículas, fibras, poros. La última capa decide la categoría.

Términos **Datos sintéticos:** generados por simulación o con un modelo, no medidos

Fuente: Izq.: Michael Plotke, Wikimedia Commons, CC BY-SA 3.0; der.: esquema propio; He et al. (2016)

Diez categorías de micrografías SEM (NFFA-Europe)




Idea clave Categorías muy distintas entre sí: un buen primer problema. El reto real son las diferencias sutiles dentro de su propio material.

Fuente: Aversa et al. (2018)


Pocos datos reales: simular para entrenar

- Casi no hay difractogramas experimentales etiquetados; simularlos desde estructuras conocidas es barato.
- El truco es el aumento de datos: ensanchar picos, agregar el doblete $K\alpha_2$, fondo y ruido al azar.
- Así se entrenó el modelo de la práctica: 52 809 patrones simulados de Materials Project.


1. Simulado ideal




2. + picos anchos, doblete $K\alpha_2$ y corrimiento



3. + fondo (amorfo, fluorescencia)



4. + ruido de conteo



Términos **Ensanchamiento de picos:** picos más anchos por cristalitos pequeños o deformación

Fuente: Park et al. (2017); Oviedo et al. (2019); Lee et al. (2020)



PREGUNTA PARA EL GRUPO

Nuestro modelo acierta el sistema cristalino en 61 % de los XRD simulados que no vio. ¿Cuánto esperan en difractogramas reales?

A

Parecido, alrededor de 61 %

B

Algo menos, entre 40 y 55 %

C

Mucho menos: como adivinar siempre la clase más común

Respondan en el chat · 1 minuto

Lo que ya se hace en la literatura


Tarea	Datos	Trabajo
Clasificar imágenes SEM en 10 categorías	21 169 micrografías (NFFA-Europe)	Modarres et al. (2017); Aversa et al. (2018)
Clasificar microestructuras	Micrografías de aceros y aleaciones	DeCost y Holm (2015); Holm et al. (2020)
Sistema cristalino y grupo espacial desde XRD	XRD simulados de estructuras conocidas	Park et al. (2017)
Identificar fases en mezclas	XRD simulados + experimentales	Lee et al. (2020); Szymanski et al. (2021)
Reconocer espectros Raman	Base RRUFF de minerales	Liu et al. (2017)
Identificar átomos y defectos en STEM	Imágenes de resolución atómica	Ziatdinov et al. (2017)

Idea clave Casi todos empiezan igual: una red convolucional, aumento de datos y validación con datos experimentales.

FTIR y Raman: la misma red, otro preprocesamiento

Qué cambia al pasar de un difractograma a un espectro vibracional

	XRD	FTIR y Raman
Eje	2θ (grados)	Número de onda (cm ⁻¹)
Qué codifica	La periodicidad del cristal	Enlaces y grupos funcionales: sirve también para polímeros y amorfos
Problemas típicos	Picos desplazados por la celda, ensanchamiento	Fondo de fluorescencia (Raman), línea base, bandas del ambiente (FTIR)
Preprocesamiento	Restar fondo y normalizar	Suavizado (Savitzky-Golay), corrección de línea base, normalización, recorte de regiones
Referencias	Patrones simulados (Materials Project)	Bibliotecas medidas: abiertas (Open Specy) o comerciales



Un espectro FTIR real (ejes en alemán: absorbancia contra número de onda)

Idea clave La red convolucional sirve igual; lo que cambia es la limpieza del espectro y de dónde salen las referencias.

Fuente: Espectro: Butenbremer, Wikimedia Commons, CC BY-SA 3.0; Cowger et al. (2021); Liu et al. (2017)

Un caso aplicado: identificar polímeros en espectros



Biblioteca abierta

Open Specy: software libre y biblioteca comunitaria de espectros Raman y FTIR para identificar microplásticos, con suavizado y corrección de línea base incluidos.



Bosque aleatorio sobre imágenes FTIR

Clasificaron cinco polímeros (PE, PP, PMMA, PAN y PS) en muestras ambientales y midieron su abundancia y tamaño de forma automática.



En su laboratorio

Verificar materia prima, detectar contaminación o degradación. Su propia biblioteca de referencia y un método simple (correlación o vecinos cercanos) son un buen primer paso.

Idea clave Con pocos espectros propios, empiece por una biblioteca bien curada y un método simple; la complejidad se agrega solo si hace falta.

Términos **Correlación:** qué tanto dos variables cambian juntas (de -1 a 1); no implica causa

Fuente: Cowger et al. (2021); Hufnagl et al. (2019)

¿Qué está mirando el modelo?



Mapas de saliencia

Qué zonas del espectro o de la imagen cambian más la decisión. Deben coincidir con picos o con la muestra, no con el ruido.



El espacio interno

El vector de números que la red calcula por imagen, proyectado a 2D: si las clases forman grupos, aprendió a separarlas.



Atajos peligrosos

La barra de escala, la franja de metadatos del SEM o el tipo de portamuestras pueden delatar la clase. Por eso recortamos la franja inferior de las imágenes.

Idea clave Una exactitud alta con un atajo es un modelo que falla apenas cambia el microscopio.


Términos **Saliencia:** mapa de las zonas de la entrada que más empujaron la decisión • **Metadatos:** información sobre cómo se obtuvo un dato (equipo, condiciones, fecha)

Un mapa de atribución, en concreto

- Para cada imagen, SHAP colorea qué píxeles empujaron la decisión hacia cada clase.

Rojo: a favor de esa clase. Azul: en contra.

- El modelo reconoce al suricata (meerkat) por la cara, no por el fondo: buena señal.
- Con micrografías se pregunta lo mismo: ¿mira la muestra o la barra de escala?



Fuente: Ejemplo de GradientExplainer (red VGG16, imágenes de ImageNet) del repositorio de SHAP (Lundberg y Lee, github.com/shap/shap), licencia MIT

Para aplicarlo en su laboratorio



Etiquetar un poco

Unas decenas de ejemplos por clase, bien etiquetados, valen más que miles dudosos.



Formato constante

Mismo rango de 2θ , mismo paso, misma magnificación: el preprocesado importa tanto como el modelo.



Partir de un modelo existente

Ajustar una red preentrenada (ImageNet, MicroNet o un modelo de XRD simulado) con datos propios.



Validar con lo propio

Separar desde el inicio un conjunto de prueba medido en su equipo y no tocarlo hasta el final.


Un ejemplo del A-Lab, revisado

Leeman et al. (2024), Fig. 1: el caso Mg_3NiO_4

Arriba: la estructura ordenada predicha (Materials Project) y su difractograma simulado.

Al medio: el compuesto conocido, tipo sal de roca, con Mg y Ni desordenados (ICSD).

Abajo: el patrón medido: coincide con el desordenado; los picos propios del ordenamiento no aparecen.



Términos ICSD: base de estructuras cristalinas medidas experimentalmente

Fuente: Fig. 1 de Leeman et al. (2024), PRX Energy 3, 011002, doi:10.1103/PRXEnergy.3.011002 (versión del repositorio NSF-PAR). Licencia CC BY 4.0

Referencias (1/7)

- [1] Zeni, C., Pinsler, R., Zügner, D., et al. (2025). **A generative model for inorganic materials design.** *Nature* 639, 624–632. doi:10.1038/s41586-025-08628-5
- [2] Xie, T., Fu, X., Ganea, O.-E., Barzilay, R., Jaakkola, T. (2022). **Crystal diffusion variational autoencoder for periodic material generation.** *ICLR* 2022. arXiv:2110.06197
- [3] Jiao, R., Huang, W., Lin, P., et al. (2023). **Crystal structure prediction by joint equivariant diffusion.** *NeurIPS* 2023. arXiv:2309.04475
- [4] Merchant, A., Batzner, S., Schoenholz, S. S., et al. (2023). **Scaling deep learning for materials discovery.** *Nature* 624, 80–85. doi:10.1038/s41586-023-06735-9
- [5] Ho, J., Jain, A., Abbeel, P. (2020). **Denoising diffusion probabilistic models.** *NeurIPS* 33. arXiv:2006.11239
- [6] Ho, J., Salimans, T. (2022). **Classifier-free diffusion guidance.** *preprint*. arXiv:2207.12598

Referencias (2/7)

- [7] LeCun, Y., Bengio, Y., Hinton, G. (2015). **Deep learning**. *Nature* 521, 436–444. doi:10.1038/nature14539
- [8] He, K., Zhang, X., Ren, S., Sun, J. (2016). **Deep residual learning for image recognition**. *CVPR 2016*, 770–778. doi:10.1109/CVPR.2016.90
- [9] Holm, E. A., Cohn, R., Gao, N., et al. (2020). **Overview: Computer vision and machine learning for microstructural characterization and analysis**. *Metall. Mater. Trans. A* 51, 5985–5999. doi:10.1007/s11661-020-06008-4
- [10] DeCost, B. L., Holm, E. A. (2015). **A computer vision approach for automated analysis and classification of microstructural image data**. *Comput. Mater. Sci.* 110, 126–133. doi:10.1016/j.commatsci.2015.08.011
- [11] Aversa, R., Modarres, M. H., Cozzini, S., Ciano, R., Chiusole, A. (2018). **The first annotated set of scanning electron microscopy images for nanoscience**. *Sci. Data* 5, 180172. doi:10.1038/sdata.2018.172
- [12] Modarres, M. H., Aversa, R., Cozzini, S., et al. (2017). **Neural network for nanoscience scanning electron microscope image recognition**. *Sci. Rep.* 7, 13282. doi:10.1038/s41598-017-13565-z

Referencias (3/7)

- [13] Park, W. B., Chung, J., Jung, J., et al. (2017). **Classification of crystal structure using a convolutional neural network.** *IUCrJ* 4, 486–494. doi:10.1107/S205225251700714X
- [14] Oviedo, F., Ren, Z., Sun, S., et al. (2019). **Fast and interpretable classification of small X-ray diffraction datasets using data augmentation and deep neural networks.** *npj Comput. Mater.* 5, 60. doi:10.1038/s41524-019-0196-x
- [15] Lee, J.-W., Park, W. B., Lee, J. H., Singh, S. P., Sohn, K.-S. (2020). **A deep-learning technique for phase identification in multiphase inorganic compounds using synthetic XRD powder patterns.** *Nat. Commun.* 11, 86. doi:10.1038/s41467-019-13749-3
- [16] Szymanski, N. J., Bartel, C. J., Zeng, Y., Tu, Q., Ceder, G. (2021). **Probabilistic deep learning approach to automate the interpretation of multi-phase diffraction spectra.** *Chem. Mater.* 33, 4204–4215. doi:10.1021/acs.chemmater.1c01071
- [17] Hollarek, D., Schopmans, H., Östreicher, J., et al. (2025). **opXRD: Open experimental powder X-ray diffraction database.** *Adv. Intell. Discov.* 2, e202500044. doi:10.1002/aidi.202500044
- [18] Liu, J., Osadchy, M., Ashton, L., et al. (2017). **Deep convolutional neural networks for Raman spectrum recognition: a unified solution.** *Analyst* 142, 4067–4074. doi:10.1039/C7AN01371J

Referencias (4/7)

- [19] Ziatdinov, M., Dyck, O., Maksov, A., et al. (2017). **Deep learning of atomically resolved scanning transmission electron microscopy images: chemical identification and tracking local transformations.** *ACS Nano* 11, 12742–12752. doi:10.1021/acsnano.7b07504
- [20] Stuckner, J., Harder, B., Smith, T. M. (2022). **Microstructure segmentation with deep learning encoders pre-trained on a large microscopy dataset.** *npj Comput. Mater.* 8, 200. doi:10.1038/s41524-022-00878-5
- [21] Dunn, A., Wang, Q., Ganose, A., Dopp, D., Jain, A. (2020). **Benchmarking materials property prediction methods: the Matbench test set and Automatminer reference algorithm.** *npj Comput. Mater.* 6, 138. doi:10.1038/s41524-020-00406-3
- [22] Xie, T., Grossman, J. C. (2018). **Crystal graph convolutional neural networks for an accurate and interpretable prediction of material properties.** *Phys. Rev. Lett.* 120, 145301. doi:10.1103/PhysRevLett.120.145301
- [23] Yang, H., Hu, C., Zhou, Y., et al. (2024). **MatterSim: A deep learning atomistic model across elements, temperatures and pressures.** *preprint.* arXiv:2405.04967
- [24] Chen, C., Ong, S. P. (2022). **A universal graph deep learning interatomic potential for the periodic table.** *Nat. Comput. Sci.* 2, 718–728. doi:10.1038/s43588-022-00349-3

Referencias (5/7)

- [25] Davies, D. W., Butler, K. T., Jackson, A. J., et al. (2019). **SMACT: Semiconducting Materials by Analogy and Chemical Theory**. *J. Open Source Softw.* 4, 1361. doi:10.21105/joss.01361
- [26] Sanchez-Lengeling, B., Aspuru-Guzik, A. (2018). **Inverse molecular design using machine learning: Generative models for matter engineering**. *Science* 361, 360–365. doi:10.1126/science.aat2663
- [27] Zunger, A. (2018). **Inverse design in search of materials with target functionalities**. *Nat. Rev. Chem.* 2, 0121. doi:10.1038/s41570-018-0121
- [28] Sun, W., Dacek, S. T., Ong, S. P., et al. (2016). **The thermodynamic scale of inorganic crystalline metastability**. *Science Advances* 2, e1600225. doi:10.1126/sciadv.1600225
- [29] Ong, S. P., Richards, W. D., Jain, A., et al. (2013). **Python Materials Genomics (pymatgen): A robust, open-source python library for materials analysis**. *Comput. Mater. Sci.* 68, 314–319. doi:10.1016/j.commatsci.2012.10.028
- [30] Aykol, M., Dwaraknath, S. S., Sun, W., Persson, K. A. (2018). **Thermodynamic limit for synthesis of metastable inorganic materials**. *Sci. Adv.* 4, eaq0148. doi:10.1126/sciadv.aq0148

Referencias (6/7)

- [31] Leeman, J., Liu, Y., Stiles, J., et al. (2024). **Challenges in high-throughput inorganic materials prediction and autonomous synthesis.** *PRX Energy* 3, 011002. doi:10.1103/PRXEnergy.3.011002
- [32] Cowger, W., Steinmetz, Z., Gray, A., et al. (2021). **Microplastic spectral classification needs an open source community: Open Specy to the rescue!.** *Anal. Chem.* 93, 7543–7548. doi:10.1021/acs.analchem.1c00123
- [33] Hufnagl, B., Steiner, D., Renner, E., et al. (2019). **A methodology for the fast identification and monitoring of microplastics in environmental samples using random decision forest classifiers.** *Anal. Methods* 11, 2277–2285. doi:10.1039/C9AY00252A
- [34] Chen, C., Ong, S. P. (2022). **A universal graph deep learning interatomic potential for the periodic table (versión arXiv, CC BY 4.0).** *arXiv:2202.02450*
- [35] Lundberg, S. M., Lee, S.-I. (2017). **A unified approach to interpreting model predictions.** *NeurIPS* 30. arXiv:1705.07874
- [36] Batatia, I., Benner, P., Chiang, Y., et al. (2023). **A foundation model for atomistic materials chemistry.** *preprint.* arXiv:2401.00096

Referencias (7/7)

[37] Song, K., Yan, Y. (2013). **A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defects.** *Appl. Surf. Sci.* 285, 858–864. doi:10.1016/j.apsusc.2013.09.002

[38] Park, S. (s. f.). **NEU-DET classification (dataset, versión 1, CC BY 4.0).** *Roboflow Universe*. universe.roboflow.com/park-sung-ho/neu-det-classification



¡Gracias!

Tomás Rojas Solórzano
Universidad de Costa Rica · tomas.rojas_s@ucr.ac.cr