



DÍA 4 • JUEVES 08:00 - 13:00

Diseño de experimentos y optimización bayesiana

¿Qué experimento conviene hacer a continuación?

El plan de hoy

Hora	Bloque	Actividad
08:00	T4.1	Recap del Día 3 y solución del ejercicio
08:10	T4.3	Diseño de experimentos esencial (LHS, Box-Behnken) con demo
08:35	T4.4	Optimización bayesiana: procesos gaussianos, EI/UCB, laboratorios autónomos
09:15	P4.2	BO sobre Hartmann 6D: BO vs búsqueda aleatoria
10:00		Receso
10:30	LAN	Capacidades experimentales del LANOTEC
12:30	P4.3	Campaña guiada de optimización de un proceso
12:55		Cierre: retos para casa y conexión con el Día 5

Términos **DoE**: diseño de experimentos: elegir de antemano qué combinaciones medir · **Latín Hypercube (LHS)**: muestreo que usa una vez cada intervalo de cada variable · **Box-Behnken**: diseño de 3 niveles que ajusta una superficie cuadrática sin ir a las esquinas · **Optimización bayesiana (BO)**: ciclo: modelo con incertidumbre → elegir experimento → medir → repetir · **Proceso gaussiano (GP)**: modelo que da una predicción y su incertidumbre en cada punto · **Expected Improvement (EI)**: cuánto se espera mejorar sobre el mejor resultado actual · **UCB**: media + β -incertidumbre: apuesta por el lado optimista · **Laboratorio autónomo**: robots y algoritmos que sintetizan, miden y deciden en ciclo · **Hartmann 6D**: función de prueba de 6 variables con óptimo conocido (3.322) · **LANOTEC**: Laboratorio Nacional de Nanotecnología del CeNAT



T4.1 • 10 min

Recap del Día 3

Solución del ejercicio Si-O-N

Si-O-N: del lote generado a la lista corta

20

estructuras generadas condicionadas a Si-O-N

16

con distancia mínima $> 1.2 \text{ \AA}$

2

pasan balance de carga (SMACT)

- Una de las que sobreviven es $\text{Si}_2\text{N}_2\text{O}$: existe en la naturaleza (sinoita). El modelo "redescubrió" una fase conocida.
- Para elegir las 3 mejores: simetría alta (XRD más clara), estequiometría cercana a fases conocidas y rutas de síntesis disponibles (nitruración, sol-gel).

Idea clave Hoy la pregunta cambia: de "¿qué material?" a "¿qué condiciones de proceso?", con presupuesto limitado.

Términos **Generación condicionada:** pedirle al generador una propiedad, química o simetría · **Balance de carga:** las cargas de cationes y aniones suman cero · **SMACT:** filtro químico de balance de carga y electronegatividad · **XRD:** difracción de rayos X: picos que revelan la red cristalina · **Estequiometría:** proporción de los elementos en la fórmula · **Nitruración:** tratamiento que incorpora nitrógeno en la superficie de un metal



T4.3 • 25 min

Diseño de experimentos esencial

Dónde poner los primeros experimentos cuando todavía no sabemos nada



Centro Nacional de Alta Tecnología



PREGUNTA PARA EL GRUPO

Su proceso tiene dos variables: temperatura y presión de N₂. ¿Cómo encontrarían la mejor combinación?

A Fijo la presión, barro la temperatura; luego fijo esa temperatura y barro la presión

B Pruebo combinaciones de ambas a la vez, repartidas en todo el rango

C Le pregunto al técnico con más experiencia

Respondan en el chat · 1 minuto

El vocabulario del diseño de experimentos

Con un ejemplo: un recubrimiento PVD cuya dureza queremos maximizar

Palabra	Qué es	En el ejemplo
Factor	Una variable que controlamos	Temperatura y presión de N ₂
Nivel	Un valor que le damos a un factor	300 °C (bajo) y 500 °C (alto)
Respuesta	Lo que medimos	Dureza en GPa
Corrida	Un experimento con una combinación de niveles	500 °C y 1.5 Pa
Efecto	Cuánto cambia la respuesta al pasar un factor de bajo a alto	Subir la temperatura suma 4.5 GPa en promedio
Interacción	El efecto de un factor depende del nivel de otro	Subir la temperatura ayuda mucho más con presión alta


Idea clave El diseño de experimentos decide qué corridas hacer para medir efectos e interacciones con el menor costo.

Interacción en cuatro experimentos

- Con presión baja, subir la temperatura suma solo 1 GPa.
- Con presión alta, subir la temperatura suma 8 GPa.

Eso es una interacción: el efecto de la temperatura depende de la presión.

Un factor a la vez (flechas): como la temperatura "casi no importa", la dejo baja y solo muevo la presión. Termino en 22 y nunca veo el 30.




Idea clave Con una sola corrida más que el camino de un factor a la vez, las cuatro combinaciones sí encuentran el 30.

Términos **Interacción:** el efecto de un factor depende del valor de otro · **GPa:** gigapascal, unidad de presión y de módulo elástico · **OFAT:** variar un factor a la vez; no ve interacciones

Un factor a la vez puede quedarse corto

- Si las variables interactúan (la mejor temperatura depende de la presión), el óptimo está en una cresta inclinada.
- Moviendo un factor a la vez se llega a un punto que parece óptimo en cada dirección, pero no lo es.
- En este esquema, 20 corridas de un factor a la vez terminan en 0.22; con las mismas 20 corridas, un Latin Hypercube llega a 0.96. El óptimo vale 1.



Idea clave El diseño de experimentos varía varios factores a la vez para ver interacciones con pocas corridas.

Términos **Factor, nivel y respuesta:** variable que se controla, el valor que toma y lo que se mide

Fuente: Czitrom (1999)

Por qué no variar un factor a la vez



Un factor a la vez

- Fija todo y mueve una variable; luego la siguiente
- Intuitivo, pero no ve interacciones
- Puede quedarse en un óptimo falso



Diseño de experimentos

- Varía varios factores a la vez de forma planificada
- Estima efectos e interacciones con menos corridas
- Base estadística para decidir qué importa

Idea clave El DoE clásico y la optimización bayesiana no compiten: el primero inicia la campaña, la segunda la continúa.

Fuente: Czitrom (1999)

Leer un factorial 2^2 : tres números con cuatro corridas

Con la tabla anterior: 20 y 22 a temperatura baja; 21 y 30 a temperatura alta



Efecto de la temperatura

- Promedio con T alta – promedio con T baja
- $(21 + 30)/2 - (20 + 22)/2 = 4.5$ GPa



Efecto de la presión

- Promedio con P alta – promedio con P baja
- $(22 + 30)/2 - (20 + 21)/2 = 5.5$ GPa



Interacción T × P

- Cuánto cambia el efecto de T al cambiar P
- $[(30 - 22) - (21 - 20)] / 2 = 3.5$ GPa

Idea clave Cada corrida entra en los tres cálculos: por eso el factorial es eficiente. Con 2 factores son 4 corridas; con K factores, 2 elevado a K.

Términos **Factorial completo**: probar todas las combinaciones de niveles (2^k corridas)

Cada diseño responde una pregunta distinta (y cuesta distinto)

Número de experimentos según cuántas variables de proceso (factores) tenga


Diseño	Para qué sirve	4 variables	6 variables
Factorial completo 2 niveles	¿Qué efecto tiene cada factor y cuáles interactúan? Prueba solo bajo y alto	16	64
Factorial completo 3 niveles	Agrega un nivel medio para ver curvas; crece como 3 elevado a K	81	729
Plackett-Burman	Un colador: de muchas variables, ¿cuáles importan?	8	8
Box-Behnken (3 puntos centrales)	Ajusta una curva (parábola) para ubicar el máximo sin ir a los extremos	27	63
Latin Hypercube	Reparte los puntos parejo en todo el rango; arranque de la BO	usted elige	usted elige

Idea clave Con presupuesto de 50 experimentos y 6 variables, un factorial de 3 niveles es imposible; LHS + BO sí cabe.


Términos **Plackett-Burman:** diseño de cribado con pocas corridas para muchos factores

Fuente: Plackett y Burman (1946); Box y Behnken (1960); McKay et al. (1979)

Cómo se ven dos diseños con 3 factores



Factorial completo 2^3 : las 8 esquinas del cubo




Box-Behnken: centros de las aristas y punto central

Idea clave El factorial ve interacciones; el Box-Behnken agrega curvatura sin ir a las esquinas extremas.

Fuente: NIST/SEMATECH e-Handbook of Statistical Methods, secciones 5.3.3.3 y 5.3.3.6 (itl.nist.gov/div898/handbook), obra del gobierno de EE. UU.

Latin Hypercube: cada variable, bien muestreada



Idea clave Con 9 experimentos, el factorial solo prueba 3 valores de cada variable; el LHS prueba 9.

Fuente: McKay et al. (1979)

¿Qué diseño uso? Depende de la pregunta



¿Cuáles variables importan?

- Muchos factores (6 o más) y poco presupuesto
- Plackett-Burman o factorial fraccionado



¿Cómo responde el proceso?

- Pocos factores; quiero entender y validar
- Factorial completo o Box-Behnken



¿Dónde está lo mejor?

- Cada corrida es cara; quiero llegar al óptimo
- LHS para empezar y optimización bayesiana para seguir

Idea clave En una campaña real se combinan: cribar, entender y optimizar.

Del DoE de validación a la optimización bayesiana

Muchos de ustedes ya usan diseño de experimentos en su industria

Lo que ya se hace

- La guía de validación de procesos de la FDA recomienda estudios DoE para revelar relaciones, incluidas interacciones multivariantes, entre entradas y salidas
- Sus resultados justifican los rangos de operación (ventanas de proceso)
- En dispositivos médicos se usa para caracterizar el proceso y fijar puntos de operación antes de la calificación (OQ)

Lo que agrega la optimización bayesiana

- Decide el siguiente experimento con lo aprendido hasta ese momento
- Conviene cuando cada corrida es cara y el objetivo es llegar al óptimo
- En reacciones químicas reales superó a químicos e ingenieros expertos en número de experimentos y en consistencia

Idea clave DoE para entender y validar el proceso; optimización bayesiana para llegar al óptimo con menos corridas. Se complementan.

Términos **Validación:** comprobar el modelo con datos que no vio • **Validación de procesos (OQ):** demostrar que un proceso industrial opera dentro de su ventana

Fuente: FDA (2011); Michaels (2015); Shields et al. (2021)



T4.4 • 40 min

Optimización bayesiana

Un asistente que aprende de cada resultado y propone el siguiente experimento



PREGUNTA PARA EL GRUPO

Ya hicieron 5 experimentos de 8 horas y les quedan 15. ¿Cómo deciden cuál hacer mañana?

- A** Repito cerca del mejor resultado que tengo
- B** Pruebo en la zona que menos conozco
- C** Depende: necesito algo que combine las dos cosas

Respondan en el chat · 1 minuto

Explotar o explorar

Como elegir restaurante: ¿el de siempre o uno nuevo?

Explotar

- Repetir cerca del mejor resultado
- Mejora poco a poco y con seguridad
- Riesgo: quedarse en un máximo local

Explorar

- Probar donde casi no hay datos
- Puede descubrir algo mucho mejor
- Riesgo: gastar experimentos en zonas malas

Idea clave La optimización bayesiana es una regla explícita para decidir, en cada paso, cuánto explotar y cuánto explorar.

Términos **Explorar y explotar**: medir donde se sabe poco o refinar cerca de lo mejor conocido

¿Por qué un modelo sustituto?

El experimento real

- 8 horas de cámara PVD y unos \$500 por punto
- Solo vemos el resultado donde medimos
- No podemos probar 10 000 condiciones para ver cuál es mejor


El modelo sustituto

- Milisegundos por predicción
- Se evalúa en miles de condiciones para elegir la siguiente
- Debe decir cuánto confía en cada predicción: ahí entra el proceso gaussiano

Idea clave Gastamos cómputo barato para ahorrar experimentos caros.

Términos **Modelo sustituto:** modelo barato que imita al experimento caro · **PVD:** deposición física de vapor: se pulveriza un blanco y se deposita una película

La optimización bayesiana en cuatro pasos





- Se repite hasta agotar el presupuesto o alcanzar la meta.
- Funciona mejor cuando cada evaluación es cara y hay pocas variables ($\lesssim 10-20$).

Términos **Función de adquisición:** puntúa cada condición según cuánto conviene medirla

Fuente: Jones et al. (1998); Shahriari et al. (2016); Frazier (2018)

Paso 2: una predicción y una banda de duda

Línea = mejor estimación del modelo; banda = cuánto duda. Cerca de los datos duda poco




Idea clave Cerca de los datos la banda se cierra; lejos de ellos sigue ancha. Esa incertidumbre es la que usamos para decidir.

Términos **Incertidumbre:** rango de valores plausibles alrededor de una predicción

Fuente: Rasmussen y Williams (2006)

Antes de medir, el modelo no sabe nada


- Antes de tener datos, el modelo acepta cualquier curva suave: cada línea morada es una posibilidad.
- Las líneas moradas son funciones que el modelo considera plausibles.
- La banda ($\pm 2\sigma$) es igual de ancha en todo el rango: todavía no sabemos nada.



Fuente: Rasmussen y Williams (2006)

El kernel: hasta dónde llega la influencia de un experimento

Si dos condiciones están cerca, sus resultados se parecen. La longitud de correlación dice qué tan cerca es "cerca"



Idea clave La longitud de correlación se ajusta a los datos (`fit_gpytorch_mll`); no hay que elegirla a mano, pero conviene saber qué significa.

Términos **Kernel:** en Jupyter, el proceso de Python que ejecuta las celdas; en un GP, la función que mide el parecido entre dos puntos • **Correlación:** qué tanto dos variables cambian juntas (de -1 a 1); no implica causa




PREGUNTA PARA EL GRUPO

Con estos 5 experimentos, ¿dónde harían el sexto?

A Justo al lado del mejor resultado

B Donde la incertidumbre es mayor

C En el borde del rango



Respondan en el chat · 1 minuto

Paso 3: un puntaje para cada condición

La función de adquisición se calcula en miles de condiciones en milisegundos; se mide la de mayor puntaje



Premia lo prometedor

- Media alta: el modelo cree que ahí el resultado es bueno
- Es explotar



Premia lo desconocido

- Banda ancha: ahí el modelo duda mucho
- Es explorar

Idea clave UCB y EI son dos recetas para combinar las dos cosas en un solo número.

Upper Confidence Bound: optimismo controlado


La idea: supongo que la realidad está en el borde de arriba de la banda y mido donde ese borde es más alto.

UCB(x) = $\mu + \sqrt{\beta} \sigma$: media más β veces la duda.

β pequeño: casi solo la media, explota (triángulo verde, cerca de A).

β grande: domina la incertidumbre, explora (triángulos naranja y morado, en B).

- Un solo parámetro, fácil de explicar a un jefe de planta.



Fuente: Srinivas et al. (2012)

Expected Improvement: cuánto espero mejorar


La pregunta: si mido aquí, ¿cuánto espero superar mi mejor resultado hasta ahora (f^*)?

El(x) = $(\mu - f^*) \Phi(z) + \sigma \phi(z)$, con $z = (\mu - f^*) / \sigma$.

Primer término: premia una media alta (explotar). Es negativo donde $\mu < f^*$.


Segundo término: premia la incertidumbre (explorar).

- Aquí El elige A por muy poco: B casi empata gracias a su incertidumbre.



Fuente: Jones et al. (1998)

El ciclo en acción, experimento a experimento



Idea clave Alterna: afina alrededor de lo bueno y, cuando ahí ya no espera mejorar, salta a la zona incierta. Con 11 experimentos llega al máximo (0.60).

Cuándo no conviene la optimización bayesiana



Demasiadas variables

Con más de 10 a 20 dimensiones el GP necesita muchos datos; primero criba con Plackett-Burman.



Evaluaciones baratas

Si cada punto cuesta un segundo, una cuadrícula o un algoritmo genético es más simple.



Quiere entender, no solo optimizar

Un Box-Behnken da coeficientes interpretables y efectos de cada factor.



Todo en paralelo

Si puede correr los 25 experimentos a la vez, la ventaja secuencial de BO desaparece.

Términos **Interpretabilidad**: entender qué usó un modelo para hacer sus predicciones


Un ciclo cerrado real: CAMEO

Decidir: aprendizaje activo que incorpora física.

Ejecutar: sintetizar, medir, simular o consultar a un experto.

Analizar: bases de datos y un modelo bayesiano que se actualiza con cada medición.

- Cada vuelta tarda de segundos a decenas de minutos; así encontraron un nuevo material para memorias de cambio de fase.



Términos Aprendizaje activo: el modelo elige qué dato medir después para aprender más rápido

Fuente: Fig. 1 de Kusne et al. (2020), Nat. Commun. 11, 5966, doi:10.1038/s41467-020-19597-w. Licencia CC BY 4.0

Laboratorios autónomos: la BO conectada a robots



Ada (2020)

Laboratorio autónomo que optimizó películas delgadas para transporte de huecos cerrando el ciclo síntesis-medición-BO.



Robot químico móvil (2020)

Un robot que se desplaza entre equipos y ejecutó cientos de experimentos de fotocátalisis guiado por BO.



CAMEO (2020)

BO en tiempo real en un sincrotrón: descubrió un nuevo material para memorias de cambio de fase.




A-Lab (2023)

Síntesis autónoma de polvos inorgánicos: 41 de 58 compuestos objetivo en 17 días.

Términos **Película delgada:** capa de nanómetros a micrómetros depositada sobre un sustrato · **Fotocátalisis:** acelerar una reacción química usando luz · **Sincrotrón:** acelerador que produce rayos X muy intensos · **A-Lab:** laboratorio autónomo de Berkeley que sintetiza con robots

Fuente: MacLeod et al. (2020); Burger et al. (2020); Kusne et al. (2020); Szymanski et al. (2023)

El A-Lab por dentro



Cálculo (objetivos) → minería de texto (recetas) → síntesis robótica → difracción → análisis automático → nueva receta si falla

Fuente: Fig. 1 de Szymanski et al. (2023), Nature 624, 86–91, doi:10.1038/s41586-023-06734-w. Licencia CC BY 4.0

Qué falta y qué significa para ustedes



Lo que falta

- Estándares de datos y metadatos
- Equipos que hablen entre sí
- Definir el papel del investigador: quién decide la meta y quién audita



Para ustedes

- No hace falta un robot
- La misma BO sirve con un cuaderno de laboratorio y 20 experimentos
- Lo difícil es definir bien la variable a optimizar y sus rangos

Idea clave La BO es una forma de decidir, no una máquina: funciona igual con un técnico que con un robot.

Términos Metadatos: información sobre cómo se obtuvo un dato (equipo, condiciones, fecha)


Fuente: Stach et al. (2021); Abolhasani y Kumacheva (2023)

Varios objetivos: dureza y fricción

- Muchas veces no basta un número: el cliente quiere dureza alta y $\text{CoF} < 0.4$.

Frente de Pareto: condiciones que nadie mejora en los dos objetivos a la vez.

- En estos 200 experimentos el más duro (2844 HV) ya tiene CoF 0.34: la restricción no estorba.
- Opciones cuando sí estorba: penalizar el objetivo, modelar el CoF aparte o usar BO multiobjetivo.



Idea clave Antes de complicar el modelo, grafique los datos: a veces la restricción ya se cumple sola.


Términos **Coeficiente de fricción (CoF):** fuerza de fricción entre fuerza normal · **Frente de Pareto:** condiciones que ninguna otra mejora en todos los objetivos a la vez · **Dureza Vickers (HV):** dureza medida con un indentador piramidal de diamante

Empujar el frente de Pareto

Zona gris: lo que ya se conoce; su borde es el frente de los mejores materiales conocidos.

Borde azul: lo mejor que la física permitiría.

- MacLeod et al. usaron un laboratorio autónomo (Ada) para cerrar esa brecha en películas delgadas, con dos objetivos en conflicto.



Términos **Band gap:** brecha de energía entre bandas ocupadas y vacías; cero en metales

Fuente: Fig. 1 de MacLeod et al. (2022), Nat. Commun. 13, 995, doi:10.1038/s41467-022-28580-6. Licencia CC BY 4.0



PREGUNTA PARA EL GRUPO

Hartmann 6D tiene 6 variables y un óptimo conocido. Con 40 evaluaciones, ¿qué tan cerca llega la búsqueda al azar?

A Más del 90 % del óptimo


B Entre 60 % y 90 %

C Menos del 60 %

Respondan en el chat · 1 minuto

Hartmann 6D: BO frente a lanzar dardos

- Función de prueba con 6 variables, varios máximos locales y óptimo conocido (3.322).
- 10 puntos iniciales + 30 iteraciones de BO, con 3 semillas distintas.
- BO supera claramente la mediana aleatoria, pero el resultado final depende de la semilla (en nuestras pruebas, entre 2.7 y 3.2): puede quedar atrapada en un máximo local.



Idea clave Compare distribuciones, no una sola corrida: tanto BO como el azar tienen suerte o mala suerte.

Términos **Semilla aleatoria**: número que fija el azar para poder repetir un resultado



PRÁCTICA • 70 min

Notebook 04: DoE y optimización bayesiana

Demo pyDOE3 • P4.2 Hartmann 6D • P4.3 campaña de proceso

Notebook: documento con celdas de código y texto que se ejecutan en orden • **pyDOE3:** biblioteca de Python para diseños de experimentos



CeNAT
Centro Nacional de Alta Tecnología

Python del día (1): un diseño LHS en unidades reales

```
from pyDOE3 import lhs
X01 = lhs(4, samples=20, criterion="maximin", seed=42) # en [0,1]

var_min = np.array([300, 0.3, -200, 0.5]) # T, P_N2, bias, flujo
var_max = np.array([550, 1.5, -50, 2.0])
X_real = X01 * (var_max - var_min) + var_min
```

maximin: entre muchos LHS posibles, elige el que maximiza la distancia mínima entre puntos.

Escalar: LHS trabaja en [0, 1]; una multiplicación y una suma lo llevan a °C, Pa y V.

seed: fija el azar (la versión nueva de pyDOE3 usa seed en vez de random_state).

Términos **Python:** lenguaje de programación usado en el curso · **Bias:** voltaje aplicado al sustrato que controla la energía de los iones

En la práctica



Escalar

- Entradas en $[0, 1]$
- Salidas estandarizadas (Standardize)
- Sin esto el GP ajusta mal



LogEI en vez de EI

Mismo punto elegido, pero no se "apaga" numéricamente cuando EI es diminuta (botorch lo recomienda).



Lotes ($q > 1$)

Si el horno admite 3 muestras, se piden 3 condiciones distintas de forma conjunta (qLogEI, qUCB). Repetir 3 veces el máximo de EI da 3 veces el mismo punto.



Ruido

Las réplicas cuentan: el GP estima el ruido de medición y no persigue diferencias menores que él.

Términos **BoTorch**: biblioteca de optimización bayesiana sobre PyTorch · **Réplicas**: repeticiones del mismo experimento para medir el ruido

Fuente: Balandat et al. (2020); Ament et al. (2023)

Python del día (2): el ciclo de BO en 10 líneas

```
for i in range(N_ITER):
    gp = SingleTaskGP(train_X, train_Y,
                      outcome_transform=Standardize(m=1))
    fit_gpytorch_mll(ExactMarginalLogLikelihood(gp.likelihood, gp))

    EI = LogExpectedImprovement(gp, best_f=train_Y.max())
    cand, _ = optimize_acqf(EI, bounds=BOUNDS, q=1,
                           num_restarts=5, raw_samples=64)

    new_y = experimento(cand)                # oráculo o laboratorio
    train_X = torch.cat([train_X, cand])
    train_Y = torch.cat([train_Y, new_y])
```

Tensores double: botorch trabaja en torch con dtype=torch.double; los datos van en [0, 1].

Standardize: pone la respuesta en media 0 y varianza 1 para que el GP ajuste bien.

LogEI: logaritmo de EI; elige el mismo punto pero es numéricamente más estable.

optimize_acqf: busca el máximo de la adquisición: evalúa muchos puntos al azar (raw_samples) y refina los mejores (num_restarts).

torch.cat: agrega el nuevo experimento a los datos y el ciclo vuelve a empezar.

Términos **Verosimilitud (likelihood):** qué tan probables son los datos dado el modelo · **Oráculo:** fuente de la respuesta 'verdadera'; en P4.3, un modelo que hace de laboratorio · **PyTorch:** biblioteca de Python para redes neuronales · **Varianza y desviación estándar:** medidas de dispersión de los datos alrededor del promedio

P4.3: una campaña de proceso con un laboratorio simulado



El histórico

200 experimentos PVD sintéticos de (Ti,Al)N: temperatura, presión de N₂, bias, relación Ti/Al → dureza, CoF.



El oráculo

Un interpolador (RBF) construido con el histórico "juega a ser el laboratorio": cada consulta simula un experimento de 8 horas.



La campaña

Arrancamos desde 5 experimentos mediocres y damos a BO 20 experimentos nuevos; comparamos con 10 campañas aleatorias.



Honestidad


En este oráculo el azar también llega lejos (~96 % del máximo); la diferencia está en los últimos puntos, cerca del óptimo.

Idea clave Mida el éxito como "experimentos necesarios para llegar al 98–99 % del máximo", no solo el valor final.

Términos **Datos sintéticos:** generados por simulación o con un modelo, no medidos · **RBF:** interpolador con funciones radiales; en P4.3 hace de laboratorio

El producto detrás de los datos

- Una fresa de carburo de tungsteno con recubrimiento TiAlN en la parte de trabajo, depositado por pulverización magnetrónica (HiPIMS).
- Las marcas A, B y C son los puntos donde los autores tomaron muestras para analizar el recubrimiento.
- Dureza, adherencia y fricción de esa capa son lo que optimiza la campaña P4.3 (con datos sintéticos).



Términos **HiPIMS:** pulverización magnetrónica por impulsos de alta potencia

Fuente: Fig. 1 de Michna et al. (2021), *Materials* 14, 3633, doi:10.3390/ma14133633. Licencia CC BY 4.0

Retos y ejercicio para casa



Retos en clase

- R1: experimentos de cada diseño con 6 variables; ¿cuál elige con 50 de presupuesto?
- R2: BO con solo 3 puntos iniciales y 3 semillas: ¿qué pasa con la variabilidad?
- R3: agregue la condición $\text{CoF} < 0.4$



Para casa

- Repita la campaña PVD con UCB ($\beta = 2$)
- ¿En qué experimento alcanza cada método el 99 % del máximo?
- Grafique los puntos evaluados en el plano T-P: ¿cómo explora cada uno?

Idea clave Mañana no hay contenido nuevo: ponen todo junto en un reto en equipo.

Referencias (1/5)

- [1] Czitrom, V. (1999). **One-factor-at-a-time versus designed experiments.** *Am. Stat.* 53, 126–131. doi:10.1080/00031305.1999.10474445
- [2] Plackett, R. L., Burman, J. P. (1946). **The design of optimum multifactorial experiments.** *Biometrika* 33, 305–325. doi:10.1093/biomet/33.4.305
- [3] Box, G. E. P., Behnken, D. W. (1960). **Some new three level designs for the study of quantitative variables.** *Technometrics* 2, 455–475. doi:10.1080/00401706.1960.10489912
- [4] McKay, M. D., Beckman, R. J., Conover, W. J. (1979). **A comparison of three methods for selecting values of input variables in the analysis of output from a computer code.** *Technometrics* 21, 239–245. doi:10.1080/00401706.1979.10489755
- [5] Jones, D. R., Schonlau, M., Welch, W. J. (1998). **Efficient global optimization of expensive black-box functions.** *J. Global Optim.* 13, 455–492. doi:10.1023/A:1008306431147
- [6] Srinivas, N., Krause, A., Kakade, S. M., Seeger, M. W. (2012). **Information-theoretic regret bounds for Gaussian process optimization in the bandit setting.** *IEEE Trans. Inf. Theory* 58, 3250–3265. doi:10.1109/TIT.2011.2182033

Referencias (2/5)

- [7] Ament, S., Daulton, S., Eriksson, D., et al. (2023). **Unexpected improvements to expected improvement for Bayesian optimization.** *NeurIPS* 36. [arXiv:2310.20708](#)
- [8] Shahriari, B., Swersky, K., Wang, Z., Adams, R. P., de Freitas, N. (2016). **Taking the human out of the loop: A review of Bayesian optimization.** *Proc. IEEE* 104, 148–175. [doi:10.1109/JPROC.2015.2494218](#)
- [9] Frazier, P. I. (2018). **A tutorial on Bayesian optimization.** *preprint*. [arXiv:1807.02811](#)
- [10] Rasmussen, C. E., Williams, C. K. I. (2006). **Gaussian Processes for Machine Learning.** *MIT Press*
- [11] Balandat, M., Karrer, B., Jiang, D. R., et al. (2020). **BoTorch: A framework for efficient Monte-Carlo Bayesian optimization.** *NeurIPS* 33. [arXiv:1910.06403](#)
- [12] Lookman, T., Balachandran, P. V., Xue, D., Yuan, R. (2019). **Active learning in materials science with emphasis on adaptive sampling using uncertainties for targeted design.** *npj Comput. Mater.* 5, 21. [doi:10.1038/s41524-019-0153-8](#)

Referencias (3/5)

- [13] Wang, A., Liang, H., McDannald, A., Takeuchi, I., Kusne, A. G. (2022). **Benchmarking active learning strategies for materials optimization and discovery.** *Oxford Open Mater. Sci.* 2, itac006. doi:10.1093/oxfmat/itac006
- [14] Kusne, A. G., Yu, H., Wu, C., et al. (2020). **On-the-fly closed-loop materials discovery via Bayesian active learning.** *Nat. Commun.* 11, 5966. doi:10.1038/s41467-020-19597-w
- [15] MacLeod, B. P., Parlane, F. G. L., et al. (2020). **Self-driving laboratory for accelerated discovery of thin-film materials.** *Science Advances* 6, eaaz8867. doi:10.1126/sciadv.aaz8867
- [16] Burger, B., Maffettone, P. M., Gusev, V. V., et al. (2020). **A mobile robotic chemist.** *Nature* 583, 237–241. doi:10.1038/s41586-020-2442-2
- [17] Szymanski, N. J., Rendy, B., Fei, Y., et al. (2023). **An autonomous laboratory for the accelerated synthesis of novel materials.** *Nature* 624, 86–91. doi:10.1038/s41586-023-06734-w
- [18] Stach, E., DeCost, B., Kusne, A. G., et al. (2021). **Autonomous experimentation systems for materials development: A community perspective.** *Matter* 4, 2702–2726. doi:10.1016/j.matt.2021.06.036

Referencias (4/5)

- [19] Abolhasani, M., Kumacheva, E. (2023). **The rise of self-driving labs in chemical and materials sciences.** *Nature Synthesis* 2, 483–492.
doi:10.1038/s44160-022-00231-0
- [20] Häse, F., Roch, L. M., Kreisbeck, C., Aspuru-Guzik, A. (2018). **Phoenix: A Bayesian optimizer for chemistry.** *ACS Cent. Sci.* 4, 1134–1145.
doi:10.1021/acscentsci.8b00307
- [21] PalDey, S., Deevi, S. C. (2003). **Single layer and multilayer wear resistant coatings of (Ti,Al)N: a review.** *Mater. Sci. Eng. A* 342, 58–79.
doi:10.1016/S0921-5093(02)00259-9
- [22] U.S. Food and Drug Administration (2011). **Process validation: General principles and practices. Guidance for industry, Rev. 1.**
fda.gov/media/71021/download
- [23] Michaels, B. (2015). **Validate your process using design of experiments.** *MD+DI (Medical Device and Diagnostic Industry)*, 27 de enero
- [24] Shields, B. J., Stevens, J., Li, J., et al. (2021). **Bayesian reaction optimization as a tool for chemical synthesis.** *Nature* 590, 89–96.
doi:10.1038/s41586-021-03213-y

Referencias (5/5)

[25] NIST/SEMATECH (2012). **e-Handbook of Statistical Methods, cap. 5: Process Improvement.** *itl.nist.gov/div898/handbook*. doi:10.18434/M32189

[26] MacLeod, B. P., Parlane, F. G. L., Rupnow, C. C., Dettelbach, K. E., et al. (2022). **A self-driving laboratory advances the Pareto front for material properties.** *Nat. Commun.* 13, 995. doi:10.1038/s41467-022-28580-6

[27] Michna, Š., Hren, I., Novotný, J., Michnová, L., Švorčík, V. (2021). **Comprehensive research and analysis of a coated machining tool with a new TiAlN composite microlayer using magnetron sputtering.** *Materials* 14, 3633. doi:10.3390/ma14133633

[28] Leeman, J., Liu, Y., Stiles, J., et al. (2024). **Challenges in high-throughput inorganic materials prediction and autonomous synthesis.** *PRX Energy* 3, 011002. doi:10.1103/PRXEnergy.3.011002



¡Gracias!

Tomás Rojas Solórzano
Universidad de Costa Rica · tomas.rojas_s@ucr.ac.cr