



DÍA 5 • VIERNES 08:00 - 12:00

Cierre, más allá del curso y mini-reto final

Terminar lo pendiente, ver qué otros datos existen y poner todo junto en un reto

El plan de hoy

Hora	Bloque	Actividad
08:00	Repaso	Lo que construimos en cuatro días
08:10	P4.3	Cierre de la optimización bayesiana: campaña PVD (notebook 04)
08:35	P3.5b	Visión pendiente: SEM y un dataset de Roboflow (notebook 06)
09:00	07	Más allá del curso: otros datasets (notebook 07)
09:20	T5.4 · T5.6	Small data, perspectivas y presentación de los briefs
09:35		Receso
09:45	RETO	Mini-reto en equipos (90 min)
11:15		Presentaciones por equipo (5 min; 3 min si son más de 7 equipos)
11:50	T5.7	Cierre: perspectivas, recursos, colaboración, tarea y encuesta

Términos **Optimización bayesiana (BO)**: ciclo: modelo con incertidumbre → elegir experimento → medir → repetir · **PVD**: deposición física de vapor: se pulveriza un blanco y se deposita una película · **Notebook**: documento con celdas de código y texto que se ejecutan en orden · **SEM y TEM**: microscopía electrónica de barrido y de transmisión · **Pocos datos (small data)**: decenas o pocos cientos de experimentos; piden modelos simples con incertidumbre



T5.1 • 10 min

Repaso

El mapa completo del curso

Lo que construimos en cuatro días



- Hoy cerramos lo pendiente (BO y visión), vemos qué otros datos existen y luego toca elegir herramienta y defender la decisión.

Términos **Descriptor (feature)**: número que describe un material y que el modelo usa como entrada · **Random Forest**: promedio de muchos árboles de decisión entrenados al azar · **MAE**: error absoluto medio, en las unidades de la propiedad · **GPa**: gigapascal, unidad de presión y de módulo elástico · **Screening**: evaluar con un modelo rápido muchos candidatos y quedarse con los mejores · **MatterGen**: modelo de difusión de Microsoft que genera cristales · **GPU**: procesador gráfico; acelera el entrenamiento y uso de redes neuronales · **Kabré**: supercomputadora del CNCA · **DoE**: diseño de experimentos: elegir de antemano qué combinaciones medir



P4.3 • 25 min

Cierre de la optimización bayesiana

La campaña PVD del notebook 04, celdas [12] a [17]

Celda: en un cristal, la celda unitaria: bloque mínimo que se repite (a , b , c , α , β , γ); en un notebook, un bloque de código

La campaña PVD, celda por celda

Notebook 04: corran de arriba hacia abajo con el kernel Python-AI-Materials

Celda	Qué hace	Qué deben ver
[12]	Lee 200 experimentos históricos de (Ti,Al)N	4 perillas y 4 resultados; dureza máxima 2844 HV
[13]	Construye el oráculo: el laboratorio de mentira	Nada impreso
[14]	Parte de 5 recetas de la mitad peor y hace 20 experimentos con BO	Punto de partida 2351 HV y la barra que sube
[15]	Repite 20 recetas al azar, 10 veces	Azar: mediana 2741 HV (96 %); 1 de 10 llega al 98 %
[16]	Grafica BO contra la banda del azar	En qué experimento la curva cruza el 98 %
[17]	Traduce la mejor receta a unidades reales	°C, Pa, V y flujo: lo que se lleva al laboratorio

Idea clave Es el mismo ciclo de Hartmann (celda [8]); solo cambió el laboratorio.

Términos **Kernel:** en Jupyter, el proceso de Python que ejecuta las celdas; en un GP, la función que mide el parecido entre dos puntos · **Python:** lenguaje de programación usado en el curso · **Dureza Vickers (HV):** dureza medida con un indentador piramidal de diamante · **Oráculo:** fuente de la respuesta 'verdadera'; en P4.3, un modelo que hace de laboratorio · **Hartmann 6D:** función de prueba de 6 variables con óptimo conocido (3.322)

El oráculo no es el GP

Oráculo: el laboratorio

- Superficie suave que pasa por los 200 experimentos y rellena entre ellos
- Preguntarle es como hacer una corrida de 8 horas, en un milisegundo
- Es fijo: no aprende ni cambia
- BO no lo ve por dentro, solo le hace preguntas

GP: el cerebro de BO

- Solo sabe lo que BO ha medido: 5 recetas iniciales más las nuevas
- Da una predicción y una duda para cada receta
- Se vuelve a ajustar en cada vuelta
- El juez (EI o UCB) usa su predicción y su duda para elegir el siguiente experimento

Idea clave El oráculo hace de laboratorio; el GP es lo que BO va aprendiendo de él.

Términos **Proceso gaussiano (GP)**: modelo que da una predicción y su incertidumbre en cada punto · **Expected Improvement (EI)**: cuánto se espera mejorar sobre el mejor resultado actual · **UCB**: media + β ·incertidumbre: apuesta por el lado optimista

Solución del Día 4: LogEI vs UCB en la campaña PVD

Experimento en el que cada método alcanza una fracción del máximo histórico (2844 HV)

Meta	LogEI	UCB ($\beta = 2$)	Lectura
95 %	3	3	Demasiado fácil: el azar también llega rápido
98 %	5	5	Todavía empatados
99 %	6	16	UCB paga su exploración: tarda más en afinar el óptimo
Final	2837 HV	2835 HV	Diferencia pequeña en HV, grande en experimentos

Idea clave Los últimos puntos porcentuales son los caros: ahí se nota cuánto explora cada estrategia.



P3.5b • 25 min

Visión: lo que quedó pendiente

Micrografías SEM y un dataset de la comunidad

SEM con aprendizaje por transferencia

Notebook 06, celdas [10] a [14]

Celda	Qué hace	Qué preguntar
[10]	Carga 200 micrografías SEM de prueba en 10 categorías (base NFFA-Europe)	¿Qué categorías se parecen entre sí?
[11]	ResNet-18 aprendida con fotos cotidianas y ajustada con unas 3500 imágenes SEM	¿Qué confunde la matriz de confusión?
[12]	Muestra las imágenes mal clasificadas	¿Se equivoca el modelo o la etiqueta es discutible?
[13]	Proyecta a 2D los 512 números que la red calcula por imagen	¿Forman grupos las categorías?
[14]	Reto B: las 5 imágenes con menor confianza	¿Cuándo pedir la opinión de una persona?

Idea clave No hace falta entrenar desde cero: se reutiliza lo que la red ya sabe ver.

Términos **Aprendizaje por transferencia**: partir de una red ya entrenada y ajustarla con pocos datos propios · **opXRD y NFFA-Europe**: conjuntos abiertos de difractogramas y de imágenes SEM · **ImageNet y ResNet**: colección de 1.2 millones de fotos y la red entrenada con ella · **Matriz de confusión**: tabla de clase real contra clase predicha

Fuente: Aversa et al. (2018); Modarres et al. (2017); He et al. (2016)

Datasets etiquetados por la comunidad: Roboflow Universe

- Imágenes ya etiquetadas, cada dataset con su licencia y sus versiones (láminas 46 a 55 del Día 3).
- **Demo:** NEU-DET, acero laminado con 6 tipos de defecto, clasificado con la misma ResNet de SEM sin reentrenarla (final del notebook 06).
- Bajar un dataset pide una API key gratuita y personal: nunca se escribe en el notebook.
- Otros ejemplos de materiales: microestructuras de acero, nanopartículas, defectos de soldadura y corrosión.

Idea clave Antes de etiquetar sus propias imágenes, busquen si alguien ya lo hizo.

Términos API: interfaz para consultar una base de datos desde un programa

Fuente: Song y Yan (2013); Park, NEU-DET classification, Roboflow Universe



07 • 20 min

Más allá del curso

Otros datasets de materiales y cómo empezar con los suyos (notebook 07)

Datos calculados de cristales y comparación de modelos

Dataset	Qué trae	Cómo se accede
Materials Project	Estructuras, energías, gaps y elásticas (DFT)	API con key gratis (martes)
OQMD	Energías de formación y estabilidad (DFT)	Descarga completa o API
JARVIS-DFT (NIST)	Más de 80 000 materiales, incluye 2D	jarvis-tools; parte en matminer
Alexandria	Cristales relajados con PBE, PBEsol y SCAN; fonones	Descarga por bloques
NOMAD	Repositorio de cálculos de muchos códigos	Web y API
Matbench	13 tareas, de 312 a 132 752 muestras	Viene en matminer
Matbench Discovery	Ranking de modelos para encontrar cristales estables	Web

Términos **Materials Project:** base abierta de más de 150 000 materiales calculados con DFT · **Band gap:** brecha de energía entre bandas ocupadas y vacías; cero en metales · **DFT:** teoría del funcional de la densidad: cálculo cuántico de energía y electrones · **OQMD y AFLOW:** otras bases de cálculos DFT de alto rendimiento · **matminer:** biblioteca de Python con datasets y descriptores de materiales · **Relajación:** mover átomos y celda hasta que las fuerzas sean casi cero · **PBE:** aproximación de DFT más usada; subestima los band gaps · **Benchmark:** tarea de referencia para comparar modelos en las mismas condiciones

Fuente: Jain et al. (2013); Saal et al. (2013); Choudhary et al. (2020); Schmidt et al. (2023); Draxl y Scheffler (2019); Dunn et al. (2020); Riebesell et al. (2025)

Otras familias de materiales

Familia	Dataset	Qué trae
MOFs	QMOF	Más de 20 000 MOFs con propiedades DFT
Catálisis	Open Catalyst OC20	Adsorbatos sobre superficies (DFT)
Polímeros	PoLyInfo (NIMS)	Propiedades medidas de polímeros; registro gratis
Espectros	RRUFF	Minerales: Raman, IR, química y fotos
Espectros	Open Specy	Bibliotecas FTIR y Raman de plásticos
Micrografías	UHCSDB (NIST)	Micrografías de acero de ultra alto carbono
Micrografías	NEU-DET (Roboflow)	6 defectos en acero laminado
Medidos	matminer	expt_gap, steel_strength, glass, superconductivity2018...

Idea clave ¿Cuál de estas familias se parece más a lo que ustedes miden o fabrican?

Términos FTIR y Raman: espectroscopías vibracionales de las moléculas y enlaces

Fuente: Rosen et al. (2021); Chanussot et al. (2021); Otsuka et al. (2011); Lafuente et al. (2015); Cowger et al. (2021); DeCost et al. (2017); Song y Yan (2013); Ward et al. (2018)

El catálogo de matminer

Notebook 07, bloque 2: se lee sin internet

45

datasets listos para cargar con
load_dataset

16

con datos medidos en laboratorio (aprox.)

312 a 132 752


filas: lo medido es pequeño, lo calculado
es grande

- La función buscar("steel") del notebook filtra el catálogo por palabra: prueben glass, thermal, dielectric, perovskite.

Fuente: Ward et al. (2018); Dunn et al. (2020)

Demo: band gaps medidos con el pipeline del martes

- 4604 composiciones con su gap medido (matbench_expt_gap); el 53 % son metales.
- Mismo código del martes: composición, 132 descriptores Magpie y Random Forest.
- **Error medio:** 0.45 eV, contra 1.14 eV si se adivina siempre el promedio.
- La nube pegada al eje vertical: metales que el modelo cree semiconductores. Conviene clasificar primero metal o no metal.



Términos Pipeline: cadena de pasos automatizados de datos a resultado · **Magpie:** 132 descriptores de composición: 22 propiedades × 6 estadísticas · **eV:** electronvoltio, unidad de energía de los electrones · **Semiconductor:** material con gap pequeño, cuya conducción se controla

Fuente: Cálculo propio, notebook 07 corrido en Kabré (kura); datos de Zhuo et al. (2018) vía Matbench

Demo: resistencia de aceros y sus propios datos



matbench_steels (necesita internet)

- 312 aceros con su límite elástico medido
- Error medio 113 MPa; adivinar el promedio, 229 MPa
- La composición no sabe del tratamiento térmico ni del laminado



Antes de usar sus datos

- Una columna objetivo, con unidades
- ¿Cuántas filas? Pocas: modelos simples y BO
- ¿Medido o calculado?
- Misma fórmula repetida: GroupKFold
- Licencia y origen

Idea clave Todo lo de la semana funciona con otros datos; cambia de dónde salen y qué tan confiables son.

Fuente: Dunn et al. (2020); cálculo propio en Kabré

Notebooks para seguir aprendiendo

Dónde	Qué hay
Repositorio del curso en GitHub	Notebooks 00 a 07, soluciones, tareas y las presentaciones en PDF
Ejemplos de matminer (nbviewer)	Bajar datos, descriptores, visualizar, entrenar e interpretar
matbench.materialsproject.org	Cómo comparar un modelo con los publicados
Notebook 06, al final	Cómo bajar un dataset de Roboflow Universe
Notebook 05_brief_B	Plantilla para optimizar un proceso con pocos datos

Fuente: Ward et al. (2018); Dunn et al. (2020)




T5.4 • 10 min

Small data: la realidad experimental

Qué hacer cuando hay 35 experimentos y no 1181

Dónde vive el laboratorio real

- La curva de aprendizaje del Día 2: con 25 materiales el error es más del doble que con ~940.
- Un laboratorio típico tiene decenas a pocos cientos de experimentos por proceso.
- No se puede hacer todo lo que hicimos con datos de DFT: hay que cambiar de estrategia, no solo de modelo.



Fuente: Cálculo propio (RF + Magpie); Xu et al. (2023)

Estrategias para pocos datos



Conocimiento del dominio

Descriptores con física ($S^2\sigma/\kappa$), restricciones conocidas, rangos razonables. Vale más que 100 descriptores genéricos.



Modelos simples con incertidumbre

Procesos gaussianos, regresiones regularizadas. Evitar redes profundas con 35 puntos.



Validación honesta

Leave-one-out o validación cruzada repetida; nunca un solo split de 7 puntos.



Aprendizaje activo

Que el modelo proponga los próximos experimentos más informativos (Día 4).



Transferir

Preentrenar con datos calculados abundantes y ajustar con los experimentales.



Usar los fracasos


Los experimentos que "no funcionaron" también son datos: enseñan dónde no está el éxito.

Términos **Incetidumbre:** rango de valores plausibles alrededor de una predicción · **Regresión:** predecir un número (por ejemplo K en GPa) · **Validación:** comprobar el modelo con datos que no vio · **Validación cruzada:** entrenar k veces dejando cada parte de los datos una vez fuera · **Aprendizaje activo:** el modelo elige qué dato medir después para aprender más rápido

Fuente: Xu et al. (2023); Zhang y Ling (2018); Raccuglia et al. (2016); Lookman et al. (2019)

Un mapa de las estrategias para pocos datos

- **Del lado de los datos:** extraer de publicaciones, construir bases, cálculo de alto rendimiento.
- **Del lado del modelo:** algoritmos adecuados, aprendizaje con clases desbalanceadas, aprendizaje activo y por transferencia.
- La revisión de Xu et al. (2023) es un buen punto de partida para el mini-reto.



Términos Alto rendimiento: calcular o medir miles de materiales con un flujo automatizado

Fuente: Fig. 1 de Xu et al. (2023), *npj Comput. Mater.* 9, 42, doi:10.1038/s41524-023-01000-z. Licencia CC BY 4.0

Trampas comunes con pocos datos



Réplicas y fugas

Si una réplica queda en entrenamiento y su gemela en prueba, el error parece menor. Agrupe réplicas al validar.



Extrapolar

El GP puede recomendar condiciones fuera del rango histórico con mucha incertidumbre. ¿Es seguro para el equipo? ¿Es físicamente posible?



Demasiados descriptores

Con 35 puntos y 50 columnas, cualquier modelo encuentra patrones falsos.



Una sola semilla

Repita con varias semillas y reporte la dispersión: con pocos datos la variabilidad es grande.

Términos **Réplicas:** repeticiones del mismo experimento para medir el ruido · **Entrenamiento y prueba:** datos con los que el modelo aprende y datos reservados para evaluarlo · **Extrapolar:** predecir fuera de la región de los datos de entrenamiento · **Semilla aleatoria:** número que fija el azar para poder repetir un resultado

Cuatro tendencias para seguir



Potenciales universales

Redes entrenadas con millones de cálculos que dan energías y fuerzas para casi toda la tabla periódica (M3GNet, MACE-MP-0): relajar candidatos sin DFT.



Descubrimiento a escala

GNoME: redes de grafos + DFT en ciclo activo, millones de estructuras estables nuevas.



Modelos de lenguaje

LLMs ajustados con pocos ejemplos compiten con modelos especializados en tareas químicas y ayudan a extraer datos de la literatura.



Laboratorios autónomos

Síntesis, caracterización y decisión en ciclo cerrado (Día 4).

Idea clave Lo que no cambia: datos de calidad, validación honesta y criterio físico.

Términos **Potencial interatómico universal**: red que da energía y fuerzas de casi cualquier material en milisegundos · **M3GNet**: potencial universal de grafos con ángulos entre tres átomos · **MACE**: potencial universal entrenado con Materials Project · **GNoME**: proyecto de Google DeepMind que propuso millones de estructuras con GNN y DFT · **GNN**: red neuronal que opera sobre un grafo de átomos y vecinos · **Grafo**: conjunto de nodos unidos por aristas; en un cristal, átomos y enlaces · **LLM**: modelo de lenguaje grande entrenado con texto (ChatGPT, Claude) · **Laboratorio autónomo**: robots y algoritmos que sintetizan, miden y deciden en ciclo

Fuente: Chen y Ong (2022); Batatia et al. (2023); Merchant et al. (2023); Jablonka et al. (2024); Szymanski et al. (2023)

El lunes en su laboratorio: una lista para empezar

- Reúna lo que ya tiene: una tabla con condiciones y resultados, incluidos los experimentos que fallaron.
- Defina una sola métrica objetivo y el presupuesto de experimentos.
- Empiece simple: un GP o un Random Forest y validación leave-one-out.
- Use el modelo para proponer los próximos 3–5 experimentos, no para "predecir el futuro".
- Registre cada experimento nuevo y vuelva a entrenar: ese ciclo es la optimización bayesiana.
- Pida ayuda: CNCA para cómputo, LANOTEC para caracterización, y esta comunidad.

Idea clave El notebook del Brief B es una plantilla que pueden reutilizar con sus propios datos.

Términos **CNCA:** Colaboratorio Nacional de Computación Avanzada, del CeNAT · **LANOTEC:** Laboratorio Nacional de Nanotecnología del CeNAT



T5.6 • 5 min

El mini-reto

Dos encargos, 90 minutos, 5 minutos para convencer

Elijan un brief

Brief A: termoeléctricos

- Cliente: fabricante de autopartes (escape a 400–700 °C)
- Datos: catálogo de 800 materiales con S , σ , κ , ZT estimado y costo relativo
- Encargo: lista corta de 10 candidatos para validación experimental
- Clave: equilibrar ZT , costo y confianza

Brief B: pocos datos

- Cliente: planta de recubrimientos PVD
- Datos: solo 35 experimentos históricos, cada uno nuevo cuesta un turno
- Encargo: las próximas 5 condiciones de proceso, con predicción e incertidumbre
- Clave: GP, validación honesta y lotes sin repetir condiciones

Términos **Termoeléctrico**: convierte una diferencia de temperatura en electricidad · **ZT**: figura de mérito termoeléctrica $S^2\sigma T/\kappa$

Cómo trabajamos y cómo se evalúa

Tiempo	Actividad		Rúbrica	Peso
15 min	EDA		Razonamiento del pipeline	40 %
25 min	Pipeline de modelado		Calidad del resultado	25 %
breve	Checkpoint con mentores		Comunicación al cliente	25 %
25 min	Refinamiento		Limitaciones identificadas	10 %
20 min	Figuras y conclusión			
5 min	Ordenar la presentación			

Idea clave No hay una única respuesta correcta: se evalúa el porqué de cada decisión.

Términos **EDA:** análisis exploratorio: mirar los datos antes de modelar

Lo que el jurado va a buscar en cada criterio

La misma lista de verificación del Día 2, aplicada a su brief

Criterio	Peso	Preguntas que debe poder responder
Razonamiento del pipeline	40 %	¿De dónde vienen los datos y qué sesgos tienen? ¿Qué descriptores y por qué? ¿Cómo separaron la prueba sin fugas?
Calidad del resultado	25 %	¿Superan a una línea base trivial? ¿Reportan la dispersión (validación cruzada, réplicas), no solo un número?
Comunicación al cliente	25 %	¿Qué decisión recomiendan, con qué confianza, y qué haría el cliente mañana?
Limitaciones identificadas	10 %	¿Dónde no confiarían en el modelo? ¿Qué dato o experimento falta? ¿Usaron asistentes de IA y para qué?

Idea clave Un resultado modesto bien justificado vale más que un R^2 alto que nadie puede explicar.

Términos **Sesgo:** error sistemático; en datos, las preferencias de quien eligió qué medir o calcular · **IA:** inteligencia artificial: sistemas que aprenden o deciden a partir de datos · **R^2 :** fracción de la variación que explica el modelo; 1 es perfecto

Fuente: Artrith et al. (2021); Kapoor et al. (2024)

Logística del reto en Kabré



Equipos

- 3-4 personas por equipo
- Una sala virtual por equipo
- Mentores rotando entre salas



Cómputo

- Cada persona con su sesión en kura (2 núcleos, 4 GB)
- Un notebook del equipo: 05_brief_A o 05_brief_B
- Compartan el archivo al final



Presentación (5 min)

- Tabla con la propuesta
- 2-3 figuras que la defiendan
- Limitaciones honestas
- Hablen al cliente, no a los expertos en ML
- Si son más de 7 equipos: 3 min

Términos **kura**: cola de CPU de Kabré donde corre Jupyter



T5.7 • 10 min

Cierre del curso

Perspectivas, recursos para seguir y cómo seguimos en contacto



CeNAT
Centro Nacional de Alta Tecnología

Perspectivas: hacia dónde va esto

En el campo, próximos años

- Modelos fundacionales (generadores como MatterGen, potenciales universales como MatterSim o MACE) como herramientas de rutina, igual que hoy lo es DFT.
- Generar candidatos se vuelve barato; sintetizar y caracterizar sigue siendo el cuello de botella.
- Laboratorios autónomos y agentes con modelos de lenguaje que proponen y ejecutan experimentos.
- El dato experimental bien registrado (incluidos los fracasos) pasa a ser el activo más valioso.

Para ustedes, desde el lunes

- Un problema propio con 20 a 100 experimentos ya alcanza para empezar con un GP y optimización bayesiana.
- Kabré (CNCA) está disponible para cómputo, incluidas las GPU que usamos el Día 3.
- Combinar cálculo y caracterización: aquí está la ventaja de trabajar con LANOTEC y otros laboratorios del país.
- Publicar datos y código junto con los artículos: así crecen las bases que usamos en el curso.

Términos **Modelo preentrenado (fundacional):** modelo ya entrenado con muchos datos que se reutiliza · **MatterSim:** potencial interatómico universal de Microsoft

Fuente: Morgan y Jacobs (2020); Merchant et al. (2023); Szymanski et al. (2023)

Recursos para seguir aprendiendo

Recurso	Qué es	Para qué sirve
dmol.pub	Libro abierto con notebooks (White, 2021)	Redes neuronales, redes de grafos y modelos generativos para moléculas y materiales
github.com/materialsproject/workshop	Talleres anuales de Materials Project	pymatgen y la API de Materials Project con ejemplos guiados
github.com/hackingmaterials/matminer_examples	Notebooks de matminer	Más descriptores y datasets, como los del Día 1 y el notebook 07
matbench.materialsproject.org	Tabla de referencia de modelos	Comparar su modelo con el estado del arte en las mismas tareas
mattermodeling.stackexchange.com	Foro de preguntas y respuestas	Dudas de DFT, potenciales interatómicos y software
Revisiones	Butler et al. (2018); Schmidt et al. (2019); Morgan y Jacobs (2020)	Lectura de fondo para ubicar lo que vimos
LLM Hackathon (anual, en línea)	Hackatón de modelos de lenguaje en química y materiales	Participar en equipo con la comunidad internacional (Jablonka et al., 2023)

Idea clave Todo el material del curso sigue en el repositorio de GitHub, con versiones para Google Colab.

Términos **Red neuronal:** modelo de capas de operaciones simples cuyos pesos se ajustan con datos · **Modelo generativo:** aprende cómo son los ejemplos reales y produce otros nuevos parecidos · **pymatgen:** biblioteca de Python para estructuras cristalinas

Fuente: White (2021); Dunn et al. (2020); Butler et al. (2018); Schmidt et al. (2019); Morgan y Jacobs (2020); Jablonka et al. (2023)

Sigamos en contacto: colaboración



GitHub Discussions

- En el repositorio del curso
- Preguntas, resultados y código
- Queda buscable para todos



Chat (opcional)

- Zulip: hilos por tema
- Gratis para grupos académicos
- Para conversar en vivo



Club de lectura

- Un artículo al mes
- Una hora, virtual
- Propuesta: ¿quién se anima?



Traigan sus datos

- Un problema de su laboratorio
- Lo planteamos juntos
- Proyectos, tesis o artículos



Cómputo

- Cuentas en Kabré por medio del CNCA
- Los notebooks del curso ya funcionan ahí



Contribuir

- Sus notebooks y datasets
- Como pull request al repositorio
- La próxima edición los usa

Antes de irnos

- Tarea de MatterGen: una pregunta, tres generaciones, entrega el lunes 12 de octubre en el formulario (enlace en el chat).
- Encuesta de evaluación del curso (enlace en el chat): nos ayuda a mejorar la siguiente edición.
- Certificado: asistencia y participación (20 %), ejercicios diarios (40 %) y mini-reto (40 %).
- Material: repositorio público en GitHub (con versiones para Colab) y la carpeta del curso en Kabré.
- Agradecimientos: CNCA-CeNAT por Kabré y el apoyo técnico; LANOTEC por la sesión experimental.

Idea clave Gracias. La mejor forma de aprender esto es aplicarlo a un problema propio la próxima semana.

Términos **CeNAT**: Centro Nacional de Alta Tecnología



Apéndice

Material de apoyo

Termoeléctricos (Brief A), modelos de lenguaje y polímeros

El problema industrial



La oportunidad

Una parte grande de la energía del combustible sale como calor por el escape. Un módulo termoeléctrico la convierte en electricidad sin partes móviles.



La exigencia

- Escape a unos 400–700 °C
- Ciclos térmicos y vibración
- Costo y toxicidad bajo lupa (Pb, Te)




La métrica

- $ZT = S^2 \sigma T / \kappa$ a la temperatura de operación
- $ZT \approx 1$ ya es competitivo
- El ZT depende de T: un material bueno a 300 K puede ser malo a 900 K

Fuente: Snyder y Toberer (2008); He y Tritt (2017)

El efecto Seebeck en una imagen

- Dos conductores distintos unidos en dos puntos, uno caliente y otro frío.
- Los portadores de carga se difunden del lado caliente al frío y aparece un voltaje.
- **Coeficiente Seebeck:** $S = \Delta V / \Delta T$.
- Un módulo real conecta muchos pares de semiconductores p y n en serie.



Términos Efecto Seebeck: una diferencia de temperatura produce un voltaje ($S = \Delta V / \Delta T$) · **Portadores de carga:** electrones o huecos que conducen la corriente

Fuente: Imagen: NASA, science.nasa.gov (adaptada: recortada y sin el botón de reproducción del video original)

Familias de termoelectricos y donde trabajan

Familia	Rango de uso típico	Comentario
Bi ₂ Te ₃ y aleaciones	cerca de ambiente	El estándar comercial para refrigeración; Te escaso
PbTe y calcogenuros	temperaturas intermedias	Muy buen ZT; plomo es una bandera regulatoria
Skutteruditas, half-Heusler	intermedias a altas	Candidatos naturales para escape automotriz
SiGe	altas	Robusto; usado en generadores para espacio
Óxidos	altas	Estables y baratos, pero ZT bajo


Idea clave Elegir material es elegir un compromiso entre ZT, temperatura, costo, toxicidad y procesabilidad.

Términos **Calcogenuros:** compuestos con azufre, selenio o telurio

Fuente: Snyder y Toberer (2008); He y Tritt (2017)

Cada familia tiene su ventana de temperatura

- zT de materiales representativos de cada familia en función de la temperatura.
- Bi_2Te_3 domina cerca de ambiente; half-Heusler, SiGe y fases Zintl rinden a alta temperatura.
- Los óxidos quedan abajo en zT , pero son estables y baratos.
- Arriba: dónde se aplicaría cada rango (automotriz, procesos industriales).



Fuente: Fig. 2 de Wolf, Hinterding y Feldhoff (2019), Entropy 21, 1058, doi:10.3390/e21111058. Licencia CC BY 4.0

ML para termoelectricos: qué funciona y qué no



Screening rápido

Modelos entrenados con datos publicados que estiman propiedades termoelectricas desde la composición, para ordenar miles de candidatos antes de sintetizar.



La física como descriptor

Construir $S^2\sigma/\kappa$ a partir de S , σ y κ le da al modelo la forma de ZT: con los datos del Brief A, el R^2 sube de 0.935 a 0.971.



ZT estimado $\neq$ ZT medido

Los valores estimados por modelos o cálculos suelen ser optimistas. Úselos para ordenar, no como promesa.




Más allá del ZT

Costo, disponibilidad de elementos, toxicidad y estabilidad a alta temperatura entran en la decisión.

Términos ML (aprendizaje automático): algoritmos que aprenden una relación a partir de ejemplos

Fuente: Gaultois et al. (2016); Zhang y Ling (2018)

Modelos de lenguaje como predictores químicos



¿Y si mis materiales no son cristales? Polímeros y biomateriales



Representación

Un polímero es una distribución de cadenas, no una molécula única: SMILES no alcanza. BigSMILES y PSMILES describen las unidades que se repiten.



Modelos

polyBERT: un modelo de lenguaje entrenado con 100 millones de polímeros hipotéticos predice 29 propiedades, unas cien veces más rápido que las huellas diseñadas a mano.



Datos


No hay un Materials Project de polímeros, y las propiedades se reportan de formas heterogéneas. Suele haber pocos datos: procesos gaussianos y DoE (Día 4) son sus aliados.

Idea clave Las ideas del curso se transfieren; cambian la representación y la cantidad de datos.

Términos **SMILES**: notación de texto para moléculas (PSMILES y BigSMILES para polímeros) · **polyBERT**: modelo de lenguaje entrenado con 100 millones de polímeros · **Huella (fingerprint)**: vector que resume una molécula o un polímero para un modelo

Fuente: Lin et al. (2019); Kuenneth y Ramprasad (2023); Audus y de Pablo (2017)

polyBERT: del texto de un polímero a sus propiedades



(a) Huellas hechas a mano frente a huellas de polyBERT. (b) Entrenamiento con PSMILES. (c) 100 millones de polímeros hipotéticos a partir de unos 13 000 sintetizados.

Fuente: Fig. 1 de Kuenneth y Ramprasad (2023), Nat. Commun. 14, 4099, doi:10.1038/s41467-023-39868-6. Licencia CC BY 4.0

Referencias (1/8)

- [1] Jain, A., Ong, S. P., Hautier, G., et al. (2013). **The Materials Project: A materials genome approach to accelerating materials innovation.** *APL Materials* 1, 011002. doi:10.1063/1.4812323
- [2] Saal, J. E., Kirklin, S., Aykol, M., Meredig, B., Wolverton, C. (2013). **Materials design and discovery with high-throughput density functional theory: the Open Quantum Materials Database (OQMD).** *JOM* 65, 1501–1509. doi:10.1007/s11837-013-0755-4
- [3] Choudhary, K., Garrity, K. F., Reid, A. C. E., DeCost, B., et al. (2020). **The joint automated repository for various integrated simulations (JARVIS) for data-driven materials design.** *npj Comput. Mater.* 6, 173. doi:10.1038/s41524-020-00440-1
- [4] Schmidt, J., Hoffmann, N., Wang, H.-C., Borlido, P., et al. (2023). **Machine-learning-assisted determination of the global zero-temperature phase diagram of materials.** *Adv. Mater.* 35, 2210788. doi:10.1002/adma.202210788
- [5] Draxl, C., Scheffler, M. (2019). **The NOMAD laboratory: from data sharing to artificial intelligence.** *J. Phys. Mater.* 2, 036001. doi:10.1088/2515-7639/ab13bb
- [6] Dunn, A., Wang, Q., Ganose, A., Dopp, D., Jain, A. (2020). **Benchmarking materials property prediction methods: the Matbench test set and Automatminer reference algorithm.** *npj Comput. Mater.* 6, 138. doi:10.1038/s41524-020-00406-3

Referencias (2/8)

- [7] Riebesell, J., Goodall, R. E. A., Benner, P., Chiang, Y., et al. (2025). **A framework to evaluate machine learning crystal stability predictions.** *Nat. Mach. Intell.* 7, 836–847. doi:10.1038/s42256-025-01055-1
- [8] Ward, L., Dunn, A., Faghaninia, A., et al. (2018). **Matminer: An open source toolkit for materials data mining.** *Comput. Mater. Sci.* 152, 60–69. doi:10.1016/j.commatsci.2018.05.018
- [9] Zhuo, Y., Mansouri Tehrani, A., Brgoch, J. (2018). **Predicting the band gaps of inorganic solids by machine learning.** *J. Phys. Chem. Lett.* 9, 1668–1673. doi:10.1021/acs.jpclett.8b00124
- [10] Rosen, A. S., Iyer, S. M., Ray, D., Yao, Z., et al. (2021). **Machine learning the quantum-chemical properties of metal–organic frameworks for accelerated materials discovery.** *Matter* 4, 1578–1597. doi:10.1016/j.matt.2021.02.015
- [11] Chanussot, L., Das, A., Goyal, S., Lavril, T., et al. (2021). **Open Catalyst 2020 (OC20) dataset and community challenges.** *ACS Catal.* 11, 6059–6072. doi:10.1021/acscatal.0c04525
- [12] Otsuka, S., Kuwajima, I., Hosoya, J., Xu, Y., Yamazaki, M. (2011). **PoLyInfo: Polymer database for polymeric materials design.** *Int. Conf. Emerging Intelligent Data and Web Technologies*, 22–29. doi:10.1109/EIDWT.2011.13

Referencias (3/8)

- [13] Lafuente, B., Downs, R. T., Yang, H., Stone, N. (2015). **The power of databases: the RRUFF project.** *En Highlights in Mineralogical Crystallography, De Gruyter*, 1–30. doi:10.1515/9783110417104-003
- [14] Cowger, W., Steinmetz, Z., Gray, A., et al. (2021). **Microplastic spectral classification needs an open source community: Open Specy to the rescue!.** *Anal. Chem.* 93, 7543–7548. doi:10.1021/acs.analchem.1c00123
- [15] DeCost, B. L., Hecht, M. D., Francis, T., Webler, B. A., Picard, Y. N., Holm, E. A. (2017). **UHCSDb: UltraHigh Carbon Steel Micrograph DataBase.** *Integr. Mater. Manuf. Innov.* 6, 197–205. doi:10.1007/s40192-017-0097-0
- [16] Song, K., Yan, Y. (2013). **A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defects.** *Appl. Surf. Sci.* 285, 858–864. doi:10.1016/j.apsusc.2013.09.002
- [17] Park, S. (s. f.). **NEU-DET classification (dataset, versión 1, CC BY 4.0).** *Roboflow Universe.* universe.roboflow.com/park-sung-ho/neu-det-classification
- [18] Aversa, R., Modarres, M. H., Cozzini, S., Ciancio, R., Chiusole, A. (2018). **The first annotated set of scanning electron microscopy images for nanoscience.** *Sci. Data* 5, 180172. doi:10.1038/sdata.2018.172

Referencias (4/8)

- [19] Modarres, M. H., Aversa, R., Cozzini, S., et al. (2017). **Neural network for nanoscience scanning electron microscope image recognition.** *Sci. Rep.* 7, 13282. doi:10.1038/s41598-017-13565-z
- [20] He, K., Zhang, X., Ren, S., Sun, J. (2016). **Deep residual learning for image recognition.** *CVPR 2016*, 770–778. doi:10.1109/CVPR.2016.90
- [21] Shahriari, B., Swersky, K., Wang, Z., Adams, R. P., de Freitas, N. (2016). **Taking the human out of the loop: A review of Bayesian optimization.** *Proc. IEEE* 104, 148–175. doi:10.1109/JPROC.2015.2494218
- [22] Rasmussen, C. E., Williams, C. K. I. (2006). **Gaussian Processes for Machine Learning.** *MIT Press*
- [23] Balandat, M., Karrer, B., Jiang, D. R., et al. (2020). **BoTorch: A framework for efficient Monte-Carlo Bayesian optimization.** *NeurIPS* 33. arXiv:1910.06403
- [24] PalDey, S., Deevi, S. C. (2003). **Single layer and multilayer wear resistant coatings of (Ti,Al)N: a review.** *Mater. Sci. Eng. A* 342, 58–79. doi:10.1016/S0921-5093(02)00259-9

Referencias (5/8)

- [25] Xu, P., Ji, X., Li, M., Lu, W. (2023). **Small data machine learning in materials science.** *npj Comput. Mater.* 9, 42. doi:10.1038/s41524-023-01000-z
- [26] Zhang, Y., Ling, C. (2018). **A strategy to apply machine learning to small datasets in materials science.** *npj Comput. Mater.* 4, 25. doi:10.1038/s41524-018-0081-z
- [27] Raccuglia, P., Elbert, K. C., Adler, P. D. F., et al. (2016). **Machine-learning-assisted materials discovery using failed experiments.** *Nature* 533, 73–76. doi:10.1038/nature17439
- [28] Lookman, T., Balachandran, P. V., Xue, D., Yuan, R. (2019). **Active learning in materials science with emphasis on adaptive sampling using uncertainties for targeted design.** *npj Comput. Mater.* 5, 21. doi:10.1038/s41524-019-0153-8
- [29] Chen, C., Ong, S. P. (2022). **A universal graph deep learning interatomic potential for the periodic table.** *Nat. Comput. Sci.* 2, 718–728. doi:10.1038/s43588-022-00349-3
- [30] Batatia, I., Benner, P., Chiang, Y., et al. (2023). **A foundation model for atomistic materials chemistry.** *preprint.* arXiv:2401.00096

Referencias (6/8)

- [31] Merchant, A., Batzner, S., Schoenholz, S. S., et al. (2023). **Scaling deep learning for materials discovery.** *Nature* 624, 80–85. doi:10.1038/s41586-023-06735-9
- [32] Jablonka, K. M., Schwaller, P., Ortega-Guerrero, A., Smit, B. (2024). **Leveraging large language models for predictive chemistry.** *Nat. Mach. Intell.* 6, 161–169. doi:10.1038/s42256-023-00788-1
- [33] Szymanski, N. J., Rendy, B., Fei, Y., et al. (2023). **An autonomous laboratory for the accelerated synthesis of novel materials.** *Nature* 624, 86–91. doi:10.1038/s41586-023-06734-w
- [34] Artrith, N., Butler, K. T., Coudert, F.-X., et al. (2021). **Best practices in machine learning for chemistry.** *Nat. Chem.* 13, 505–508. doi:10.1038/s41557-021-00716-z
- [35] Kapoor, S., Cantrell, E. M., Peng, K., et al. (2024). **REFORMS: Consensus-based recommendations for machine-learning-based science.** *Sci. Adv.* 10, eadk3452. doi:10.1126/sciadv.adk3452
- [36] Morgan, D., Jacobs, R. (2020). **Opportunities and challenges for machine learning in materials science.** *Annu. Rev. Mater. Res.* 50, 71–103. doi:10.1146/annurev-matsci-070218-010015

Referencias (7/8)

- [37] White, A. D. (2021). **Deep Learning for Molecules and Materials**. *Living J. Comput. Mol. Sci.* 3(1), 1499. Libro abierto: dmol.pub. doi:10.33011/livecoms.3.1.1499
- [38] Schmidt, J., Marques, M. R. G., Botti, S., Marques, M. A. L. (2019). **Recent advances and applications of machine learning in solid-state materials science**. *npj Comput. Mater.* 5, 83. doi:10.1038/s41524-019-0221-0
- [39] Jablonka, K. M., Ai, Q., Al-Feghali, A., et al. (2023). **14 examples of how LLMs can transform materials science and chemistry: a reflection on a large language model hackathon**. *Digital Discovery* 2, 1233–1250. doi:10.1039/D3DD00113J
- [40] Butler, K. T., Davies, D. W., Cartwright, H., Isayev, O., Walsh, A. (2018). **Machine learning for molecular and materials science**. *Nature* 559, 547–555. doi:10.1038/s41586-018-0337-2
- [41] Snyder, G. J., Toberer, E. S. (2008). **Complex thermoelectric materials**. *Nature Materials* 7, 105–114. doi:10.1038/nmat2090
- [42] He, J., Tritt, T. M. (2017). **Advances in thermoelectric materials research: Looking back and moving forward**. *Science* 357, eaak9997. doi:10.1126/science.aak9997

Referencias (8/8)

- [43] Gaultois, M. W., Oliynyk, A. O., Mar, A., et al. (2016). **Perspective: Web-based machine learning models for real-time screening of thermoelectric materials properties.** *APL Materials* 4, 053213. doi:10.1063/1.4952607
- [44] Wolf, M., Hinterding, R., Feldhoff, A. (2019). **High power factor vs. high zT: A review of thermoelectric materials for high-temperature application.** *Entropy* 21, 1058. doi:10.3390/e21111058
- [45] Lin, T.-S., Coley, C. W., Mochigase, H., et al. (2019). **BigSMILES: A structurally-based line notation for describing macromolecules.** *ACS Cent. Sci.* 5, 1523–1531. doi:10.1021/acscentsci.9b00476
- [46] Kuenneth, C., Ramprasad, R. (2023). **polyBERT: a chemical language model to enable fully machine-driven ultrafast polymer informatics.** *Nat. Commun.* 14, 4099. doi:10.1038/s41467-023-39868-6
- [47] Audus, D. J., de Pablo, J. J. (2017). **Polymer informatics: Opportunities and challenges.** *ACS Macro Lett.* 6, 1078–1082. doi:10.1021/acsmacrolett.7b00228



¡Gracias!

Tomás Rojas Solórzano
Universidad de Costa Rica · tomas.rojas_s@ucr.ac.cr