



DÍA 5 • VIERNES 08:00 - 12:00

## Cierre, más allá del curso y mini-reto final

Terminar lo pendiente, ver qué otros datos existen y poner todo junto en un reto

# El plan de hoy

| Hora  | Bloque      | Actividad                                                        |
|-------|-------------|------------------------------------------------------------------|
| 08:00 | Repaso      | Lo que construimos en cuatro días                                |
| 08:10 | P4.3        | Cierre de la optimización bayesiana: campaña PVD (notebook 04)   |
| 08:35 | P3.5b       | Visión pendiente: SEM y un dataset de Roboflow (notebook 06)     |
| 09:00 | 07          | Más allá del curso: otros datasets (notebook 07)                 |
| 09:20 | T5.4 · T5.6 | Small data, perspectivas y presentación de los briefs            |
| 09:35 |             | Receso                                                           |
| 09:45 | RETO        | Mini-reto en equipos (90 min)                                    |
| 11:15 |             | Presentaciones por equipo (5 min; 3 min si son más de 7 equipos) |
| 11:50 |             | Cierre del curso, tarea de MatterGen y encuesta                  |

**Términos** **Optimización bayesiana (BO)**: ciclo: modelo con incertidumbre → elegir experimento → medir → repetir · **PVD**: deposición física de vapor: se pulveriza un blanco y se deposita una película · **Notebook**: documento con celdas de código y texto que se ejecutan en orden · **SEM y TEM**: microscopía electrónica de barrido y de transmisión · **Pocos datos (small data)**: decenas o pocos cientos de experimentos; piden modelos simples con incertidumbre · **MatterGen**: modelo de difusión de Microsoft que genera cristales



T5.1 • 10 min

# Repaso

El mapa completo del curso

# Lo que construimos en cuatro días



- Hoy cerramos lo pendiente (BO y visión), vemos qué otros datos existen y luego toca elegir herramienta y defender la decisión.

**Términos** **Descriptor (feature)**: número que describe un material y que el modelo usa como entrada · **Random Forest**: promedio de muchos árboles de decisión entrenados al azar · **MAE**: error absoluto medio, en las unidades de la propiedad · **GPa**: gigapascal, unidad de presión y de módulo elástico · **Screening**: evaluar con un modelo rápido muchos candidatos y quedarse con los mejores · **GPU**: procesador gráfico; acelera el entrenamiento y uso de redes neuronales · **Kabré**: supercomputadora del CNCA · **DoE**: diseño de experimentos: elegir de antemano qué combinaciones medir



P4.3 • 25 min

## Cierre de la optimización bayesiana

La campaña PVD del notebook 04, celdas [12] a [17]

**Celda:** en un cristal, la celda unitaria: bloque mínimo que se repite ( $a$ ,  $b$ ,  $c$ ,  $\alpha$ ,  $\beta$ ,  $\gamma$ ); en un notebook, un bloque de código

# La campaña PVD, celda por celda

*Notebook 04: corran de arriba hacia abajo con el kernel Python-AI-Materials*

| Celda | Qué hace                                                          | Qué deben ver                                       |
|-------|-------------------------------------------------------------------|-----------------------------------------------------|
| [12]  | Lee 200 experimentos históricos de (Ti,Al)N                       | 4 perillas y 4 resultados; dureza máxima 2844 HV    |
| [13]  | Construye el oráculo: el laboratorio de mentira                   | Nada impreso                                        |
| [14]  | Parte de 5 recetas de la mitad peor y hace 20 experimentos con BO | Punto de partida 2351 HV y la barra que sube        |
| [15]  | Repite 20 recetas al azar, 10 veces                               | Azar: mediana 2741 HV (96 %); 1 de 10 llega al 98 % |
| [16]  | Grafica BO contra la banda del azar                               | En qué experimento la curva cruza el 98 %           |
| [17]  | Traduce la mejor receta a unidades reales                         | °C, Pa, V y flujo: lo que se lleva al laboratorio   |

**Idea clave** Es el mismo ciclo de Hartmann (celda [8]); solo cambió el laboratorio.

**Términos** **Kernel:** en Jupyter, el proceso de Python que ejecuta las celdas; en un GP, la función que mide el parecido entre dos puntos · **Python:** lenguaje de programación usado en el curso · **Dureza Vickers (HV):** dureza medida con un indentador piramidal de diamante · **Oráculo:** fuente de la respuesta 'verdadera'; en P4.3, un modelo que hace de laboratorio · **Hartmann 6D:** función de prueba de 6 variables con óptimo conocido (3.322)

# El oráculo no es el GP

## Oráculo: el laboratorio

- Superficie suave que pasa por los 200 experimentos y rellena entre ellos
- Preguntarle es como hacer una corrida de 8 horas, en un milisegundo
- Es fijo: no aprende ni cambia
- BO no lo ve por dentro, solo le hace preguntas

## GP: el cerebro de BO

- Solo sabe lo que BO ha medido: 5 recetas iniciales más las nuevas
- Da una predicción y una duda para cada receta
- Se vuelve a ajustar en cada vuelta
- El juez (EI o UCB) usa su predicción y su duda para elegir el siguiente experimento

**Idea clave** El oráculo hace de laboratorio; el GP es lo que BO va aprendiendo de él.

**Términos** **Proceso gaussiano (GP)**: modelo que da una predicción y su incertidumbre en cada punto · **Expected Improvement (EI)**: cuánto se espera mejorar sobre el mejor resultado actual · **UCB**: media +  $\beta$ ·incertidumbre: apuesta por el lado optimista

# Solución del Día 4: LogEI vs UCB en la campaña PVD

Experimento en el que cada método alcanza una fracción del máximo histórico (2844 HV)

| Meta  | LogEI   | UCB ( $\beta = 2$ ) | Lectura                                                |
|-------|---------|---------------------|--------------------------------------------------------|
| 95 %  | 3       | 3                   | Demasiado fácil: el azar también llega rápido          |
| 98 %  | 5       | 5                   | Todavía empatados                                      |
| 99 %  | 6       | 16                  | UCB paga su exploración: tarda más en afinar el óptimo |
| Final | 2837 HV | 2835 HV             | Diferencia pequeña en HV, grande en experimentos       |

**Idea clave** Los últimos puntos porcentuales son los caros: ahí se nota cuánto explora cada estrategia.



P3.5b • 25 min

# Visión: lo que quedó pendiente

Micrografías SEM y un dataset de la comunidad

# SEM con aprendizaje por transferencia

Notebook 06, celdas [10] a [14]

| Celda | Qué hace                                                                       | Qué preguntar                                       |
|-------|--------------------------------------------------------------------------------|-----------------------------------------------------|
| [10]  | Carga 200 micrografías SEM de prueba en 10 categorías (base NFFA-Europe)       | ¿Qué categorías se parecen entre sí?                |
| [11]  | ResNet-18 aprendida con fotos cotidianas y ajustada con unas 3500 imágenes SEM | ¿Qué confunde la matriz de confusión?               |
| [12]  | Muestra las imágenes mal clasificadas                                          | ¿Se equivoca el modelo o la etiqueta es discutible? |
| [13]  | Proyecta a 2D los 512 números que la red calcula por imagen                    | ¿Forman grupos las categorías?                      |
| [14]  | Reto B: las 5 imágenes con menor confianza                                     | ¿Cuándo pedir la opinión de una persona?            |

**Idea clave** No hace falta entrenar desde cero: se reutiliza lo que la red ya sabe ver.

**Términos** **Aprendizaje por transferencia:** partir de una red ya entrenada y ajustarla con pocos datos propios · **opXRD y NFFA-Europe:** conjuntos abiertos de difractogramas y de imágenes SEM · **ImageNet y ResNet:** colección de 1.2 millones de fotos y la red entrenada con ella · **Matriz de confusión:** tabla de clase real contra clase predicha

Fuente: Aversa et al. (2018); Modarres et al. (2017); He et al. (2016)

# Datasets etiquetados por la comunidad: Roboflow Universe

- Imágenes ya etiquetadas, cada dataset con su licencia y sus versiones (láminas 46 a 55 del Día 3).
- **Demo:** NEU-DET, acero laminado con 6 tipos de defecto, clasificado con la misma ResNet de SEM sin reentrenarla (final del notebook 06).
- Bajar un dataset pide una API key gratuita y personal: nunca se escribe en el notebook.
- Otros ejemplos de materiales: microestructuras de acero, nanopartículas, defectos de soldadura y corrosión.

**Idea clave** Antes de etiquetar sus propias imágenes, busquen si alguien ya lo hizo.

**Términos API:** interfaz para consultar una base de datos desde un programa

Fuente: Song y Yan (2013); Park, NEU-DET classification, Roboflow Universe



07 • 20 min

## Más allá del curso

Otros datasets de materiales y cómo empezar con los suyos (notebook 07)

# Datos calculados de cristales y comparación de modelos

| Dataset            | Qué trae                                             | Cómo se accede                  |
|--------------------|------------------------------------------------------|---------------------------------|
| Materials Project  | Estructuras, energías, gaps y elásticas (DFT)        | API con key gratis (martes)     |
| OQMD               | Energías de formación y estabilidad (DFT)            | Descarga completa o API         |
| JARVIS-DFT (NIST)  | Más de 80 000 materiales, incluye 2D                 | jarvis-tools; parte en matminer |
| Alexandria         | Cristales relajados con PBE, PBEsol y SCAN; fonones  | Descarga por bloques            |
| NOMAD              | Repositorio de cálculos de muchos códigos            | Web y API                       |
| Matbench           | 13 tareas, de 312 a 132 752 muestras                 | Viene en matminer               |
| Matbench Discovery | Ranking de modelos para encontrar cristales estables | Web                             |

**Términos** **Materials Project:** base abierta de más de 150 000 materiales calculados con DFT · **Band gap:** brecha de energía entre bandas ocupadas y vacías; cero en metales · **DFT:** teoría del funcional de la densidad: cálculo cuántico de energía y electrones · **OQMD y AFLOW:** otras bases de cálculos DFT de alto rendimiento · **matminer:** biblioteca de Python con datasets y descriptores de materiales · **Relajación:** mover átomos y celda hasta que las fuerzas sean casi cero · **PBE:** aproximación de DFT más usada; subestima los band gaps · **Benchmark:** tarea de referencia para comparar modelos en las mismas condiciones

Fuente: Jain et al. (2013); Saal et al. (2013); Choudhary et al. (2020); Schmidt et al. (2023); Draxl y Scheffler (2019); Dunn et al. (2020); Riebesell et al. (2025)

# Otras familias de materiales

| Familia      | Dataset            | Qué trae                                                  |
|--------------|--------------------|-----------------------------------------------------------|
| MOFs         | QMOF               | Más de 20 000 MOFs con propiedades DFT                    |
| Catálisis    | Open Catalyst OC20 | Adsorbatos sobre superficies (DFT)                        |
| Polímeros    | PoLyInfo (NIMS)    | Propiedades medidas de polímeros; registro gratis         |
| Espectros    | RRUFF              | Minerales: Raman, IR, química y fotos                     |
| Espectros    | Open Specy         | Bibliotecas FTIR y Raman de plásticos                     |
| Micrografías | UHCSDB (NIST)      | Micrografías de acero de ultra alto carbono               |
| Micrografías | NEU-DET (Roboflow) | 6 defectos en acero laminado                              |
| Medidos      | matminer           | expt_gap, steel_strength, glass, superconductivity2018... |

**Idea clave** ¿Cuál de estas familias se parece más a lo que ustedes miden o fabrican?

**Términos FTIR y Raman:** espectroscopías vibracionales de las moléculas y enlaces

Fuente: Rosen et al. (2021); Chanussot et al. (2021); Otsuka et al. (2011); Lafuente et al. (2015); Cowger et al. (2021); DeCost et al. (2017); Song y Yan (2013); Ward et al. (2018)

# El catálogo de matminer

*Notebook 07, bloque 2: se lee sin internet*

**45**

datasets listos para cargar con  
load\_dataset

**16**

con datos medidos en laboratorio (aprox.)

**312 a 132 752**


filas: lo medido es pequeño, lo calculado  
es grande

- La función buscar("steel") del notebook filtra el catálogo por palabra: prueben glass, thermal, dielectric, perovskite.

*Fuente: Ward et al. (2018); Dunn et al. (2020)*

# Demo: band gaps medidos con el pipeline del martes

- 4604 composiciones con su gap medido (matbench\_expt\_gap); el 53 % son metales.
- Mismo código del martes: composición, 132 descriptores Magpie y Random Forest.
- **Error medio:** 0.45 eV, contra 1.14 eV si se adivina siempre el promedio.
- La nube pegada al eje vertical: metales que el modelo cree semiconductores. Conviene clasificar primero metal o no metal.



**Términos Pipeline:** cadena de pasos automatizados de datos a resultado · **Magpie:** 132 descriptores de composición: 22 propiedades × 6 estadísticas · **eV:** electronvoltio, unidad de energía de los electrones · **Semiconductor:** material con gap pequeño, cuya conducción se controla

Fuente: Cálculo propio, notebook 07 corrido en Kabré (kura); datos de Zhuo et al. (2018) vía Matbench

# Demo: resistencia de aceros y sus propios datos



## matbench\_steels (necesita internet)

- 312 aceros con su límite elástico medido
- Error medio 113 MPa; adivinar el promedio, 229 MPa
- La composición no sabe del tratamiento térmico ni del laminado



## Antes de usar sus datos

- Una columna objetivo, con unidades
- ¿Cuántas filas? Pocas: modelos simples y BO
- ¿Medido o calculado?
- Misma fórmula repetida: GroupKFold
- Licencia y origen

**Idea clave** Todo lo de la semana funciona con otros datos; cambia de dónde salen y qué tan confiables son.

Fuente: Dunn et al. (2020); cálculo propio en Kabré

# Notebooks para seguir aprendiendo

| Dónde                           | Qué hay                                                           |
|---------------------------------|-------------------------------------------------------------------|
| Repositorio del curso en GitHub | Notebooks 00 a 07, soluciones, tareas y las presentaciones en PDF |
| Ejemplos de matminer (nbviewer) | Bajar datos, descriptores, visualizar, entrenar e interpretar     |
| matbench.materialsproject.org   | Cómo comparar un modelo con los publicados                        |
| Notebook 06, al final           | Cómo bajar un dataset de Roboflow Universe                        |
| Notebook 05_brief_B             | Plantilla para optimizar un proceso con pocos datos               |

Fuente: Ward et al. (2018); Dunn et al. (2020)




T5.4 • 10 min

## Small data: la realidad experimental

Qué hacer cuando hay 35 experimentos y no 1181

# Dónde vive el laboratorio real

- La curva de aprendizaje del Día 2: con 25 materiales el error es más del doble que con ~940.
- Un laboratorio típico tiene decenas a pocos cientos de experimentos por proceso.
- No se puede hacer todo lo que hicimos con datos de DFT: hay que cambiar de estrategia, no solo de modelo.



Fuente: Cálculo propio (RF + Magpie); Xu et al. (2023)

# Estrategias para pocos datos



## Conocimiento del dominio

Descriptores con física ( $S^2\sigma/\kappa$ ), restricciones conocidas, rangos razonables. Vale más que 100 descriptores genéricos.



## Modelos simples con incertidumbre

Procesos gaussianos, regresiones regularizadas. Evitar redes profundas con 35 puntos.



## Validación honesta

Leave-one-out o validación cruzada repetida; nunca un solo split de 7 puntos.



## Aprendizaje activo

Que el modelo proponga los próximos experimentos más informativos (Día 4).



## Transferir

Preentrenar con datos calculados abundantes y ajustar con los experimentales.



## Usar los fracasos


Los experimentos que "no funcionaron" también son datos: enseñan dónde no está el éxito.

**Términos** **Incertidumbre:** rango de valores plausibles alrededor de una predicción · **Regresión:** predecir un número (por ejemplo K en GPa) · **Validación:** comprobar el modelo con datos que no vio · **Validación cruzada:** entrenar k veces dejando cada parte de los datos una vez fuera · **Aprendizaje activo:** el modelo elige qué dato medir después para aprender más rápido

Fuente: Xu et al. (2023); Zhang y Ling (2018); Raccuglia et al. (2016); Lookman et al. (2019)

# Un mapa de las estrategias para pocos datos

- **Del lado de los datos:** extraer de publicaciones, construir bases, cálculo de alto rendimiento.
- **Del lado del modelo:** algoritmos adecuados, aprendizaje con clases desbalanceadas, aprendizaje activo y por transferencia.
- La revisión de Xu et al. (2023) es un buen punto de partida para el mini-reto.



**Términos Alto rendimiento:** calcular o medir miles de materiales con un flujo automatizado

Fuente: Fig. 1 de Xu et al. (2023), *npj Comput. Mater.* 9, 42, doi:10.1038/s41524-023-01000-z. Licencia CC BY 4.0

# Trampas comunes con pocos datos



## Réplicas y fugas

Si una réplica queda en entrenamiento y su gemela en prueba, el error parece menor. Agrupe réplicas al validar.



## Extrapolar

El GP puede recomendar condiciones fuera del rango histórico con mucha incertidumbre. ¿Es seguro para el equipo? ¿Es físicamente posible?



## Demasiados descriptores

Con 35 puntos y 50 columnas, cualquier modelo encuentra patrones falsos.



## Una sola semilla

Repita con varias semillas y reporte la dispersión: con pocos datos la variabilidad es grande.

**Términos** **Réplicas:** repeticiones del mismo experimento para medir el ruido · **Entrenamiento y prueba:** datos con los que el modelo aprende y datos reservados para evaluarlo · **Extrapolar:** predecir fuera de la región de los datos de entrenamiento · **Semilla aleatoria:** número que fija el azar para poder repetir un resultado

# Cuatro tendencias para seguir



## Potenciales universales

Redes entrenadas con millones de cálculos que dan energías y fuerzas para casi toda la tabla periódica (M3GNet, MACE-MP-0): relajar candidatos sin DFT.



## Descubrimiento a escala

GNoME: redes de grafos + DFT en ciclo activo, millones de estructuras estables nuevas.



## Modelos de lenguaje

LLMs ajustados con pocos ejemplos compiten con modelos especializados en tareas químicas y ayudan a extraer datos de la literatura.



## Laboratorios autónomos

Síntesis, caracterización y decisión en ciclo cerrado (Día 4).

**Idea clave** Lo que no cambia: datos de calidad, validación honesta y criterio físico.

**Términos** **Potencial interatómico universal**: red que da energía y fuerzas de casi cualquier material en milisegundos · **M3GNet**: potencial universal de grafos con ángulos entre tres átomos · **MACE**: potencial universal entrenado con Materials Project · **GNoME**: proyecto de Google DeepMind que propuso millones de estructuras con GNN y DFT · **GNN**: red neuronal que opera sobre un grafo de átomos y vecinos · **Grafo**: conjunto de nodos unidos por aristas; en un cristal, átomos y enlaces · **LLM**: modelo de lenguaje grande entrenado con texto (ChatGPT, Claude) · **Laboratorio autónomo**: robots y algoritmos que sintetizan, miden y deciden en ciclo

Fuente: Chen y Ong (2022); Batatia et al. (2023); Merchant et al. (2023); Jablonka et al. (2024); Szymanski et al. (2023)

# El lunes en su laboratorio: una lista para empezar

- Reúna lo que ya tiene: una tabla con condiciones y resultados, incluidos los experimentos que fallaron.
- Defina una sola métrica objetivo y el presupuesto de experimentos.
- Empiece simple: un GP o un Random Forest y validación leave-one-out.
- Use el modelo para proponer los próximos 3–5 experimentos, no para "predecir el futuro".
- Registre cada experimento nuevo y vuelva a entrenar: ese ciclo es la optimización bayesiana.
- Pida ayuda: CNCA para cómputo, LANOTEC para caracterización, y esta comunidad.

**Idea clave** El notebook del Brief B es una plantilla que pueden reutilizar con sus propios datos.

**Términos** **CNCA:** Colaboratorio Nacional de Computación Avanzada, del CeNAT · **LANOTEC:** Laboratorio Nacional de Nanotecnología del CeNAT



T5.6 • 5 min

## El mini-reto

Dos encargos, 90 minutos, 5 minutos para convencer

# Elijan un brief

## Brief A: termoeléctricos

- Cliente: fabricante de autopartes (escape a 400–700 °C)
- Datos: catálogo de 800 materiales con  $S$ ,  $\sigma$ ,  $\kappa$ ,  $ZT$  estimado y costo relativo
- Encargo: lista corta de 10 candidatos para validación experimental
- Clave: equilibrar  $ZT$ , costo y confianza

## Brief B: pocos datos

- Cliente: planta de recubrimientos PVD
- Datos: solo 35 experimentos históricos, cada uno nuevo cuesta un turno
- Encargo: las próximas 5 condiciones de proceso, con predicción e incertidumbre
- Clave: GP, validación honesta y lotes sin repetir condiciones

Términos **Termoeléctrico**: convierte una diferencia de temperatura en electricidad · **ZT**: figura de mérito termoeléctrica  $S^2\sigma T/\kappa$

# Cómo trabajamos y cómo se evalúa

| Tiempo | Actividad               |  | Rúbrica                    | Peso |
|--------|-------------------------|--|----------------------------|------|
| 15 min | EDA                     |  | Razonamiento del pipeline  | 40 % |
| 25 min | Pipeline de modelado    |  | Calidad del resultado      | 25 % |
| breve  | Checkpoint con mentores |  | Comunicación al cliente    | 25 % |
| 25 min | Refinamiento            |  | Limitaciones identificadas | 10 % |
| 20 min | Figuras y conclusión    |  |                            |      |
| 5 min  | Ordenar la presentación |  |                            |      |

**Idea clave** No hay una única respuesta correcta: se evalúa el porqué de cada decisión.

**Términos** **EDA:** análisis exploratorio: mirar los datos antes de modelar

# Lo que el jurado va a buscar en cada criterio

La misma lista de verificación del Día 2, aplicada a su brief

| Criterio                   | Peso | Preguntas que debe poder responder                                                                                |
|----------------------------|------|-------------------------------------------------------------------------------------------------------------------|
| Razonamiento del pipeline  | 40 % | ¿De dónde vienen los datos y qué sesgos tienen? ¿Qué descriptores y por qué? ¿Cómo separaron la prueba sin fugas? |
| Calidad del resultado      | 25 % | ¿Superan a una línea base trivial? ¿Reportan la dispersión (validación cruzada, réplicas), no solo un número?     |
| Comunicación al cliente    | 25 % | ¿Qué decisión recomiendan, con qué confianza, y qué haría el cliente mañana?                                      |
| Limitaciones identificadas | 10 % | ¿Dónde no confiarían en el modelo? ¿Qué dato o experimento falta? ¿Usaron asistentes de IA y para qué?            |

**Idea clave** Un resultado modesto bien justificado vale más que un  $R^2$  alto que nadie puede explicar.

**Términos** **Sesgo:** error sistemático; en datos, las preferencias de quien eligió qué medir o calcular · **IA:** inteligencia artificial: sistemas que aprenden o deciden a partir de datos ·  **$R^2$ :** fracción de la variación que explica el modelo; 1 es perfecto

Fuente: Artrith et al. (2021); Kapoor et al. (2024)

# Logística del reto en Kabré



## Equipos

- 3-4 personas por equipo
- Una sala virtual por equipo
- Mentores rotando entre salas



## Cómputo

- Cada persona con su sesión en kura (2 núcleos, 4 GB)
- Un notebook del equipo: 05\_brief\_A o 05\_brief\_B
- Compartan el archivo al final



## Presentación (5 min)

- Tabla con la propuesta
- 2-3 figuras que la defiendan
- Limitaciones honestas
- Hablen al cliente, no a los expertos en ML
- Si son más de 7 equipos: 3 min

Términos **kura**: cola de CPU de Kabré donde corre Jupyter

# Cierre del curso

- Tarea de MatterGen: una pregunta, tres generaciones, entrega el lunes 12 de octubre en el formulario (enlace en el chat).
- Todo el material queda en el repositorio público del curso en GitHub y en la carpeta de Kabré.
- Encuesta de evaluación del curso (enlace en el chat): nos ayuda a mejorar la siguiente edición.
- Certificado: asistencia y participación (20 %), ejercicios diarios (40 %) y mini-reto (40 %).
- Agradecimientos: CNCA-CeNAT por Kabré y el apoyo técnico; LANOTEC por la sesión experimental.

**Idea clave** Gracias. La mejor forma de aprender esto es aplicarlo a un problema propio la próxima semana.

Términos **CeNAT**: Centro Nacional de Alta Tecnología



Apéndice

# Material de apoyo

Termoeléctricos (Brief A), modelos de lenguaje y polímeros

# El problema industrial



## La oportunidad

Una parte grande de la energía del combustible sale como calor por el escape. Un módulo termoeléctrico la convierte en electricidad sin partes móviles.



## La exigencia

- Escape a unos 400–700 °C
- Ciclos térmicos y vibración
- Costo y toxicidad bajo lupa (Pb, Te)




## La métrica

- $ZT = S^2 \sigma T / \kappa$  a la temperatura de operación
- $ZT \approx 1$  ya es competitivo
- El ZT depende de T: un material bueno a 300 K puede ser malo a 900 K

Fuente: Snyder y Toberer (2008); He y Tritt (2017)

# El efecto Seebeck en una imagen

- Dos conductores distintos unidos en dos puntos, uno caliente y otro frío.
- Los portadores de carga se difunden del lado caliente al frío y aparece un voltaje.
- **Coeficiente Seebeck:**  $S = \Delta V / \Delta T$ .
- Un módulo real conecta muchos pares de semiconductores p y n en serie.



**Términos** **Efecto Seebeck:** una diferencia de temperatura produce un voltaje ( $S = \Delta V / \Delta T$ ) · **Portadores de carga:** electrones o huecos que conducen la corriente

Fuente: Imagen: NASA, [science.nasa.gov](https://science.nasa.gov) (adaptada: recortada y sin el botón de reproducción del video original)

# Familias de termoelectricos y dónde trabajan

| Familia                               | Rango de uso típico      | Comentario                                          |
|---------------------------------------|--------------------------|-----------------------------------------------------|
| $\text{Bi}_2\text{Te}_3$ y aleaciones | cerca de ambiente        | El estándar comercial para refrigeración; Te escaso |
| PbTe y calcogenuros                   | temperaturas intermedias | Muy buen ZT; plomo es una bandera regulatoria       |
| Skutteruditas, half-Heusler           | intermedias a altas      | Candidatos naturales para escape automotriz         |
| SiGe                                  | altas                    | Robusto; usado en generadores para espacio          |
| Óxidos                                | altas                    | Estables y baratos, pero ZT bajo                    |


**Idea clave** Elegir material es elegir un compromiso entre ZT, temperatura, costo, toxicidad y procesabilidad.

**Términos** **Calcogenuros:** compuestos con azufre, selenio o telurio

Fuente: Snyder y Toberer (2008); He y Tritt (2017)

# Cada familia tiene su ventana de temperatura

- $zT$  de materiales representativos de cada familia en función de la temperatura.
- $\text{Bi}_2\text{Te}_3$  domina cerca de ambiente; half-Heusler, SiGe y fases Zintl rinden a alta temperatura.
- Los óxidos quedan abajo en  $zT$ , pero son estables y baratos.
- Arriba: dónde se aplicaría cada rango (automotriz, procesos industriales).



Fuente: Fig. 2 de Wolf, Hinterding y Feldhoff (2019), Entropy 21, 1058, doi:10.3390/e21111058. Licencia CC BY 4.0

# ML para termoelectricos: qué funciona y qué no



## Screening rápido

Modelos entrenados con datos publicados que estiman propiedades termoelectricas desde la composición, para ordenar miles de candidatos antes de sintetizar.



## La física como descriptor

Construir  $S^2\sigma/\kappa$  a partir de  $S$ ,  $\sigma$  y  $\kappa$  le da al modelo la forma de ZT: con los datos del Brief A, el  $R^2$  sube de 0.935 a 0.971.



## ZT estimado $\neq$ ZT medido

Los valores estimados por modelos o cálculos suelen ser optimistas. Úselos para ordenar, no como promesa.




## Más allá del ZT

Costo, disponibilidad de elementos, toxicidad y estabilidad a alta temperatura entran en la decisión.

**Términos ML (aprendizaje automático):** algoritmos que aprenden una relación a partir de ejemplos

Fuente: Gaultois et al. (2016); Zhang y Ling (2018)

# Modelos de lenguaje como predictores químicos



# ¿Y si mis materiales no son cristales? Polímeros y biomateriales



## Representación

Un polímero es una distribución de cadenas, no una molécula única: SMILES no alcanza. BigSMILES y PSMILES describen las unidades que se repiten.



## Modelos

polyBERT: un modelo de lenguaje entrenado con 100 millones de polímeros hipotéticos predice 29 propiedades, unas cien veces más rápido que las huellas diseñadas a mano.



## Datos


No hay un Materials Project de polímeros, y las propiedades se reportan de formas heterogéneas. Suele haber pocos datos: procesos gaussianos y DoE (Día 4) son sus aliados.

**Idea clave** Las ideas del curso se transfieren; cambian la representación y la cantidad de datos.

**Términos** **SMILES**: notación de texto para moléculas (PSMILES y BigSMILES para polímeros) · **polyBERT**: modelo de lenguaje entrenado con 100 millones de polímeros · **Huella (fingerprint)**: vector que resume una molécula o un polímero para un modelo

Fuente: Lin et al. (2019); Kuenneth y Ramprasad (2023); Audus y de Pablo (2017)

# polyBERT: del texto de un polímero a sus propiedades



(a) Huellas hechas a mano frente a huellas de polyBERT. (b) Entrenamiento con PSMILES. (c) 100 millones de polímeros hipotéticos a partir de unos 13 000 sintetizados.

Fuente: Fig. 1 de Kuenneth y Ramprasad (2023), Nat. Commun. 14, 4099, doi:10.1038/s41467-023-39868-6. Licencia CC BY 4.0

# Referencias (1/8)

- [1] Jain, A., Ong, S. P., Hautier, G., et al. (2013). **The Materials Project: A materials genome approach to accelerating materials innovation.** *APL Materials* 1, 011002. doi:10.1063/1.4812323
- [2] Saal, J. E., Kirklin, S., Aykol, M., Meredig, B., Wolverton, C. (2013). **Materials design and discovery with high-throughput density functional theory: the Open Quantum Materials Database (OQMD).** *JOM* 65, 1501–1509. doi:10.1007/s11837-013-0755-4
- [3] Choudhary, K., Garrity, K. F., Reid, A. C. E., DeCost, B., et al. (2020). **The joint automated repository for various integrated simulations (JARVIS) for data-driven materials design.** *npj Comput. Mater.* 6, 173. doi:10.1038/s41524-020-00440-1
- [4] Schmidt, J., Hoffmann, N., Wang, H.-C., Borlido, P., et al. (2023). **Machine-learning-assisted determination of the global zero-temperature phase diagram of materials.** *Adv. Mater.* 35, 2210788. doi:10.1002/adma.202210788
- [5] Draxl, C., Scheffler, M. (2019). **The NOMAD laboratory: from data sharing to artificial intelligence.** *J. Phys. Mater.* 2, 036001. doi:10.1088/2515-7639/ab13bb
- [6] Dunn, A., Wang, Q., Ganose, A., Dopp, D., Jain, A. (2020). **Benchmarking materials property prediction methods: the Matbench test set and Automatminer reference algorithm.** *npj Comput. Mater.* 6, 138. doi:10.1038/s41524-020-00406-3

## Referencias (2/8)

- [7] Riebesell, J., Goodall, R. E. A., Benner, P., Chiang, Y., et al. (2025). **A framework to evaluate machine learning crystal stability predictions.** *Nat. Mach. Intell.* 7, 836–847. doi:10.1038/s42256-025-01055-1
- [8] Ward, L., Dunn, A., Faghaninia, A., et al. (2018). **Matminer: An open source toolkit for materials data mining.** *Comput. Mater. Sci.* 152, 60–69. doi:10.1016/j.commatsci.2018.05.018
- [9] Zhuo, Y., Mansouri Tehrani, A., Brgoch, J. (2018). **Predicting the band gaps of inorganic solids by machine learning.** *J. Phys. Chem. Lett.* 9, 1668–1673. doi:10.1021/acs.jpclett.8b00124
- [10] Rosen, A. S., Iyer, S. M., Ray, D., Yao, Z., et al. (2021). **Machine learning the quantum-chemical properties of metal–organic frameworks for accelerated materials discovery.** *Matter* 4, 1578–1597. doi:10.1016/j.matt.2021.02.015
- [11] Chanussot, L., Das, A., Goyal, S., Lavril, T., et al. (2021). **Open Catalyst 2020 (OC20) dataset and community challenges.** *ACS Catal.* 11, 6059–6072. doi:10.1021/acscatal.0c04525
- [12] Otsuka, S., Kuwajima, I., Hosoya, J., Xu, Y., Yamazaki, M. (2011). **PoLyInfo: Polymer database for polymeric materials design.** *Int. Conf. Emerging Intelligent Data and Web Technologies*, 22–29. doi:10.1109/EIDWT.2011.13

## Referencias (3/8)

- [13] Lafuente, B., Downs, R. T., Yang, H., Stone, N. (2015). **The power of databases: the RRUFF project.** *En Highlights in Mineralogical Crystallography, De Gruyter*, 1–30. doi:10.1515/9783110417104-003
- [14] Cowger, W., Steinmetz, Z., Gray, A., et al. (2021). **Microplastic spectral classification needs an open source community: Open Specy to the rescue!.** *Anal. Chem.* 93, 7543–7548. doi:10.1021/acs.analchem.1c00123
- [15] DeCost, B. L., Hecht, M. D., Francis, T., Webler, B. A., Picard, Y. N., Holm, E. A. (2017). **UHCSDb: UltraHigh Carbon Steel Micrograph DataBase.** *Integr. Mater. Manuf. Innov.* 6, 197–205. doi:10.1007/s40192-017-0097-0
- [16] Song, K., Yan, Y. (2013). **A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defects.** *Appl. Surf. Sci.* 285, 858–864. doi:10.1016/j.apsusc.2013.09.002
- [17] Park, S. (s. f.). **NEU-DET classification (dataset, versión 1, CC BY 4.0).** *Roboflow Universe.* [universe.roboflow.com/park-sung-ho/neu-det-classification](https://universe.roboflow.com/park-sung-ho/neu-det-classification)
- [18] Aversa, R., Modarres, M. H., Cozzini, S., Ciancio, R., Chiusole, A. (2018). **The first annotated set of scanning electron microscopy images for nanoscience.** *Sci. Data* 5, 180172. doi:10.1038/sdata.2018.172

# Referencias (4/8)

- [19] Modarres, M. H., Aversa, R., Cozzini, S., et al. (2017). **Neural network for nanoscience scanning electron microscope image recognition.** *Sci. Rep.* 7, 13282. doi:10.1038/s41598-017-13565-z
- [20] He, K., Zhang, X., Ren, S., Sun, J. (2016). **Deep residual learning for image recognition.** *CVPR 2016*, 770–778. doi:10.1109/CVPR.2016.90
- [21] Shahriari, B., Swersky, K., Wang, Z., Adams, R. P., de Freitas, N. (2016). **Taking the human out of the loop: A review of Bayesian optimization.** *Proc. IEEE* 104, 148–175. doi:10.1109/JPROC.2015.2494218
- [22] Rasmussen, C. E., Williams, C. K. I. (2006). **Gaussian Processes for Machine Learning.** *MIT Press*
- [23] Balandat, M., Karrer, B., Jiang, D. R., et al. (2020). **BoTorch: A framework for efficient Monte-Carlo Bayesian optimization.** *NeurIPS* 33. arXiv:1910.06403
- [24] PalDey, S., Deevi, S. C. (2003). **Single layer and multilayer wear resistant coatings of (Ti,Al)N: a review.** *Mater. Sci. Eng. A* 342, 58–79. doi:10.1016/S0921-5093(02)00259-9

# Referencias (5/8)

- [25] Xu, P., Ji, X., Li, M., Lu, W. (2023). **Small data machine learning in materials science.** *npj Comput. Mater.* 9, 42. doi:10.1038/s41524-023-01000-z
- [26] Zhang, Y., Ling, C. (2018). **A strategy to apply machine learning to small datasets in materials science.** *npj Comput. Mater.* 4, 25. doi:10.1038/s41524-018-0081-z
- [27] Raccuglia, P., Elbert, K. C., Adler, P. D. F., et al. (2016). **Machine-learning-assisted materials discovery using failed experiments.** *Nature* 533, 73–76. doi:10.1038/nature17439
- [28] Lookman, T., Balachandran, P. V., Xue, D., Yuan, R. (2019). **Active learning in materials science with emphasis on adaptive sampling using uncertainties for targeted design.** *npj Comput. Mater.* 5, 21. doi:10.1038/s41524-019-0153-8
- [29] Chen, C., Ong, S. P. (2022). **A universal graph deep learning interatomic potential for the periodic table.** *Nat. Comput. Sci.* 2, 718–728. doi:10.1038/s43588-022-00349-3
- [30] Batatia, I., Benner, P., Chiang, Y., et al. (2023). **A foundation model for atomistic materials chemistry.** *preprint.* arXiv:2401.00096

## Referencias (6/8)

- [31] Merchant, A., Batzner, S., Schoenholz, S. S., et al. (2023). **Scaling deep learning for materials discovery.** *Nature* 624, 80–85. doi:10.1038/s41586-023-06735-9
- [32] Jablonka, K. M., Schwaller, P., Ortega-Guerrero, A., Smit, B. (2024). **Leveraging large language models for predictive chemistry.** *Nat. Mach. Intell.* 6, 161–169. doi:10.1038/s42256-023-00788-1
- [33] Szymanski, N. J., Rendy, B., Fei, Y., et al. (2023). **An autonomous laboratory for the accelerated synthesis of novel materials.** *Nature* 624, 86–91. doi:10.1038/s41586-023-06734-w
- [34] Artrith, N., Butler, K. T., Coudert, F.-X., et al. (2021). **Best practices in machine learning for chemistry.** *Nat. Chem.* 13, 505–508. doi:10.1038/s41557-021-00716-z
- [35] Kapoor, S., Cantrell, E. M., Peng, K., et al. (2024). **REFORMS: Consensus-based recommendations for machine-learning-based science.** *Sci. Adv.* 10, eadk3452. doi:10.1126/sciadv.adk3452
- [36] Butler, K. T., Davies, D. W., Cartwright, H., Isayev, O., Walsh, A. (2018). **Machine learning for molecular and materials science.** *Nature* 559, 547–555. doi:10.1038/s41586-018-0337-2

# Referencias (7/8)

- [37] Snyder, G. J., Toberer, E. S. (2008). **Complex thermoelectric materials.** *Nature Materials* 7, 105–114. doi:10.1038/nmat2090
- [38] He, J., Tritt, T. M. (2017). **Advances in thermoelectric materials research: Looking back and moving forward.** *Science* 357, eaak9997. doi:10.1126/science.aak9997
- [39] Gaultois, M. W., Oliynyk, A. O., Mar, A., et al. (2016). **Perspective: Web-based machine learning models for real-time screening of thermoelectric materials properties.** *APL Materials* 4, 053213. doi:10.1063/1.4952607
- [40] Wolf, M., Hinterding, R., Feldhoff, A. (2019). **High power factor vs. high zT: A review of thermoelectric materials for high-temperature application.** *Entropy* 21, 1058. doi:10.3390/e21111058
- [41] Lin, T.-S., Coley, C. W., Mochigase, H., et al. (2019). **BigSMILES: A structurally-based line notation for describing macromolecules.** *ACS Cent. Sci.* 5, 1523–1531. doi:10.1021/acscentsci.9b00476
- [42] Kuenneth, C., Ramprasad, R. (2023). **polyBERT: a chemical language model to enable fully machine-driven ultrafast polymer informatics.** *Nat. Commun.* 14, 4099. doi:10.1038/s41467-023-39868-6

# Referencias (8/8)

[43] Audus, D. J., de Pablo, J. J. (2017). **Polymer informatics: Opportunities and challenges.** *ACS Macro Lett.* 6, 1078–1082.  
[doi:10.1021/acsmacrolett.7b00228](https://doi.org/10.1021/acsmacrolett.7b00228)



# ¡Gracias!

Tomás Rojas Solórzano  
Universidad de Costa Rica · [tomas.rojas\\_s@ucr.ac.cr](mailto:tomas.rojas_s@ucr.ac.cr)